

Aplikace neuronových sítí

Podmínky předmětu, úvod, motivace

Podmínky předmětu

Podmínky předmětu

- Předmět je založen na bodovém systému
- Body získáte především za vypracovaná cvičení
- Účast na hodinách je nepovinná, ale bodovaná (2 body za účast)
- Cvičení jsou samostatné úlohy odevzdávané formou commitů do git repozitáře
- Předmět není zakončen zkouškou
- Výsledná známka bude udělena na základě dosažených bodů ze cvičení a docházky

Bodový systém

- 100% účast na přednáškách znamená cca 10 % bodů
- Zbylých 90 % bodů se získává vypracováním úloh
- Lze posbírat i bonusové body za nadstandardní aktivitu
- Teoreticky jsou možné i výsledky méně než 0 % a více než > 100 %
- Závislost výsledné známky na dosažených bodech určuje následující tabulka:

| Dosažené body | Známka |
|--------------------------|--------|
| $\geq 90 \%$ | 1 |
| $\geq 80 \%$ a $< 90 \%$ | 1- |
| $\geq 70 \%$ a $< 80 \%$ | 2 |
| $\geq 60 \%$ a $< 70 \%$ | 2- |
| $\geq 50 \%$ a $< 60 \%$ | 3 |
| $< 50 \%$ | 4 |

Cvičení

- Cvičení jsou připravena jako notebooky v jazyce Python
- Založena na knihovně PyTorch
- Obsahují bodované unit testy
- Každý test, který projde, bude odměněn body podle složitosti odpovídajícího úkolu (inspirováno story pointy nad Fibonacciho sekvencí 1, 2, 3, 5, 8, ...)
- Všechny testy označené jako **required** musí bezpodmínečně projít, jinak nebude předmět uznán (ani při celkovém zisku bodů > 50 %)
- Každé cvičení má deadline na vypracování. Testy, které procházejí až po termínu, získávají pouze 50 % deklarovaných bodů

Úvod a přehled

Umělá intelligence (Artificial Intelligence, AI)

- Plánování
- Učení
- Ontologie
- ...

Strojové učení (Machine Learning, ML)

- Lineární klasifikace/regrese
- Statistické metody
- Bayesovské rozhodování
- Neuronové sítě
- ...

Hluboké učení (Deep Learning, DL)

- Hluboké neuronové sítě

předmět ANS 2023

Příklady známých aplikací neuronových sítí a hlubokého učení




DeepL (2017)



ChatGPT (2022)




Midjourney (2022)



DeepMind AlphaFold (2018)



Tesla autopilot (2016)

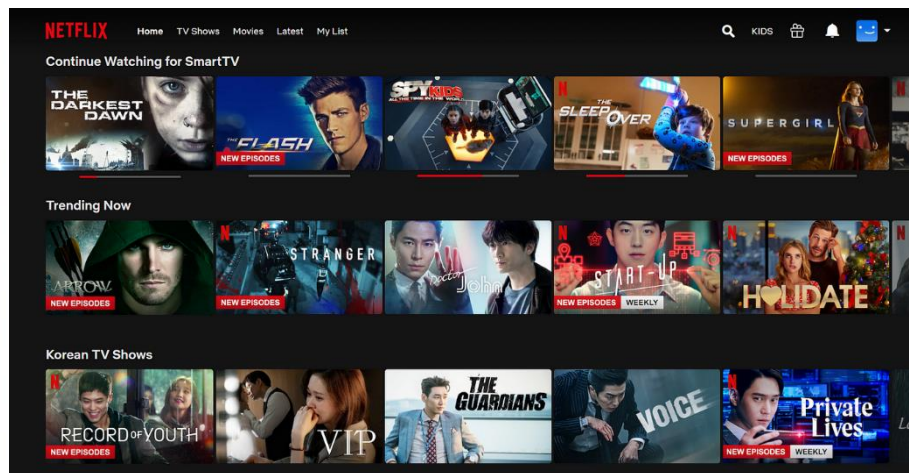





DeepMind AlphaGo (2015)



deepfake (2019)


Další příklady aplikací neuronových sítí



Témata předmětu: od jednoduchých modelů po složité

1. Lineární klasifikace
 2. Optimalizace
 3. Zpětná propagace
 4. Vícevrstvý perceptron
 5. Konvoluční sítě
 6. Hraní si s konvolučními sítěmi (adversarial examples, deep dream, style transfer)
 7. Rekurentní sítě (sekvenční data, jazykové modely)
 8. Attention mechanismus a transformery (BERT, (Chat)GPT)
 9. Generativní modely: GAN (thispersondoesnotexist.com)
 10. Generativní modely: (variační) autoenkodéry a diffusion (midjourney a spol.)
-
- základy učení s učitelem
klasifikace obrázků
- s učitelem i bez učitele
- učení bez
učitele

Proč jsou neurosítě tak úspěšné? Škálování




zdroj: [Andrew Ng, "Neural networks and Deep Learning"](#)

Proč jsou neurosítě tak úspěšné? Škálování

- Velkou roli hraje škálování
 - Základní principy byly vynalezeny již v 70. letech 20. století
- Škálování dat
 - Díky digitalizaci a rozvoji internetu obrovské množství dat ve všude
- Škálování hardware
 - Pomohl především rozvoj GPU a jejich programovatelnost


Proč jsou neurosítě tak úspěšné? Cena za výkon



zdroj: <https://www.lesswrong.com/posts/c6KFvQcZggQKZzxr9/trends-in-gpu-price-performance>

Proč jsou neurosítě tak úspěšné? Alexnet (2012)

1000 classes, Top-5 error [%]



Proč jsou neurosítě tak úspěšné? Alexnet (2012)

- [Krizhevsky, Sutskever, Hinton: “ImageNet Classification with Deep Convolutional Neural Networks”](#)
- Síť, která “nastartovala DNN/CNN revoluci”
- Autoři nevyvinuli žádný nový algoritmus, “pouze” ukázali, jak správně CNN používat
- Místo sigmoid aktivací přechod na ReLU
- Kromě klasické L2 regularizace navíc Dropout
- Výrazné umělé rozšiřování dat (data augmentation)
- Místo SGD → Momentum SGD
- Postupné snižování learning rate
- Trénováno na dvou GTX 580 celkem 5-6 dní