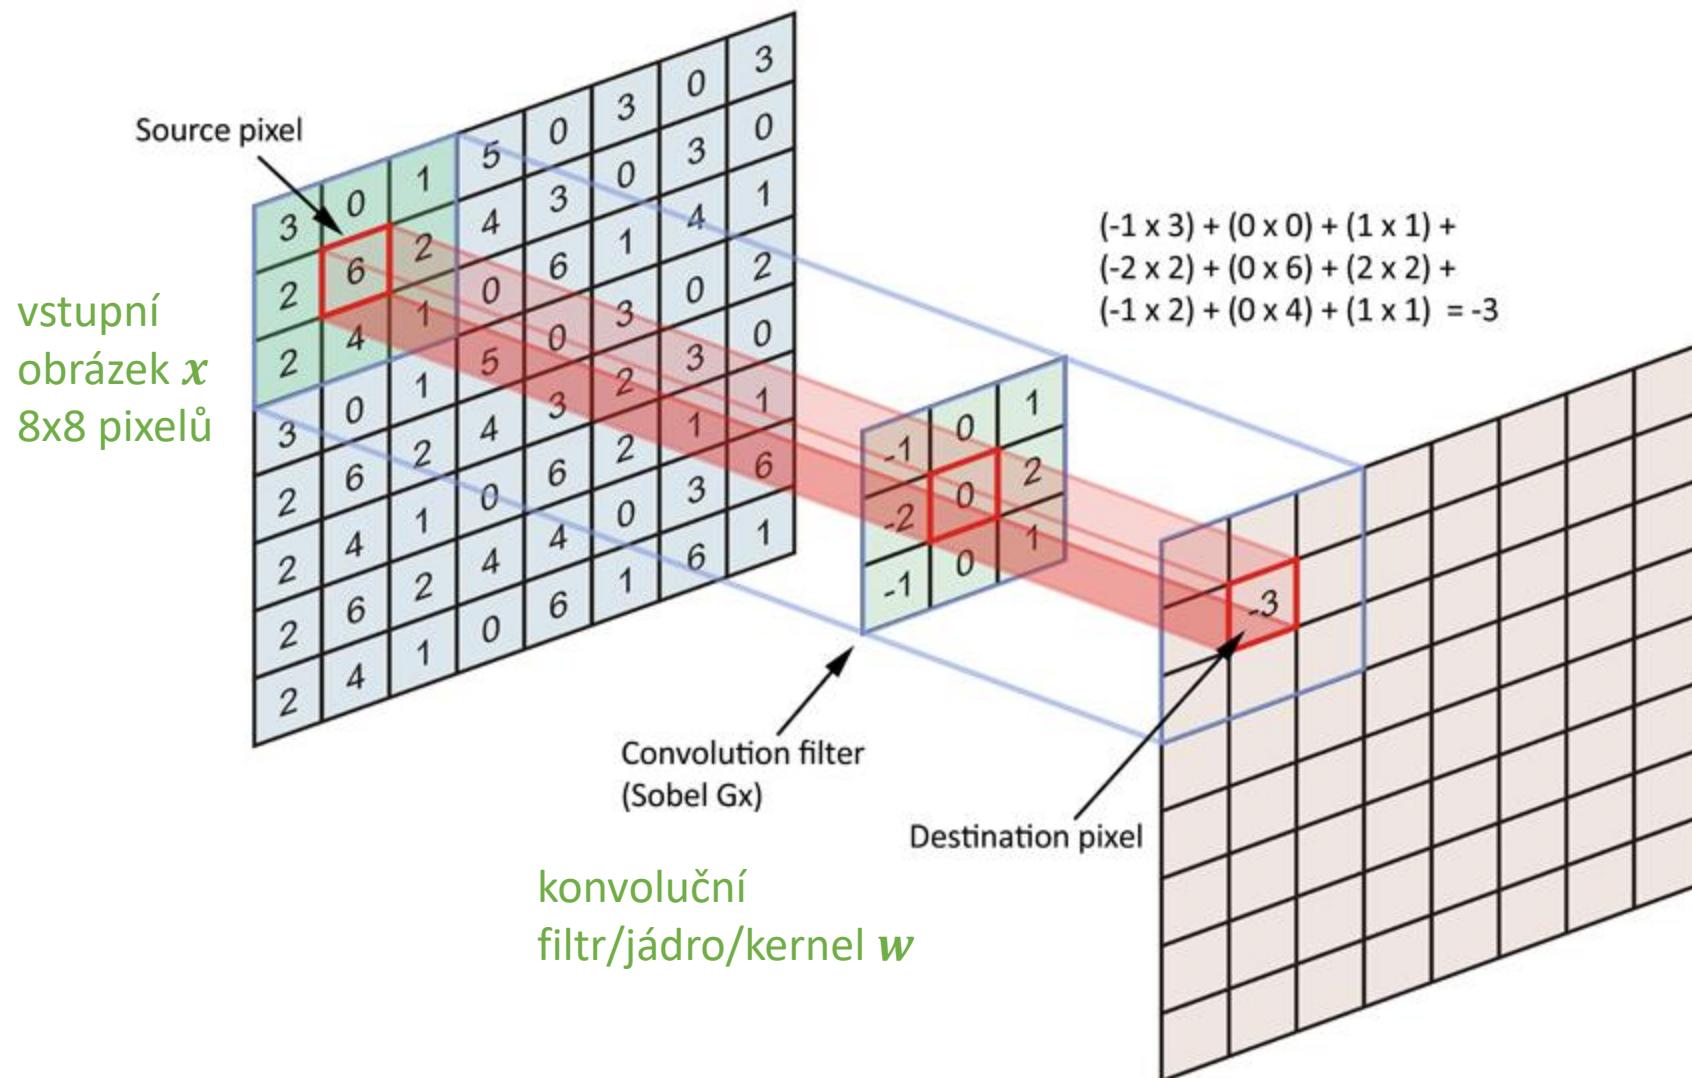


# Aplikace neuronových sítí

---

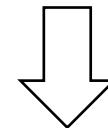
## Konvoluční sítě

# Dvourozměrná konvoluce



**Pro každý výstupní pixel:**

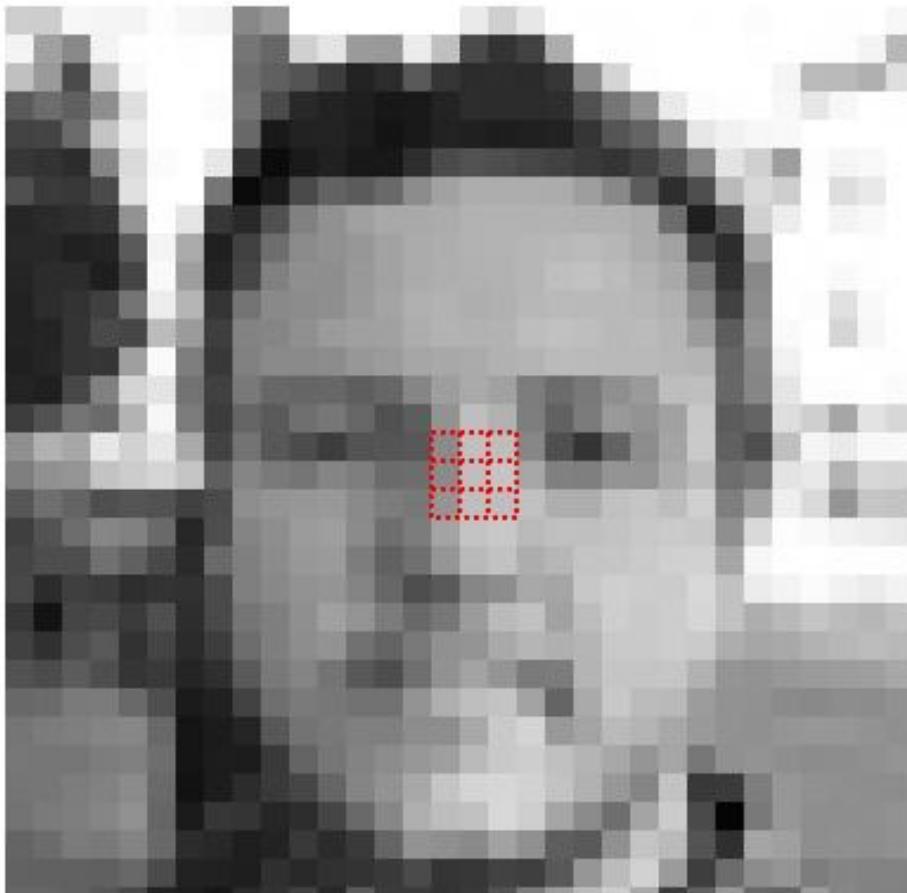
$$z_{uv} = \sum_{i=-k}^{+k} \sum_{j=-k}^{+k} w_{ij} x_{u+i, v+j} + b$$



$$z_{uv} = \mathbf{w}^T \mathbf{x}_{uv} + b$$

výstupní obrázek z velikost závisí na nastavení konvoluce

# Demo

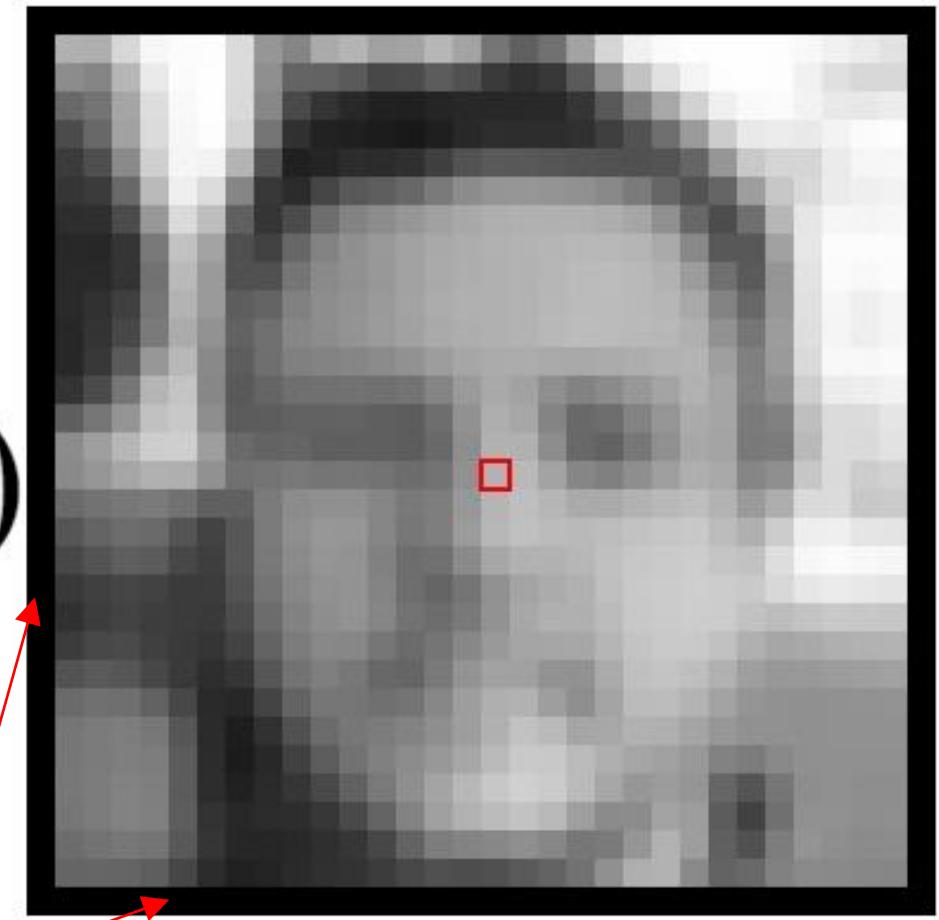


input image

$$\begin{aligned} & (139 \times 0.0625 + 192 \times 0.125 + 190 \times 0.0625 \\ & + 139 \times 0.125 + 191 \times 0.25 + 197 \times 0.125 \\ & + 149 \times 0.0625 + 191 \times 0.125 + 190 \times 0.0625) \\ & = 179 \end{aligned}$$

kernel:

blur ▾



output image

okraje?

# Padding

Jak se vypořádat s okraji?

|                |                |                |   |   |   |   |
|----------------|----------------|----------------|---|---|---|---|
| 0 <sub>0</sub> | 0 <sub>1</sub> | 0 <sub>2</sub> | 0 | 0 | 0 | 0 |
| 0 <sub>2</sub> | 3 <sub>2</sub> | 3 <sub>0</sub> | 2 | 1 | 0 | 0 |
| 0 <sub>0</sub> | 0 <sub>1</sub> | 0 <sub>2</sub> | 1 | 3 | 1 | 0 |
| 0              | 3              | 1              | 2 | 2 | 3 | 0 |
| 0              | 2              | 0              | 0 | 2 | 2 | 0 |
| 0              | 2              | 0              | 0 | 0 | 1 | 0 |
| 0              | 0              | 0              | 0 | 0 | 0 | 0 |

Obrázek např. "nastavíme" nulami  
→ tzv. zero padding

|      |      |      |
|------|------|------|
| 6.0  | 14.0 | 17.0 |
| 14.0 | 12.0 | 12.0 |
| 8.0  | 10.0 | 17.0 |

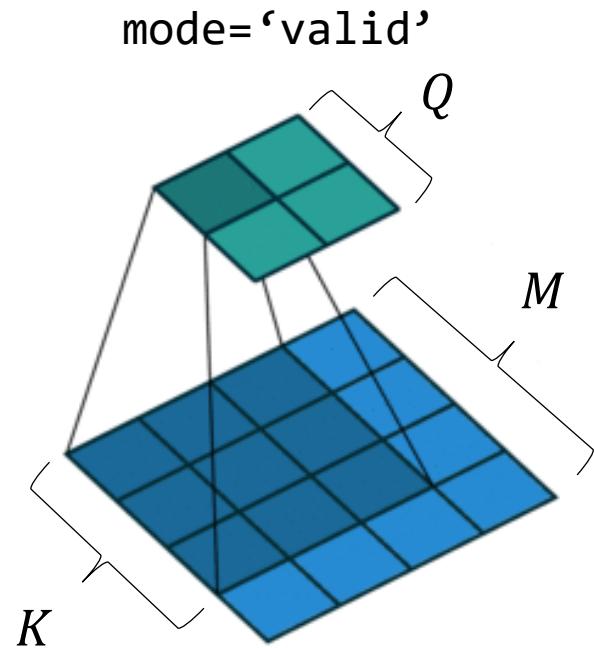
(výsledek je 3x3, protože  
v příkladu stride=2)

Existují další způsoby: const, wrap, symm, ...

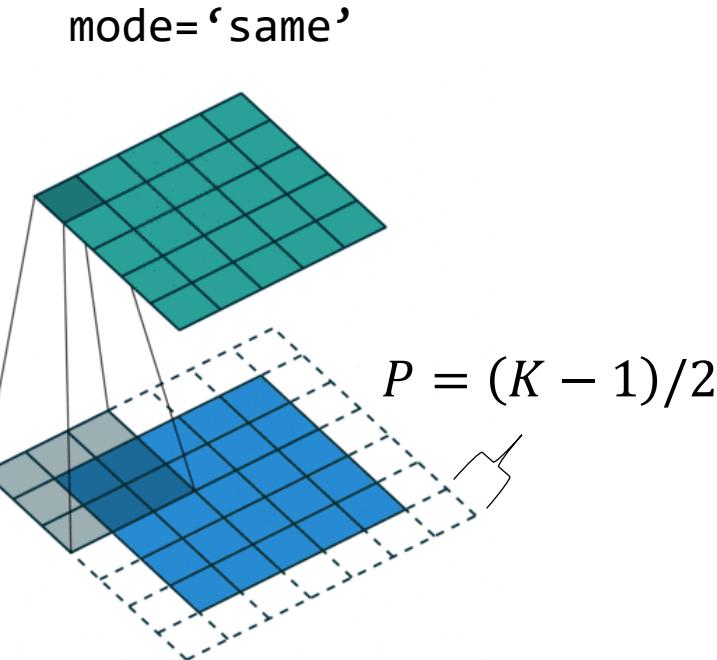
obrázky: [https://github.com/vdumoulin/conv\\_arithmetic](https://github.com/vdumoulin/conv_arithmetic)

# Velikost výstupu v závislosti na paddingu

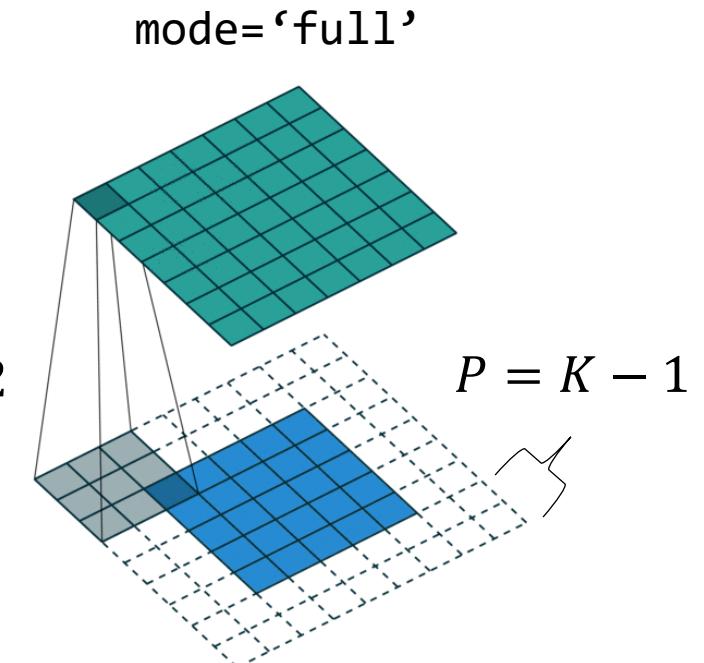
`scipy.signal.convolve2d(x, w, mode, ...)` → výstup  $Q \times Q$



$$\begin{aligned} Q &= M - (K - 1) \\ &= 4 - 3 + 1 \\ &= 2 \end{aligned}$$



$$\begin{aligned} Q &= M - (K - 1) + 2P \\ &= M \\ &= 5 \end{aligned}$$



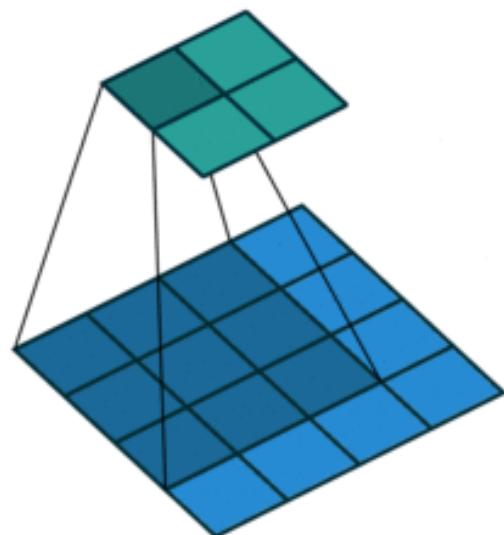
$$\begin{aligned} Q &= M - (K - 1) + 2P \\ &= M + (K - 1) \\ &= 5 + 3 - 1 \\ &= 7 \end{aligned}$$

obrázky: [https://github.com/vdumoulin/conv\\_arithmetic](https://github.com/vdumoulin/conv_arithmetic)

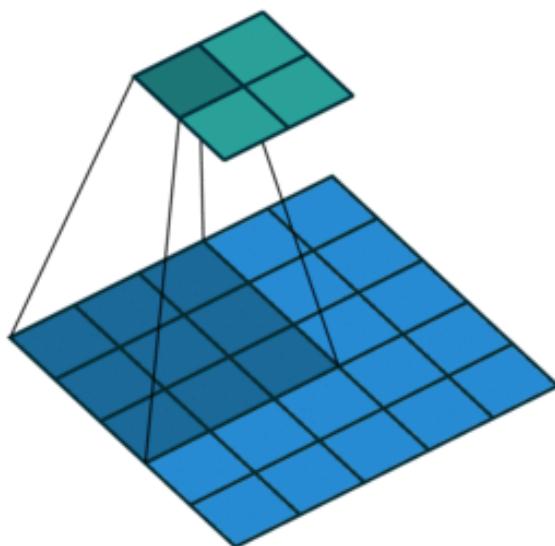
# Velikost kroku

V anglické literatuře **stride**

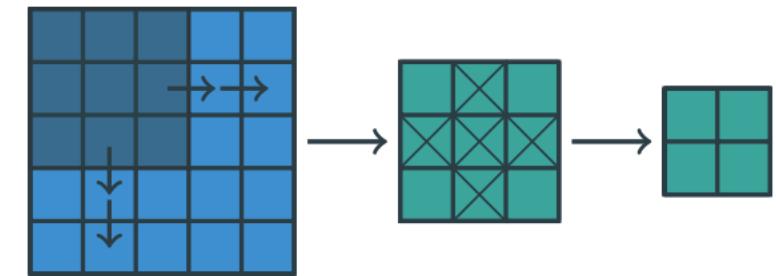
$$S = 1$$



$$S = 2$$



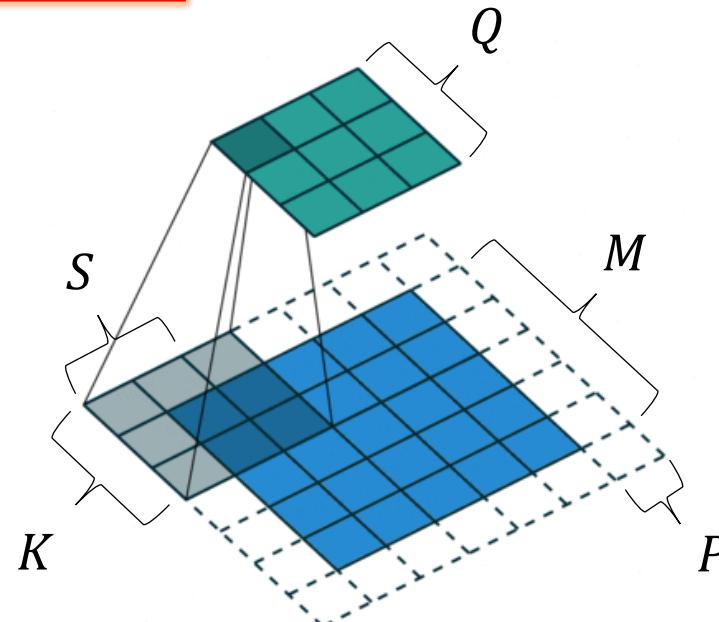
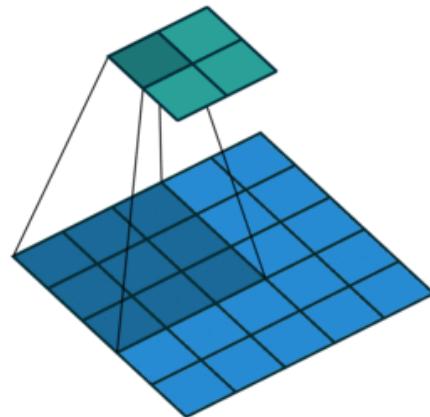
$S = 2$  je to samé, jako když  $S = 1$ , ale ponecháme pouze každý  $S$ -tý výstup:



Vidíme tedy, že velikost výstupu se krokem  $S$  dělí  
(mezery jsou ve výstupu)

# Velikost výstupu konvoluce

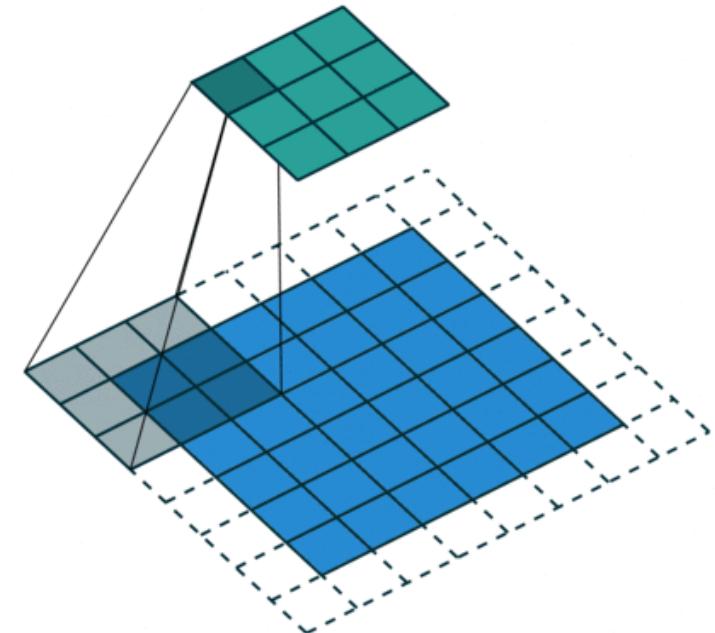
$$Q = \left\lceil \frac{M + 2P - K}{S} \right\rceil + 1$$



$$Q = \left\lceil \frac{5 + 2 \cdot 0 - 3}{2} \right\rceil + 1 = 2$$

$$Q = \left\lceil \frac{5 + 2 \cdot 1 - 3}{2} \right\rceil + 1 = 3$$

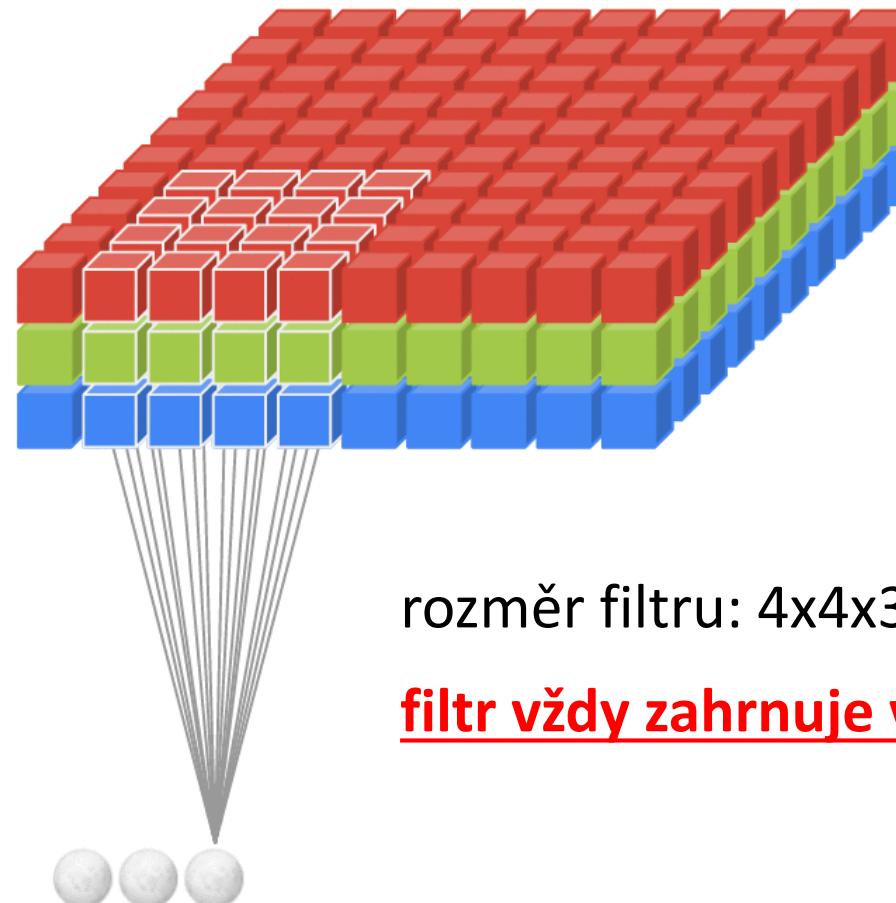
“Když to nevyjde hezky”:



$$Q = \left\lceil \frac{6 + 2 \cdot 1 - 3}{2} \right\rceil + 1 = 3$$

obrázky: [https://github.com/vdumoulin/conv\\_arithmetic](https://github.com/vdumoulin/conv_arithmetic)

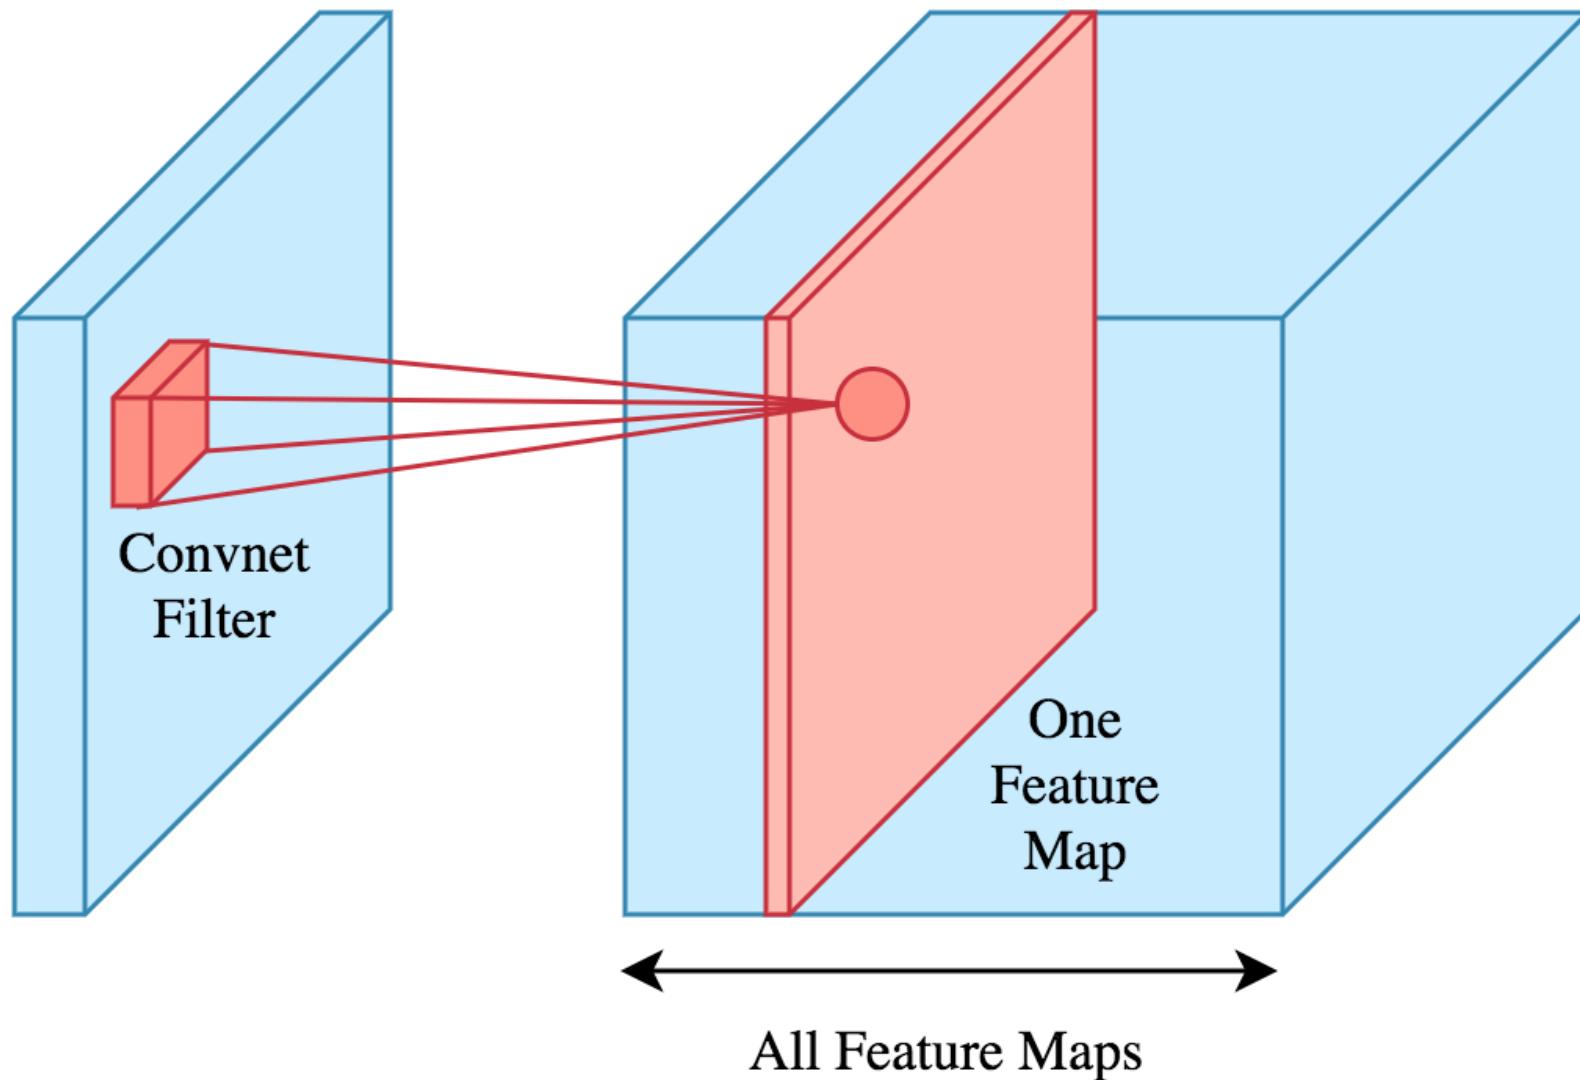
# Vícekanálový vstup



rozměr filtru:  $4 \times 4 \times 3$

**filtr vždy zahrnuje všechny vstupní kanály**

# Více konvolučních filtrů



# Konvoluce jako vrstva v neurosíti

Váhy  $W$  jsou tensor tvaru

$$K \times K' \times C \times F$$

Bias  $b$  je vektor délky

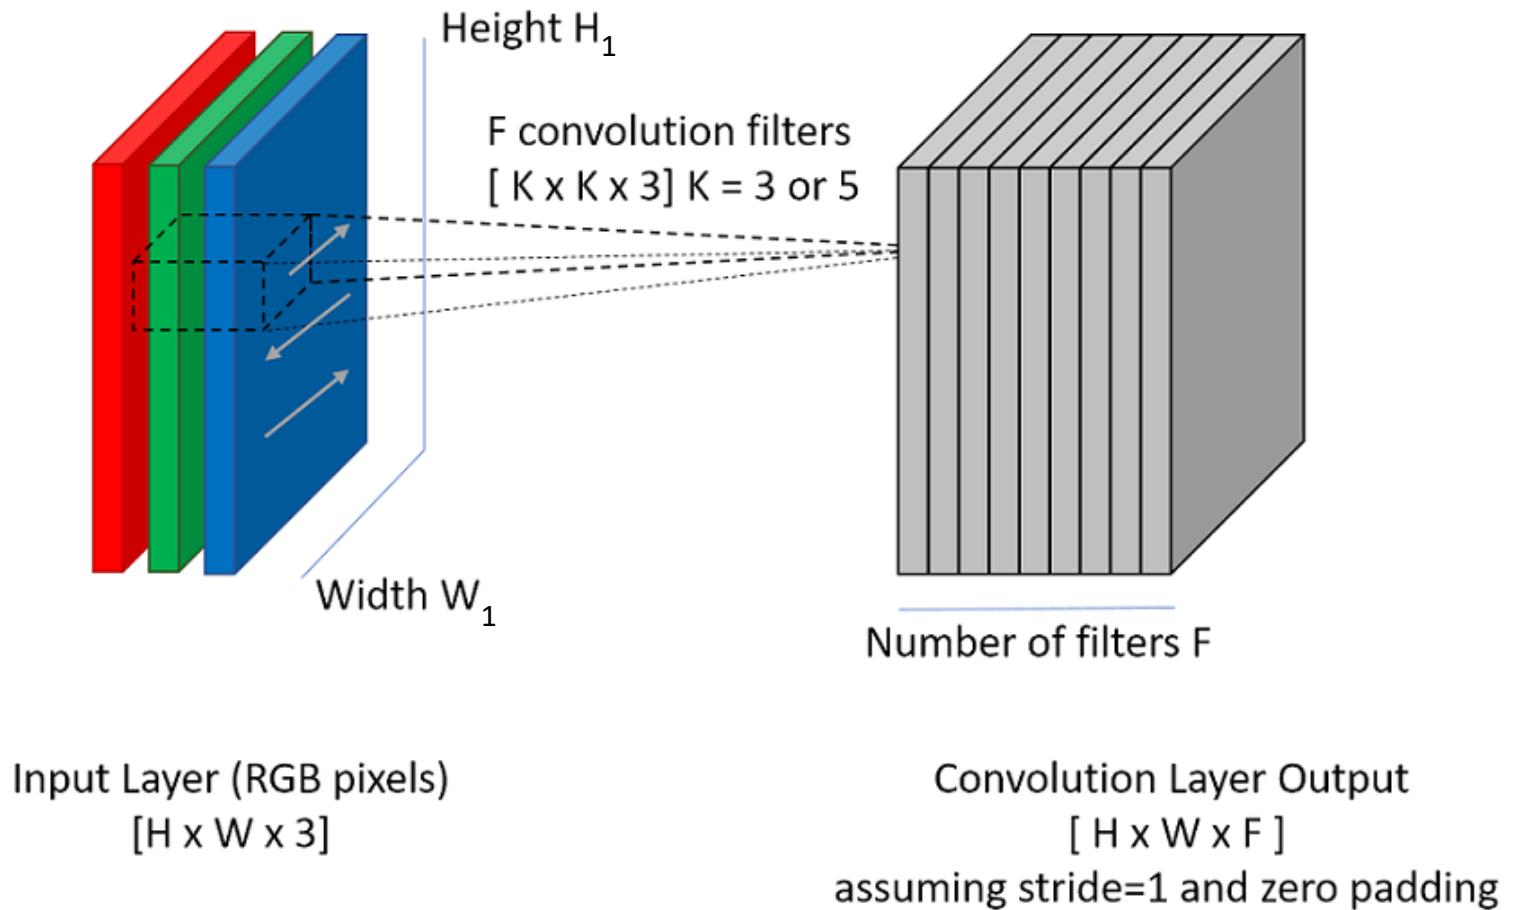
$$F$$

Výstup má rozměr

$$Q = \left\lfloor \frac{M + 2P - K}{S} \right\rfloor + 1$$

Hyperparametry:

- velikost filtru  $K$
- počet filtrů  $F$
- padding (okraj)  $P$
- stride (krok)  $S$



# Příklad: RGB $32 \times 32 \times 3$ , 10 $5 \times 5$ filtrů, bez paddingu, stride=1

Váhy W jsou tensor tvaru

$$5 \times 5 \times 3 \times 10$$

Bias b je vector délky

10 (počet filtrů)

Počet parametrů vrstvy

$$5 \cdot 5 \cdot 3 \cdot 10 + 10 = 760$$

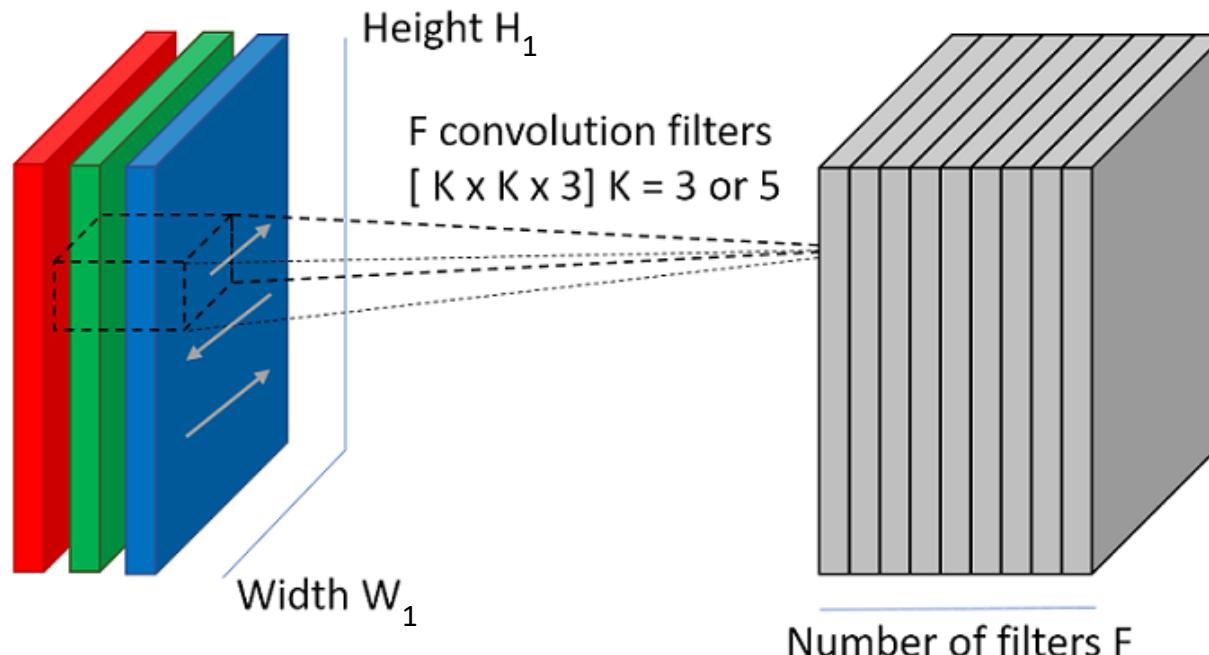
váhy

biasy

Vstup tvaru

$$32 \times 32 \times 3$$

Pro porovnání lineární vrstva  $(32 \cdot 32 \cdot 3) \times (28 \cdot 28 \cdot 10)$   
by měla  $32 \cdot 32 \cdot 3 \cdot 28 \cdot 28 \cdot 10 \approx 24 \cdot 10^6$  parametrů!



obrázek: <http://john-cd.com/blog/2017/03/08/Deep-Learning>

Výstup má rozměr

$$Q \times Q \text{ kde } Q = \left\lceil \frac{32+2 \cdot 0 - 5}{1} \right\rceil + 1 = 28$$

a hloubku

10 (počet filtrů)

# Zpětný průchod konvoluce: gradient na váhy

- Dopředný průchod

$$z_{uv} = \sum_{i=1}^K \sum_{j=1}^K \sum_{c=1}^C w_{ijc} x_{su+i, sv+j, c} + b$$

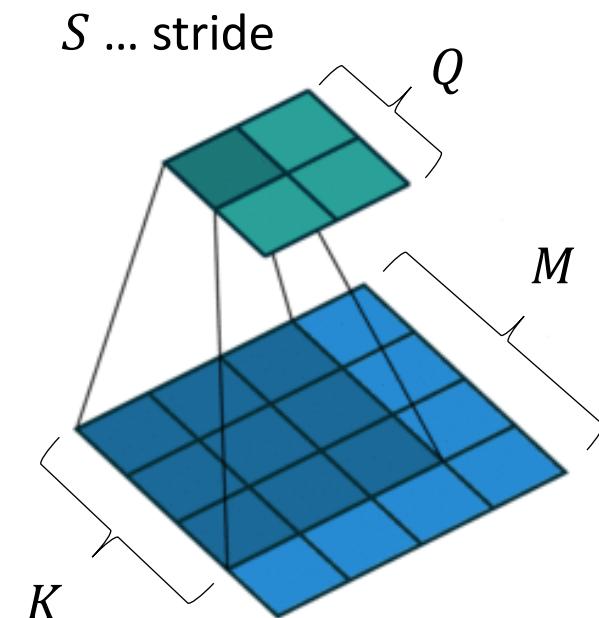
- Lokální gradient

$$\frac{\partial z_{uv}}{\partial w_{ijc}} = x_{i+su, j+sv, c}$$

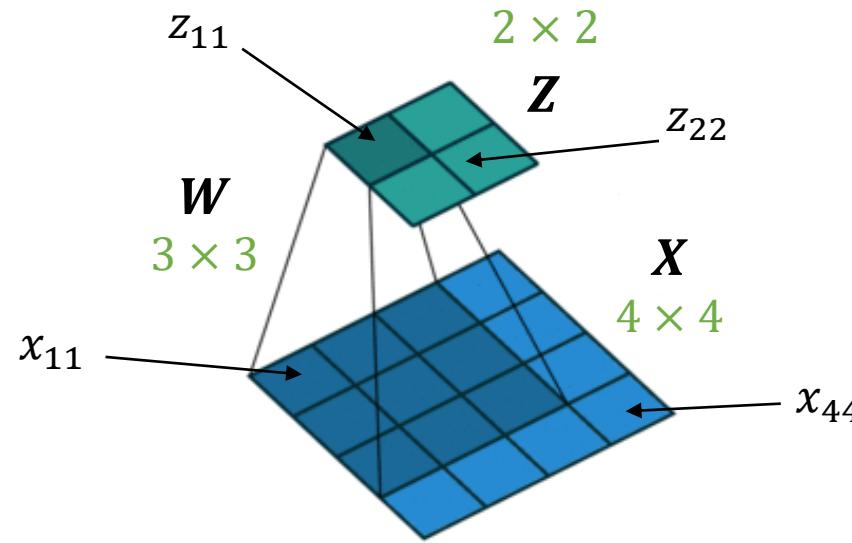
- Celkový gradient na váhy

$$\begin{aligned} \frac{\partial L}{\partial w_{ijc}} &= \sum_{u=1}^Q \sum_{v=1}^Q \frac{\partial L}{\partial z_{uv}} \cdot \frac{\partial z_{uv}}{\partial w_{ijc}} \quad \text{pokud } S > 1: \\ &= \sum_{u=1}^Q \sum_{v=1}^Q \overline{z_{uv}} \cdot x_{i+su, j+sv, c} \quad \text{"mezery" } \underline{\text{ve vstupu}} \end{aligned}$$

- Zpětný průchod na váhy je tedy rovněž konvoluce!



# Konvoluce jako lineární vrstva



konvoluci na obrázku lze zapsat maticově:

$$2 \times 2 \rightarrow 4 \times 1$$

$$\begin{bmatrix} z_{11} \\ z_{12} \\ z_{21} \\ z_{22} \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 & 0 & 0 & 0 & 0 \\ 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 \\ 0 & 0 & 0 & 0 & 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} \end{bmatrix} \begin{bmatrix} x_{11} \\ x_{12} \\ x_{13} \\ \vdots \\ x_{42} \\ x_{43} \\ x_{44} \end{bmatrix}$$

... podobné lineární vrstvě

# Zpětný průchod konvoluce: gradient na vstup

- Připomeňme, že pro lineární vrstvu

$$4 \times 1 \rightarrow 2 \times 2$$

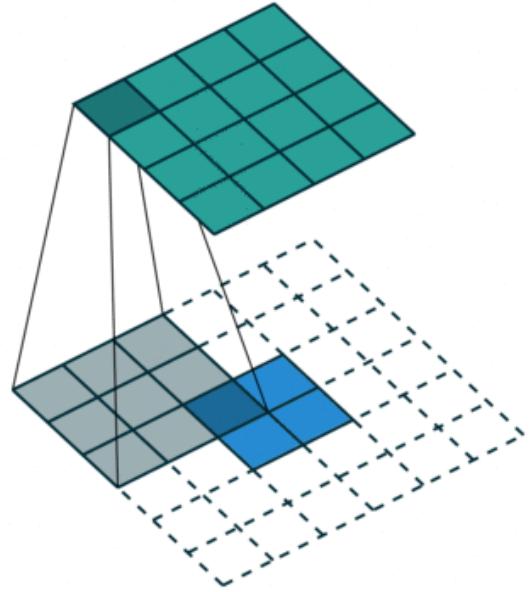
$$\mathbf{z} = \mathbf{W}\mathbf{x}$$

je gradient na vstup

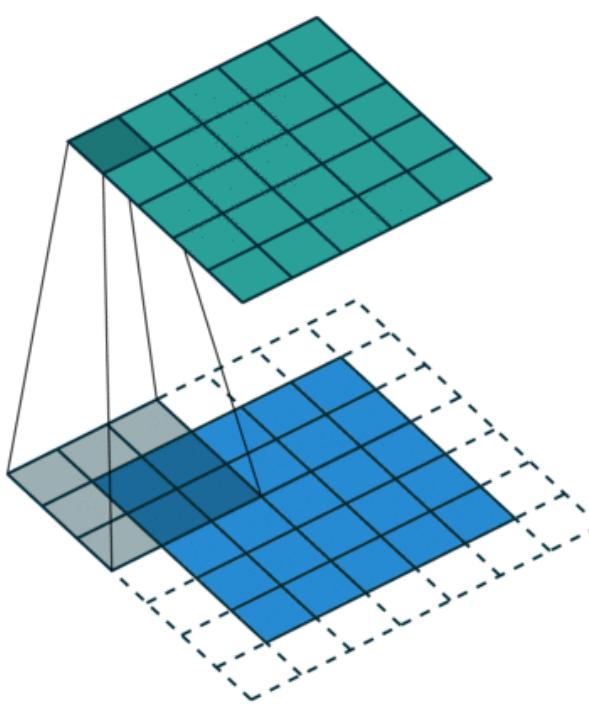
$$16 \times 1 \rightarrow 4 \times 4 \quad 16 \times 4 \quad 2 \times 2 \rightarrow 4 \times 1$$
$$\bar{\mathbf{x}} = \mathbf{W}^T \bar{\mathbf{z}}$$

- Zpětná propagace gradientu na vstup konvoluce je tedy opět konvoluce, jejíž lineární forma má transponovanou matici  $\mathbf{W}$
- Odtud anglický název **transposed convolution**
- “Obrácená” konvoluce: z tvaru výstupu  $\mathbf{z}$  na tvar vstupu  $\mathbf{x}$ 
  - Nalezneme dokonce i název dekonvoluce: špatně, ve skutečnosti něco jiného

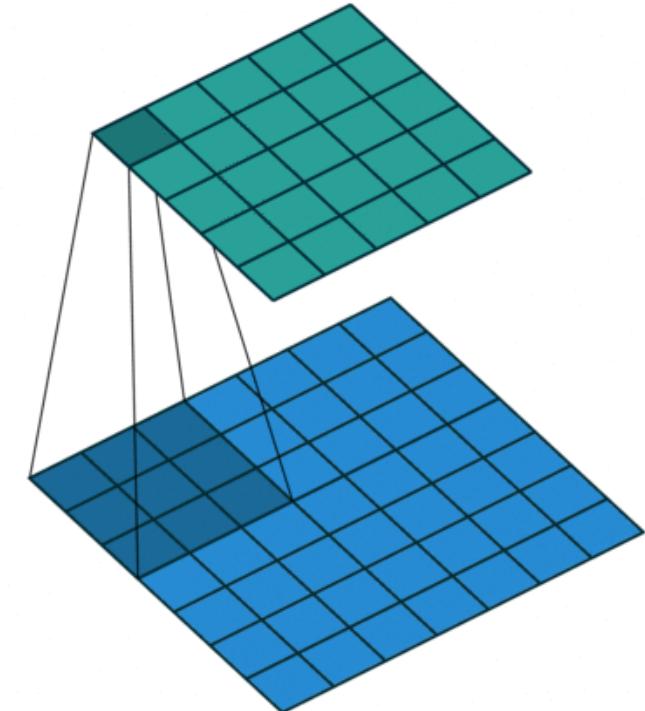
# Ilustrace transponované konvoluce, stride=1



bez paddingu, stride=1

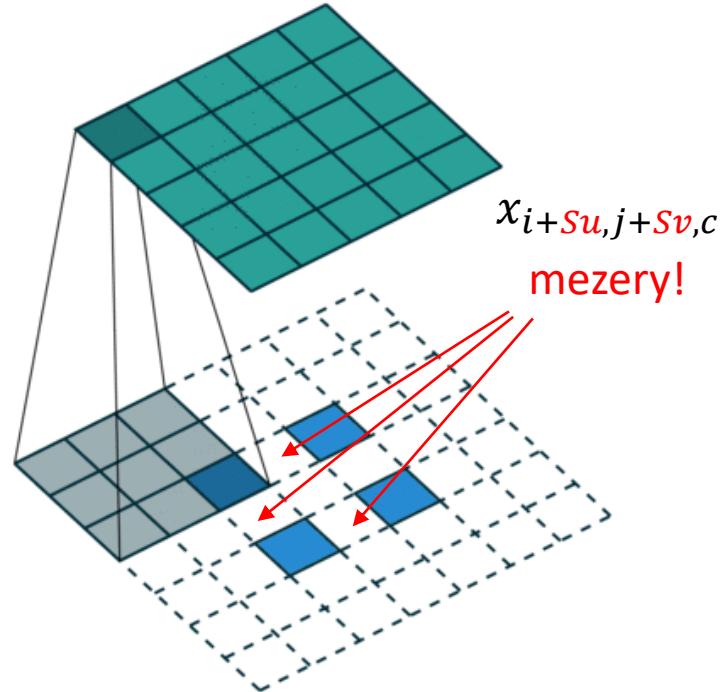


poloviční padding, stride=1

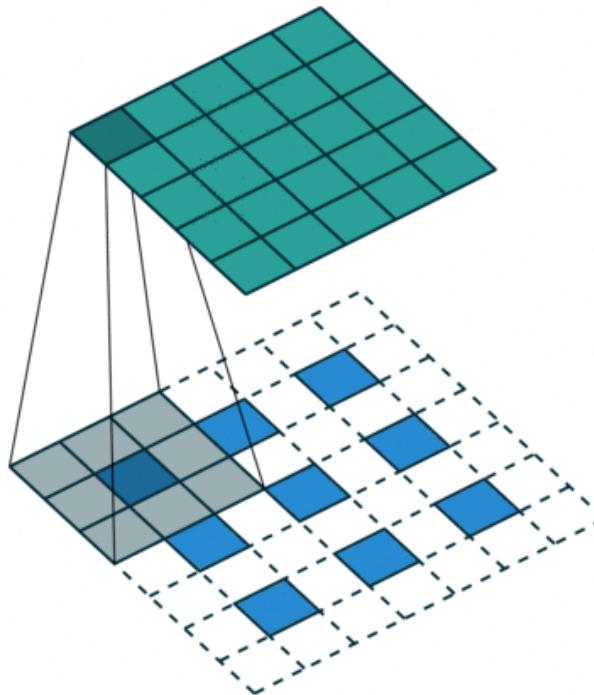


full padding, stride=1

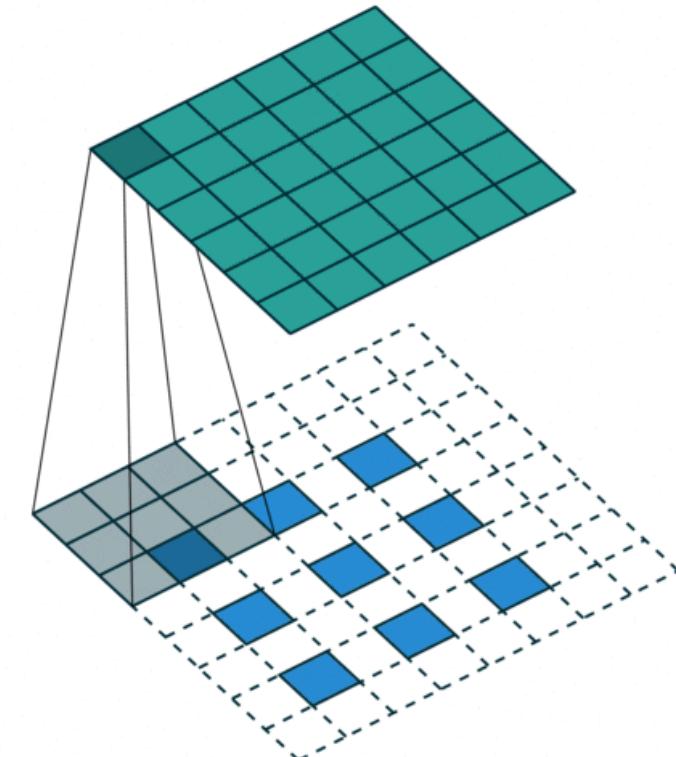
# Illustrace transponované konvoluce, stride > 1



bez paddingu, stride=2



poloviční padding, stride=2

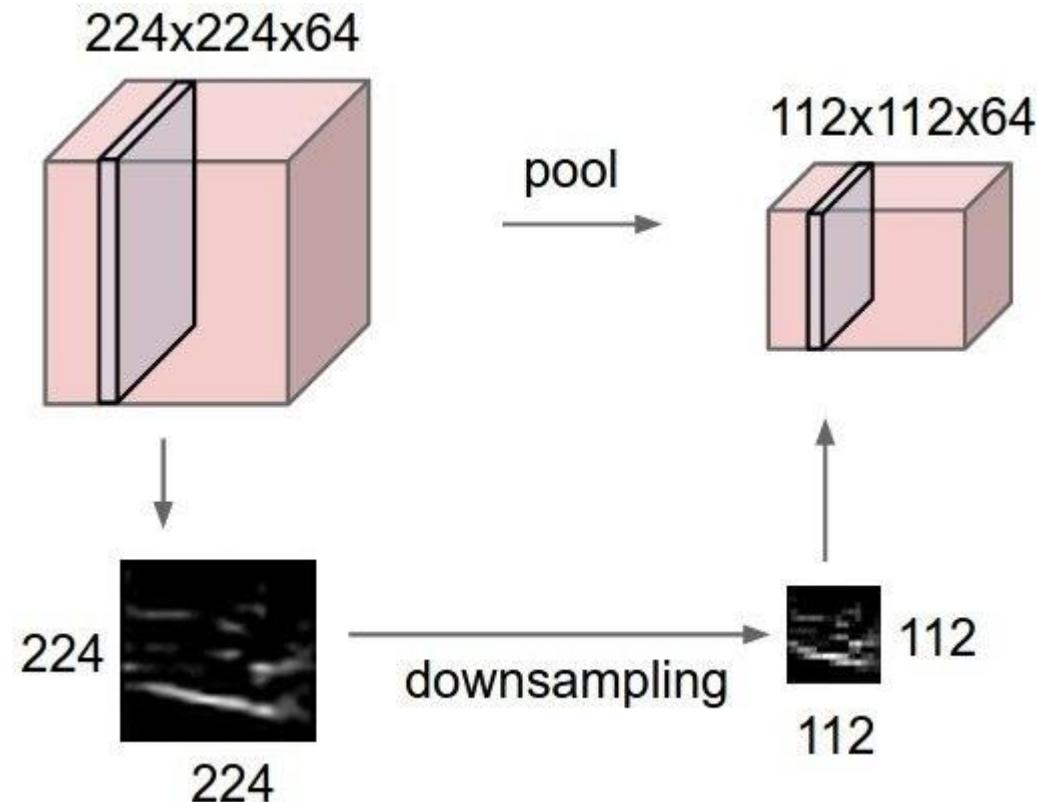


poloviční padding, stride=2  
"když to nevyjde hezky"

mezery → anglický název **fractionally strided convolution**

# Pooling

cílem zmenšit objem dat → méně paměti, tlak na kompresi příznakového prostoru



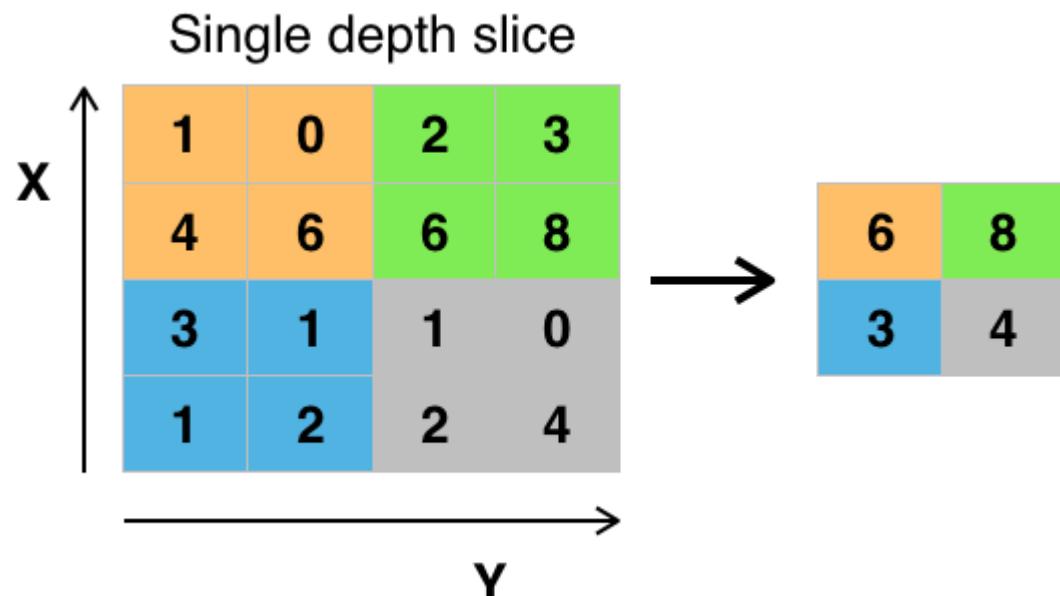
obrázek: <http://cs231n.github.io/>

# Max pooling

- Nejčastější forma poolingu
- Robustní vůči malému posunu vstupu

**Počet parametrů: 0**

např. 2x2 max pooling, stride=2:



**výstup:**

maximum přes každé okénko

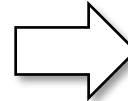
vždy pouze pro jeden kanál vstupu → redukuje pouze v  $x$  a  $y$  prostoru

**příklad:**

vstup: 32x32x3

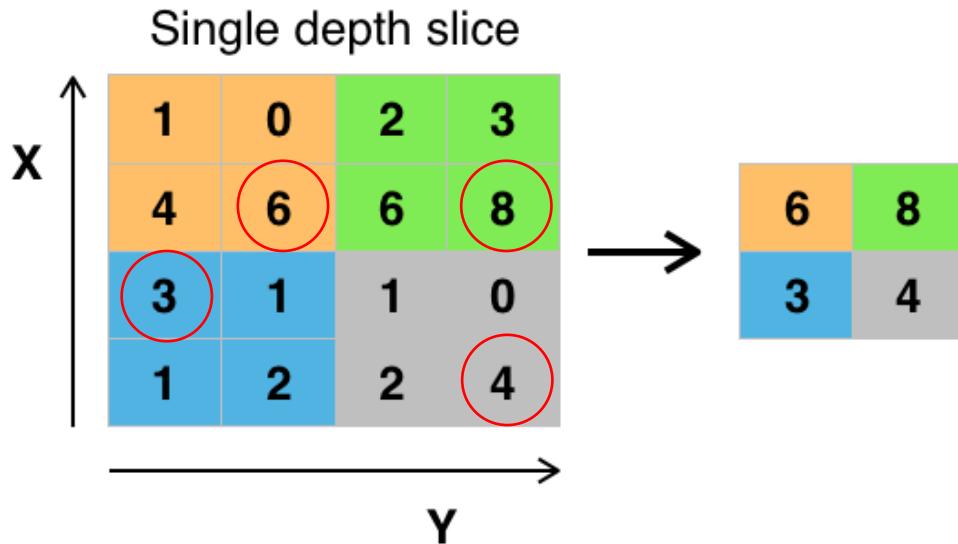
výstup: 16x16x3

# Max pooling: zpětný průchod

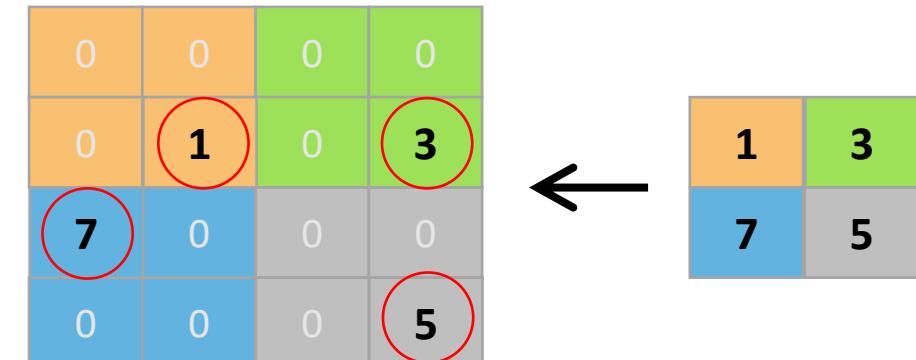
funkce max zapsána jinak:  $z = \begin{cases} x_1 & \text{pokud } x_1 \geq x_i \forall x_i \in x \\ & \vdots \\ x_D & \text{pokud } x_D \geq x_i \forall x_i \in x \end{cases}$   **výběr prvku z pole**

(sub)gradient pak je:  $\bar{x}_d = \begin{cases} 1 & \text{pokud } x_d \geq x_i \forall x_i \in x \\ 0 & \text{jinak} \end{cases}$

## dopředný průchod

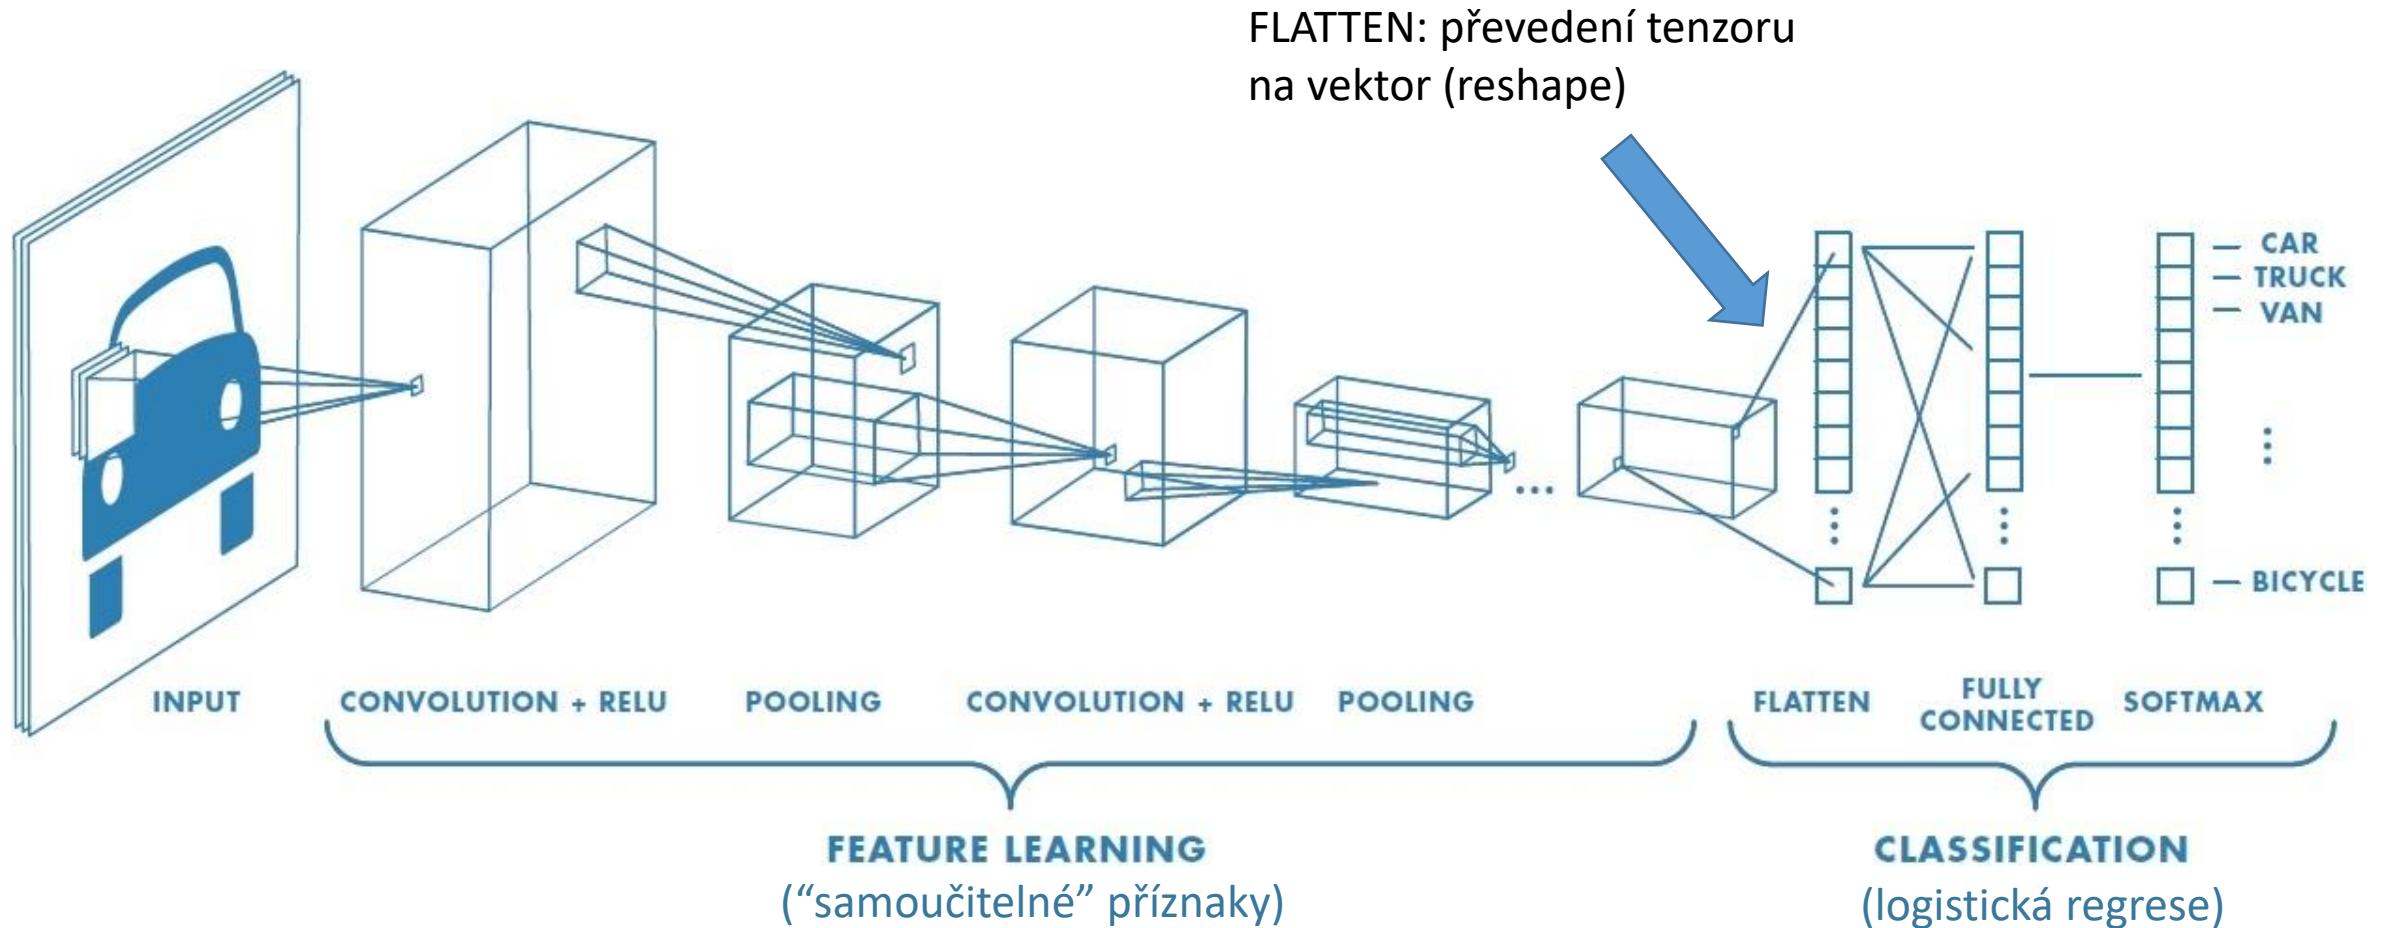


## zpětný průchod



# Konvoluční síť (Convolutional Neural Network, CNN)

- zadefinováním konvoluce jako bloku v neurosíti nyní můžeme libovolně kombinovat s ostatními vrstvami



obrázek: <https://ch.mathworks.com/solutions/deep-learning/convolutional-neural-network.html>

# Rozpoznávání MNIST číslovek: LeNet-5 (1998)

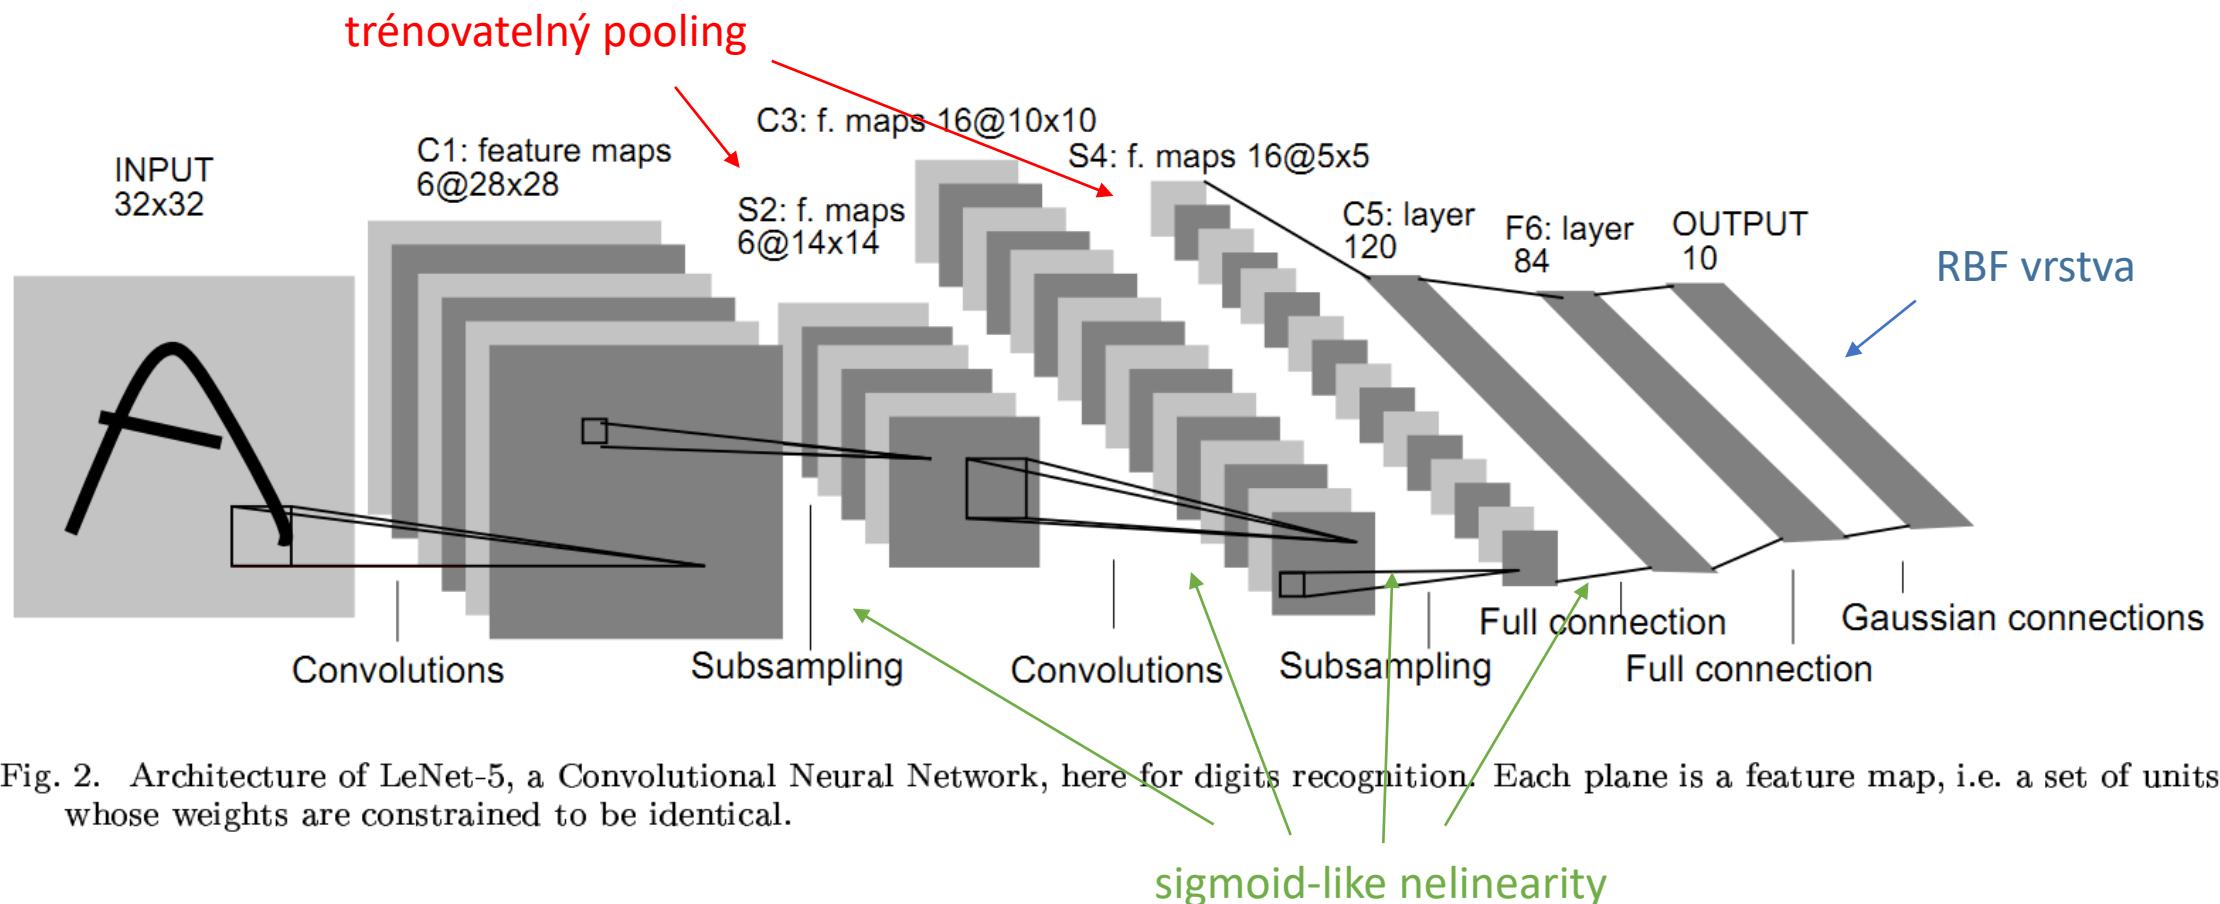


Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

- první známá a úspěšná konvoluční síť
- architektura: CONV-POOL-CONV-POOL-FC-FC-FC

FC ... Fully Connected

# Rozpoznávání MNIST číslovek: LeNet-5 (1998)

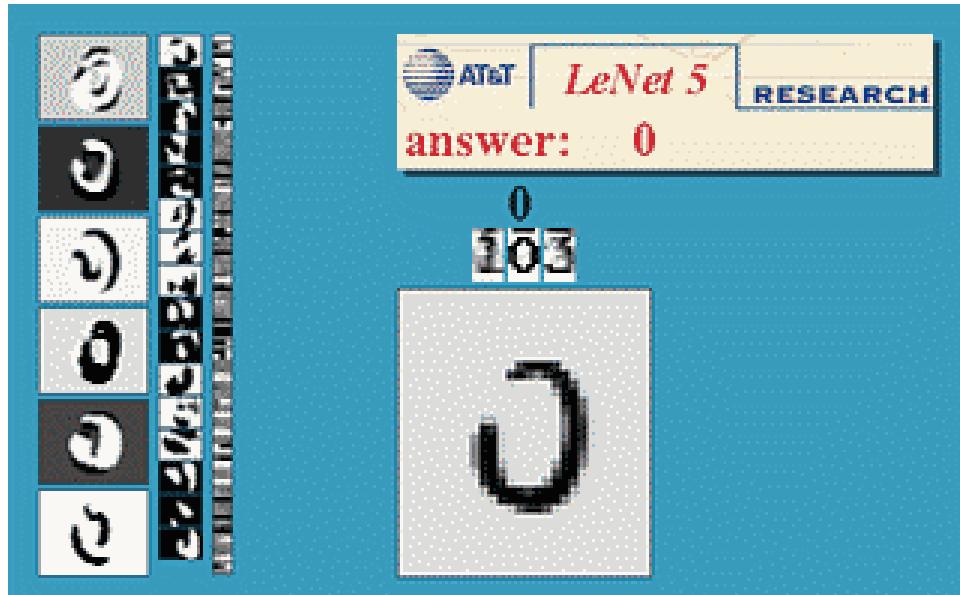


Fig. 4. Size-normalized examples from the MNIST database.  
MNIST ... 60000 obrázků číslovek

# LeNet-5: dobové výsledky (error rate) na MNIST

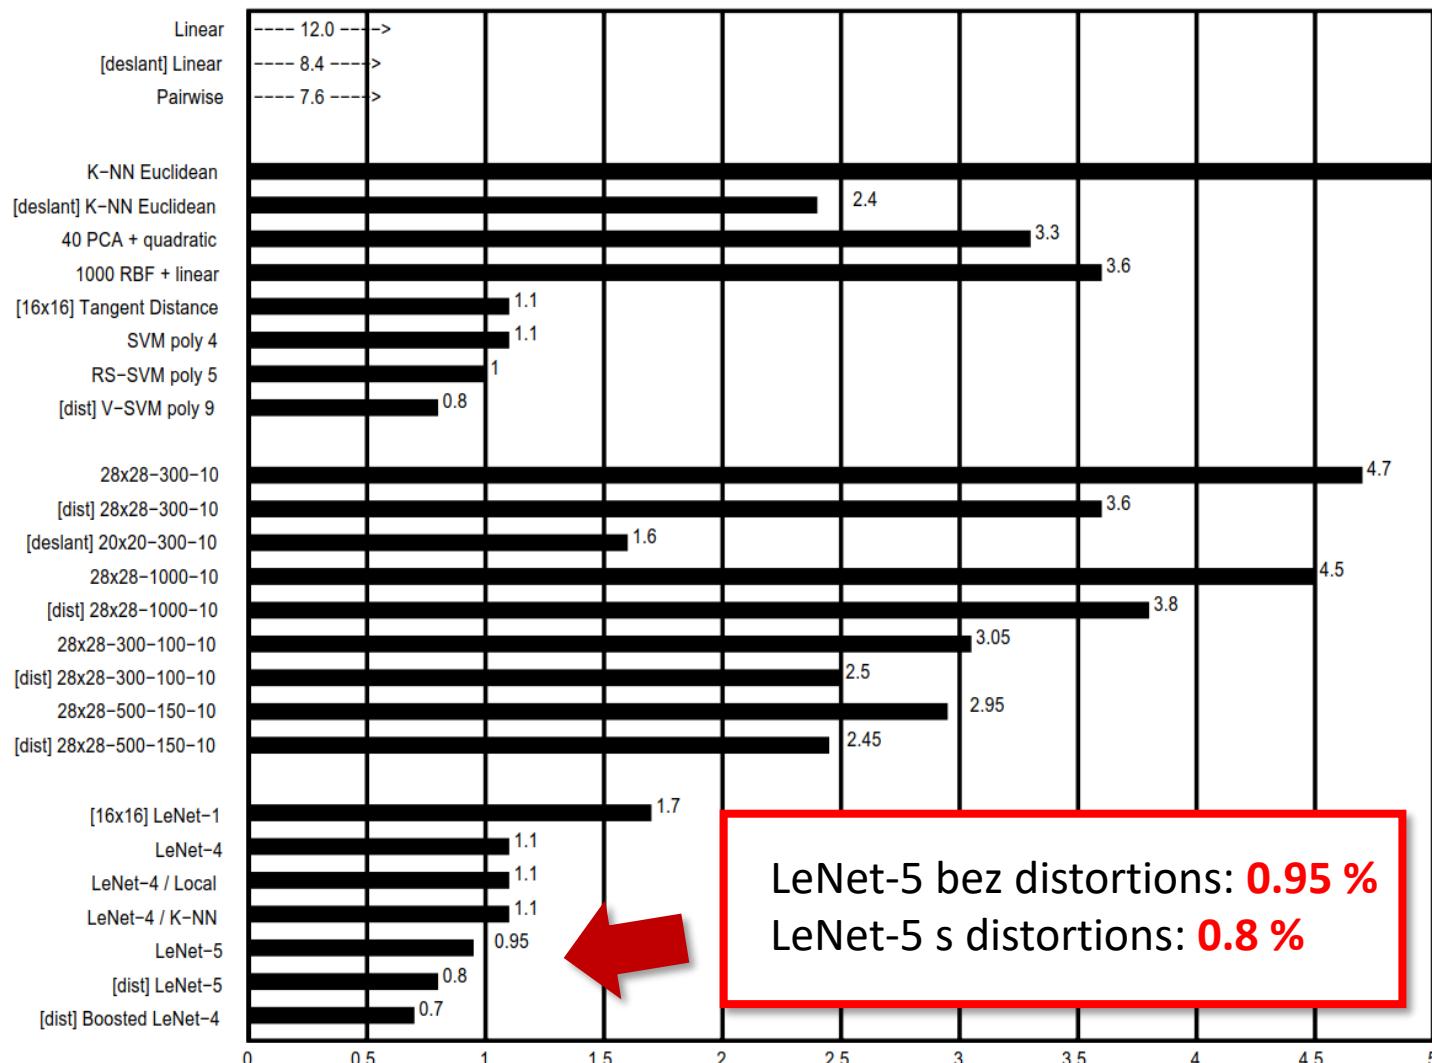
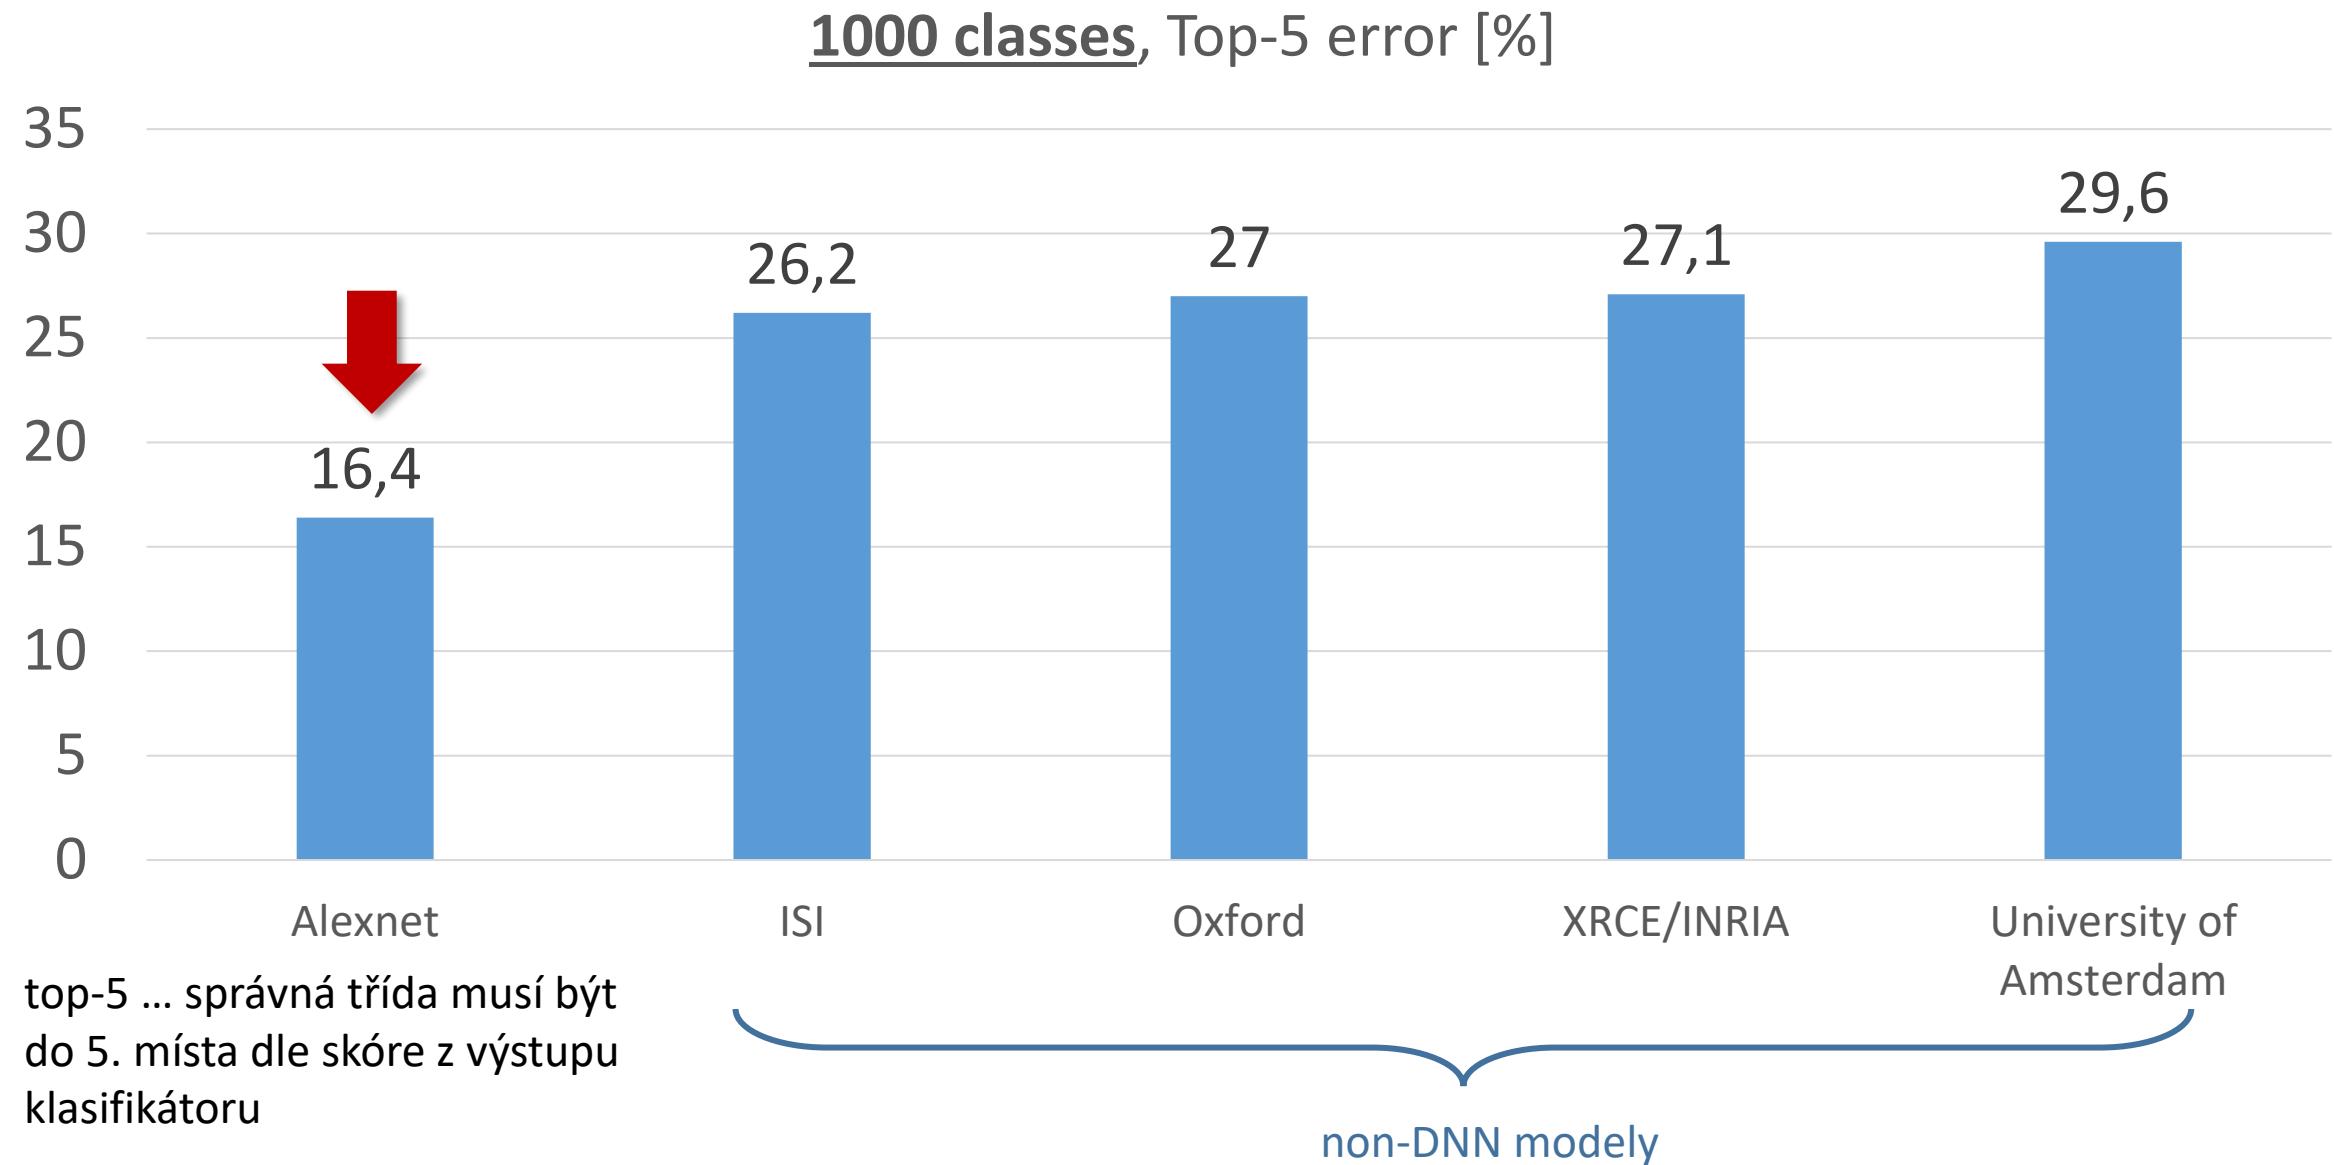
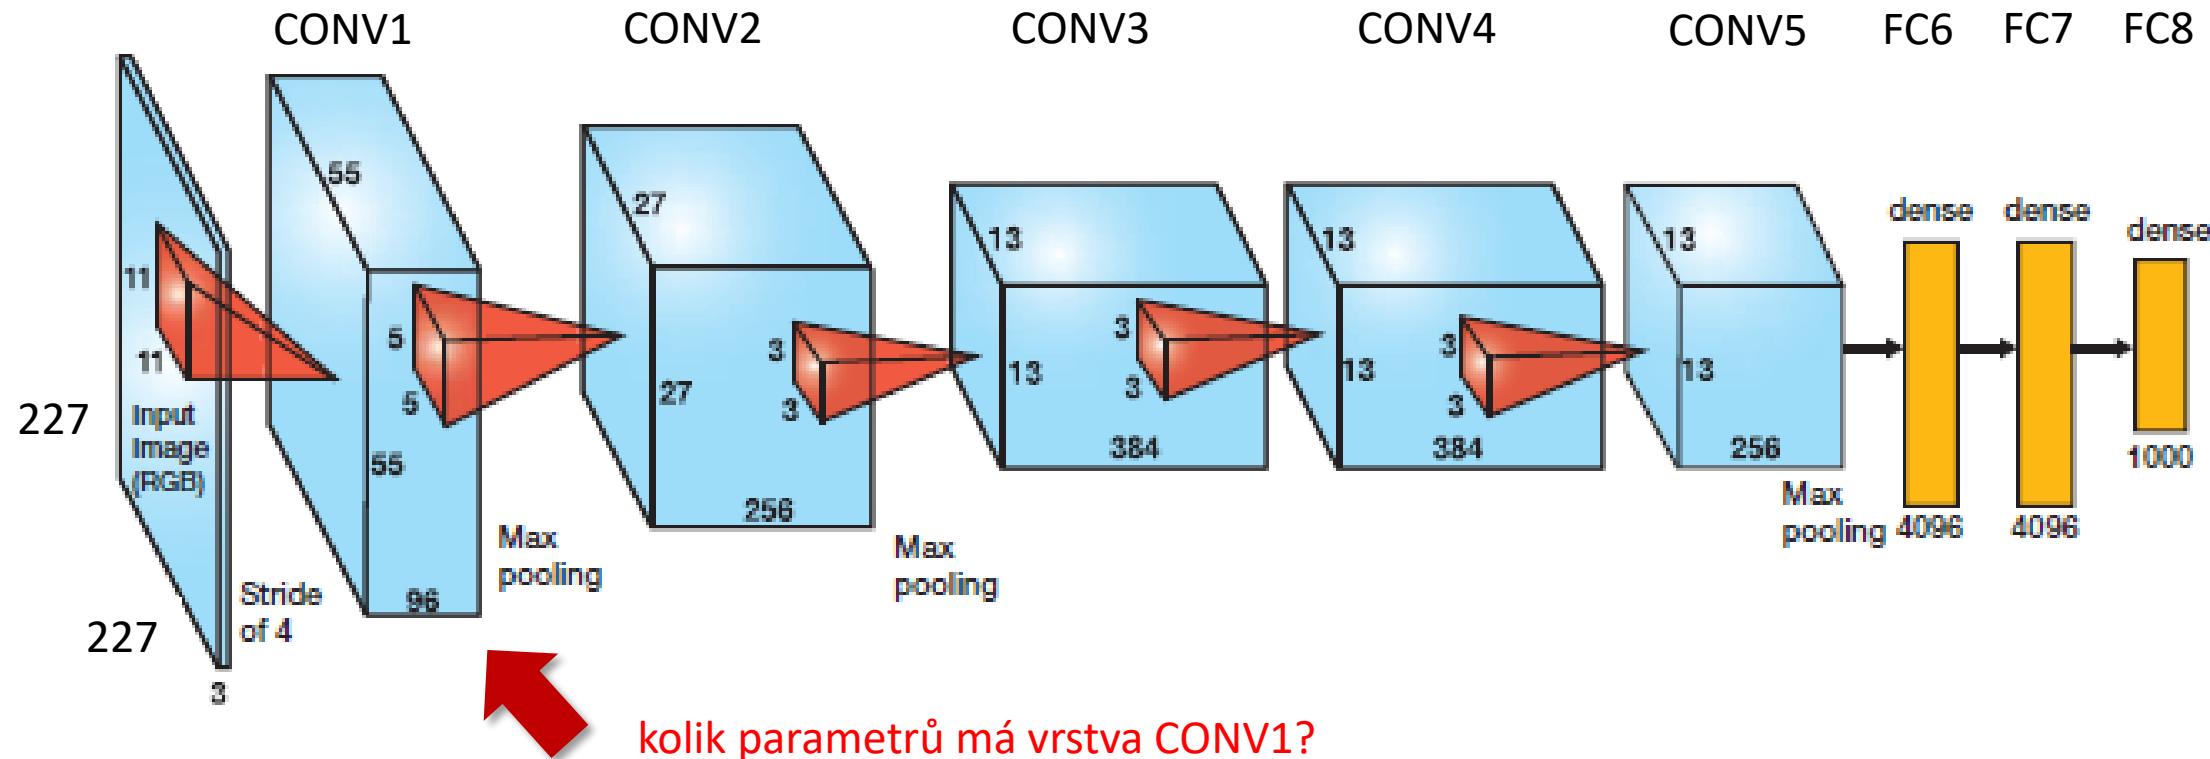


Fig. 9. Error rate on the test set (%) for various classification methods. [deslant] indicates that the classifier was trained and tested on the deslanted version of the database. [dist] indicates that the training set was augmented with artificially distorted examples. [16x16] indicates that the system used the 16x16 pixel images. The uncertainty in the quoted error rates is about 0.1%.

# Rozpoznávání ImageNet: Alexnet (2012)

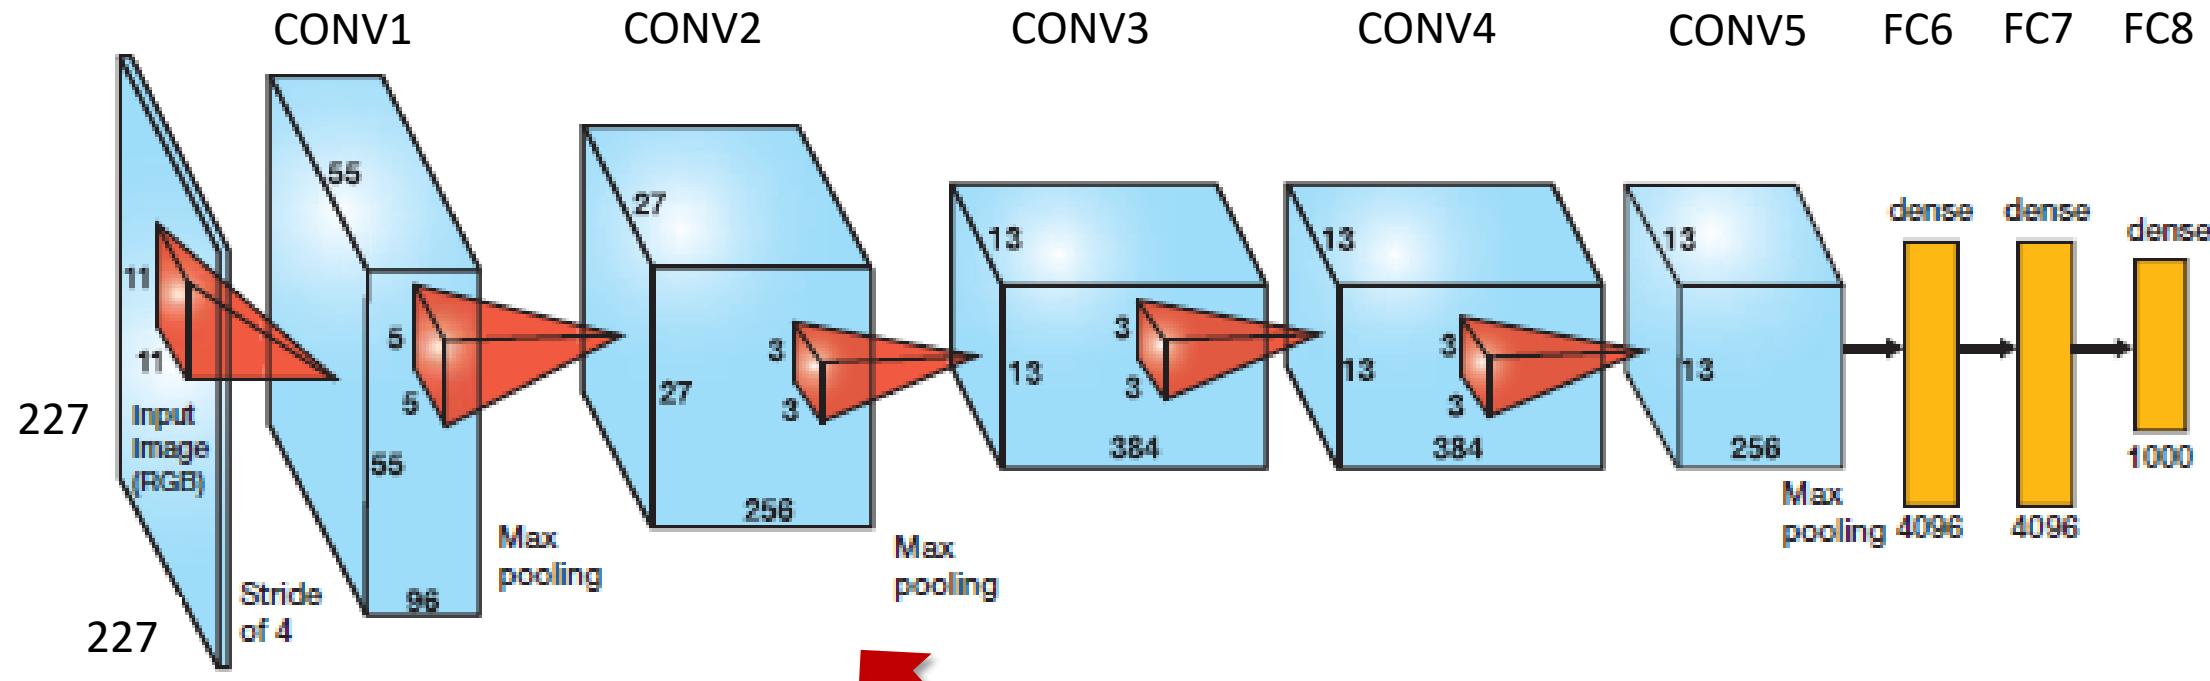


# Alexnet (2012)



- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

# Alexnet (2012)

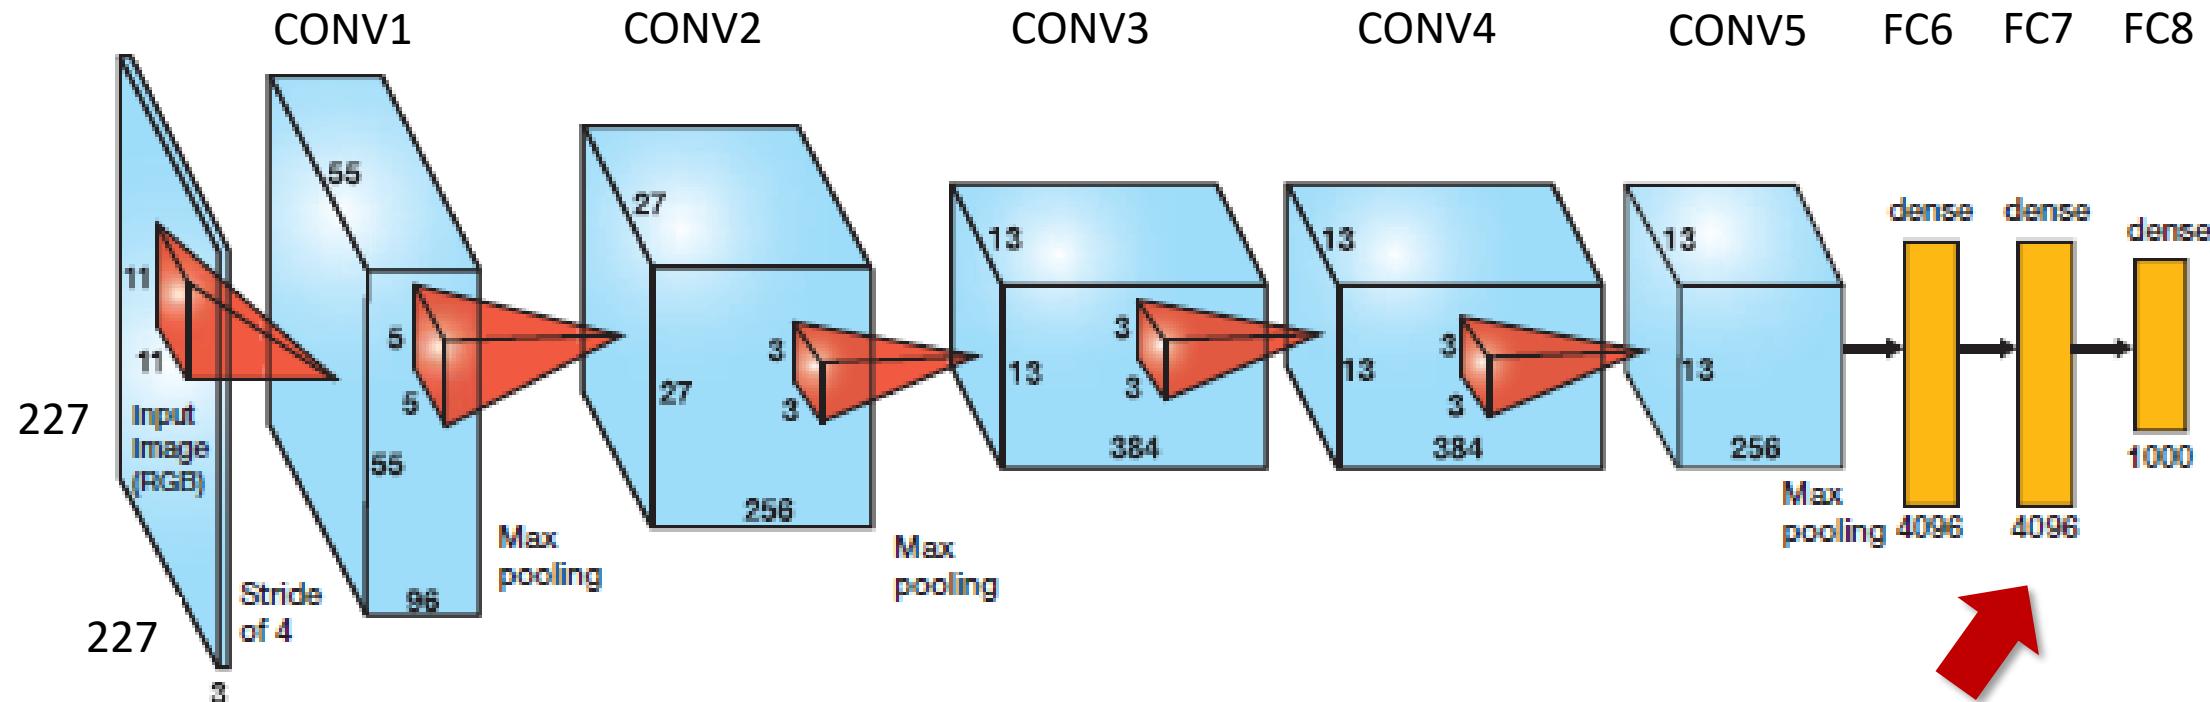


kolik parametrů má vrstva CONV2?

$$5 \cdot 5 \cdot 96 \cdot 256 = 614\,400$$

- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

# Alexnet (2012)



kolik parametrů má vrstva FC7?

$$4096 \cdot 4096 = 16\,777\,216 (!)$$

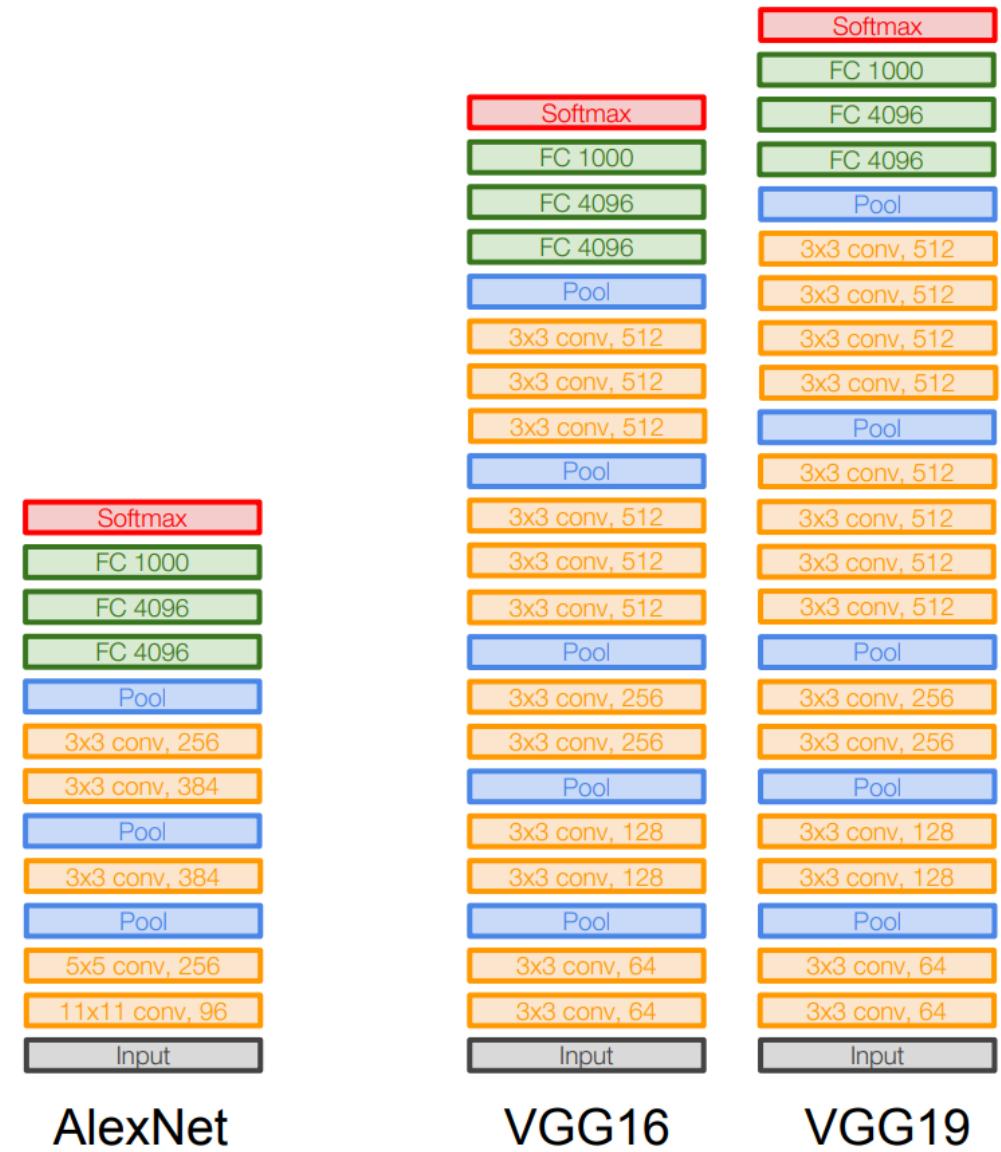
- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

# Alexnet (2012)

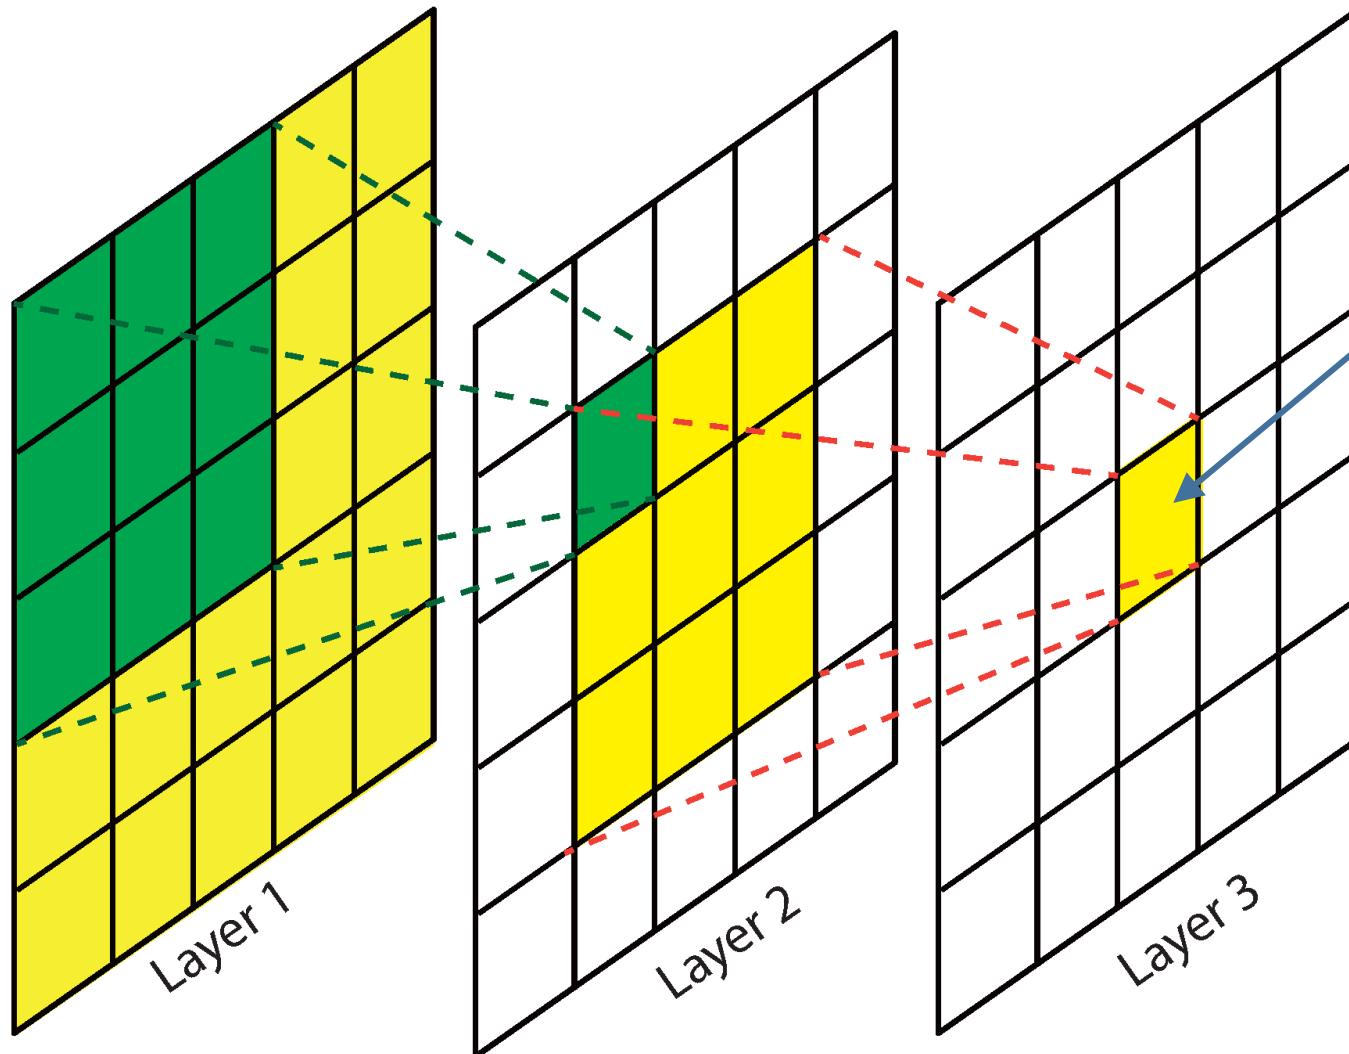
- Krizhevsky, Sutskever, Hinton: “ImageNet Classification with Deep Convolutional Neural Networks”
- Sít, která “nastartovala DNN/CNN revoluci”
- Autoři nevyvinuli žádný nový algoritmus, “pouze” ukázali, jak správně CNN používat
- Místo sigmoid aktivací přechod na ReLU
- Kromě klasické L2 regularizace navíc Dropout
- Výrazné umělé rozšiřování dat (data augmentation)
- Místo SGD → Momentum SGD
- Postupné snižování learning rate
- Trénováno na dvou GTX 580 celkem 5-6 dní

# VGG (2014)

- Simonyan, Zisserman: “Very Deep Convolutional Networks for Large-Scale Image Recognition”
- Druhé místo ImageNet competition 2014
- Mnohem jednodušší architektura než vítěz (GoogLeNet)
- Velmi podobné AlexNet
- Místo 11x11 apod. konvolucí pouze 3x3
- Pouze 2x2 max-pooling
- Žádná lokální normalizace
- 16 a 19 vrstev
- VGG-16: 8.4 % top-5 error



# Receptive field



výsledek konvoluce  $3 \times 3$  nad  
druhou vrstvou závisí na  $5 \times 5$   
oblasti v první vrstvě

pro 3. vrstvu by to bylo  $7 \times 7$ ,  
pro 4. vrstvu  $9 \times 9$ , atd.

jednotlivé neurony každé další  
vrstvy tedy popisují větší a  
větší část obrázku

# VGG (2014)

- VGG tedy nahrazuje jedinou  $7 \times 7$  konvoluci vrstvenými  $3 \times 3$  konvolucemi
- Stejné “zorné pole” (receptive field)
- Méně parametrů:

$$3 \times (3 \times 3 \times C \times C) = 27C^2$$

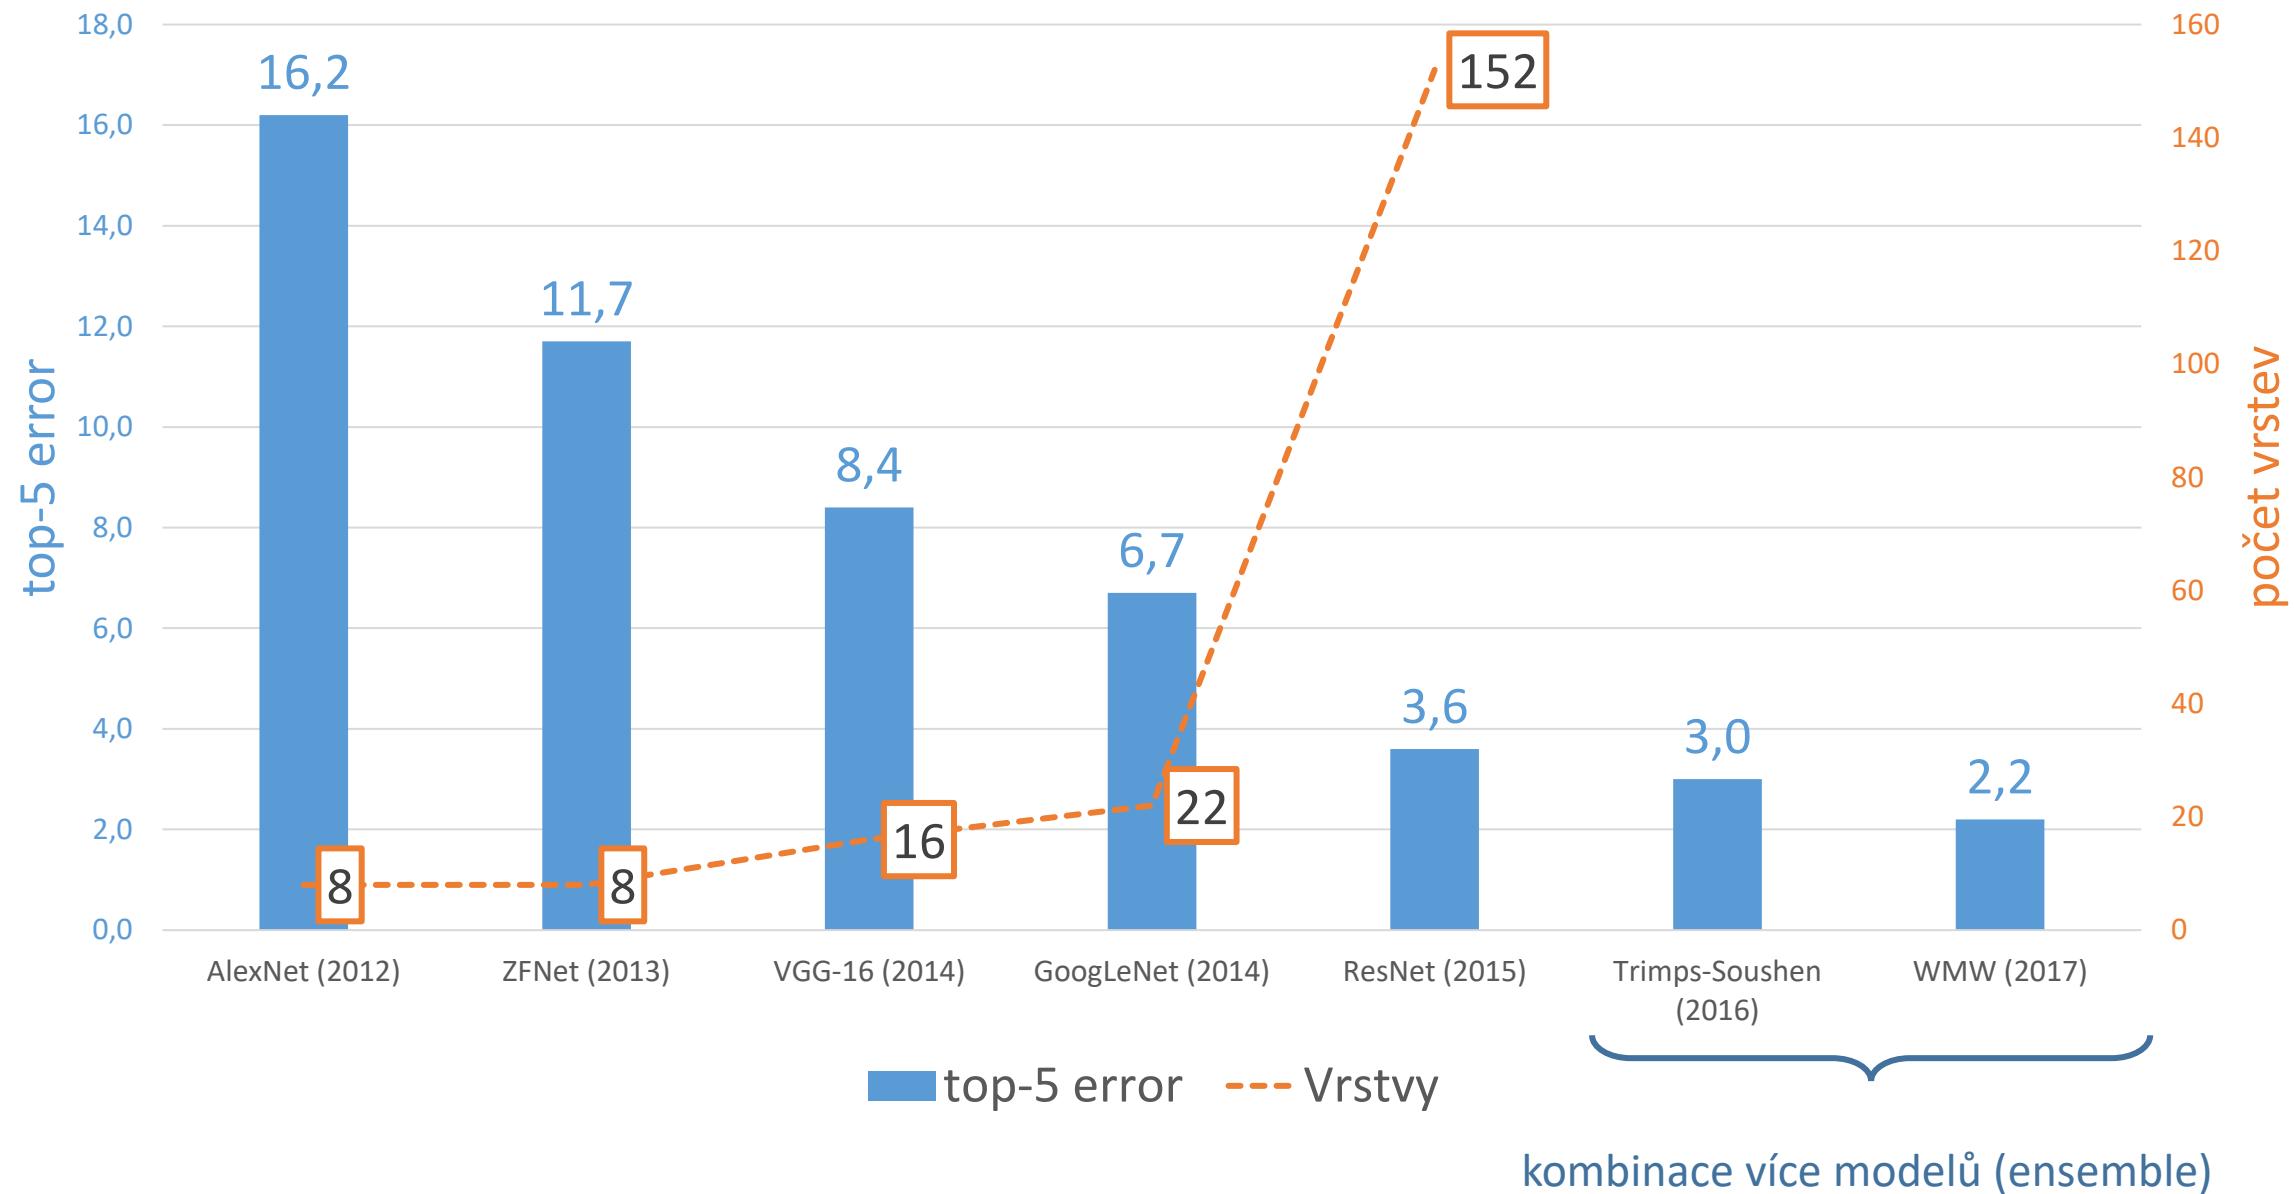
vs

$$1 \times (7 \times 7 \times C \times C) = 49C^2$$

- Zároveň více nelinearit
- Výsledné “FC7” příznaky (4096D) lze použít i pro jiné úlohy (viz transfer learning)
- Poslední klasická CNN



# ImageNet klasifikace



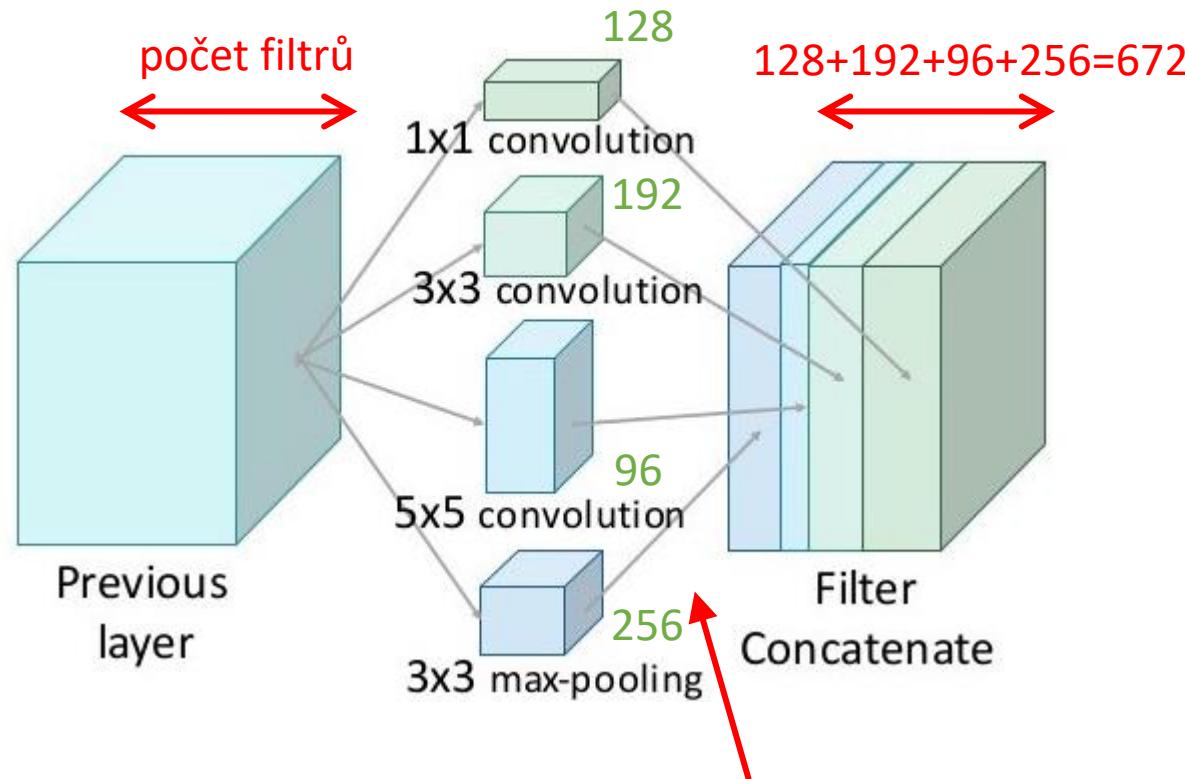
# GoogLeNet (2014)

- Szegedy et al.: Going Deeper with Convolutions
- Navrženo s ohledem na výpočetní náročnost a celkový počet parametrů
- Skládá se z tzv. **Inception** modulů, které kombinují více typů konvolucí v jedné vrstvě (vychází z Lin et al.: “Network in network”)



obrázek: <http://knowyourmeme.com/memes/we-need-to-go-deeper>

# Inception modul v1

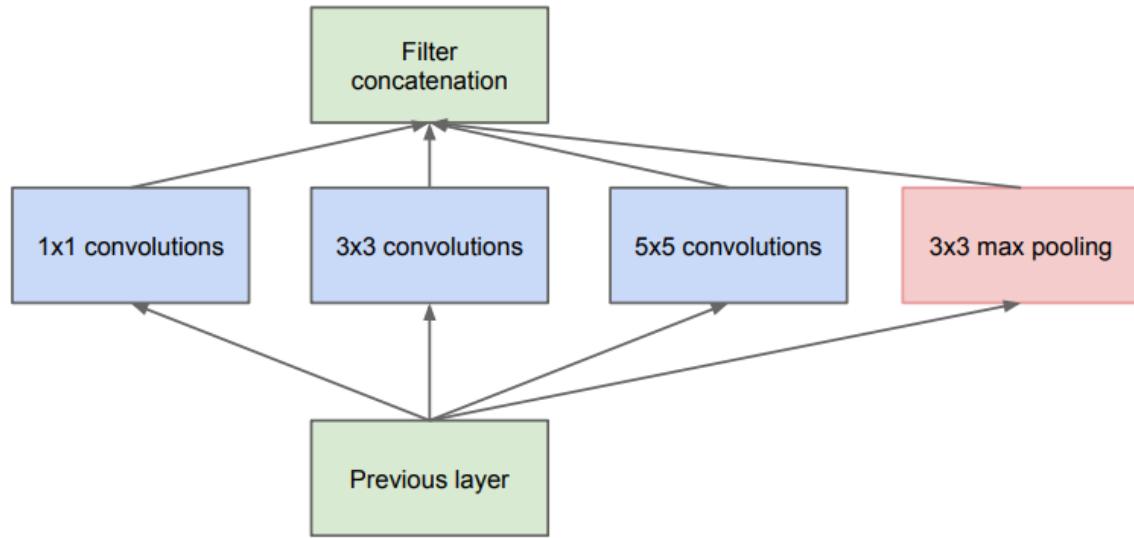


zero padding tak, aby výsledek konvoluce  
měl vždy stejnou velikost (mode='same')

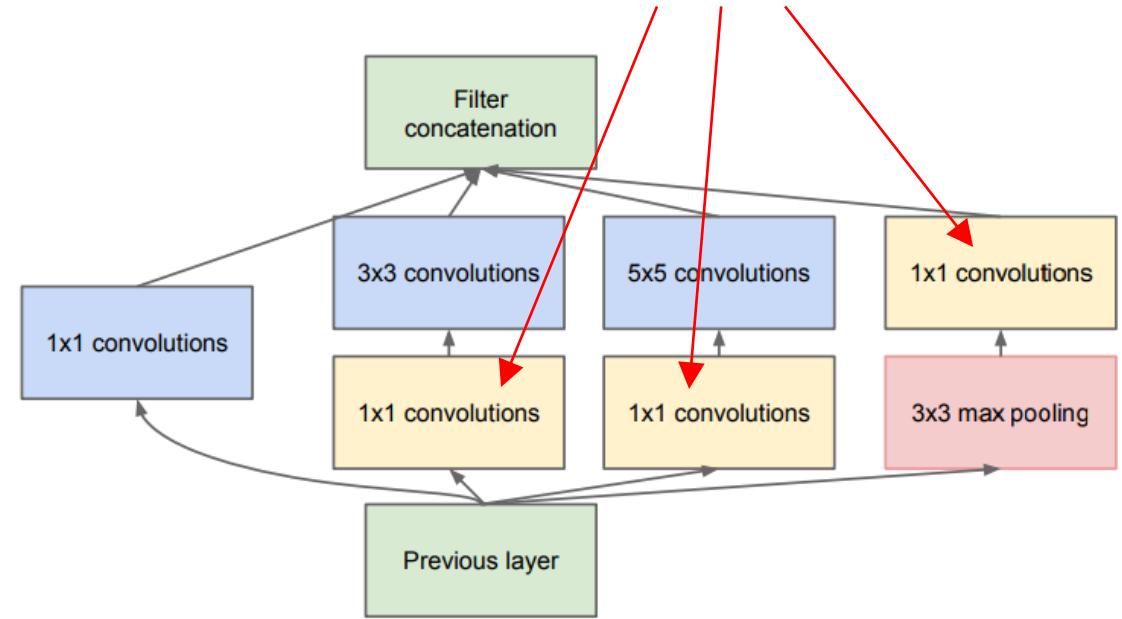
# Optimalizace Inception modulu

[Szegedy et al.: Going Deeper with Convolutions](#)

1x1 “bottleneck” vrstvy s méně filtry: redukují dimenze a urychlují



(a) Inception module, naïve version



(b) Inception module with dimension reductions

Figure 2: Inception module

obrázek: <https://arxiv.org/abs/1409.4842>

ve skutečnosti použita tato varianta

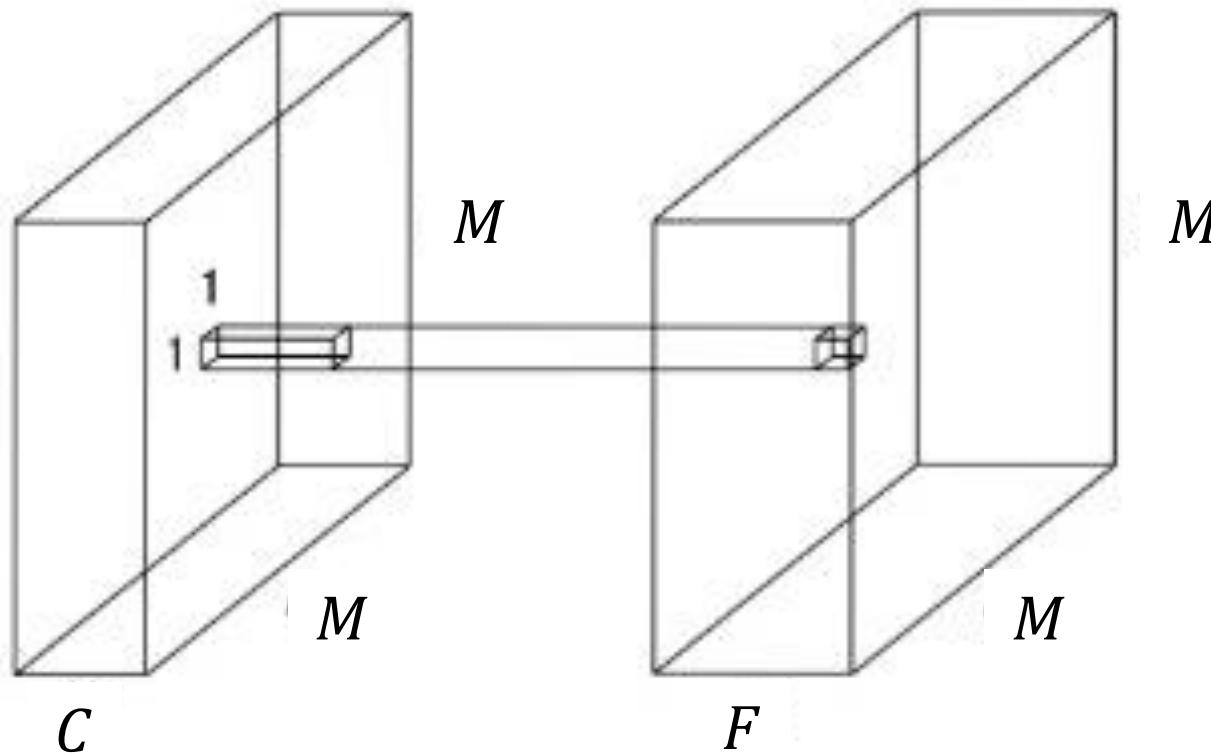


# $1 \times 1$ konvoluce

vzpomeňme: filtr vždy zahrnuje všechny kanály

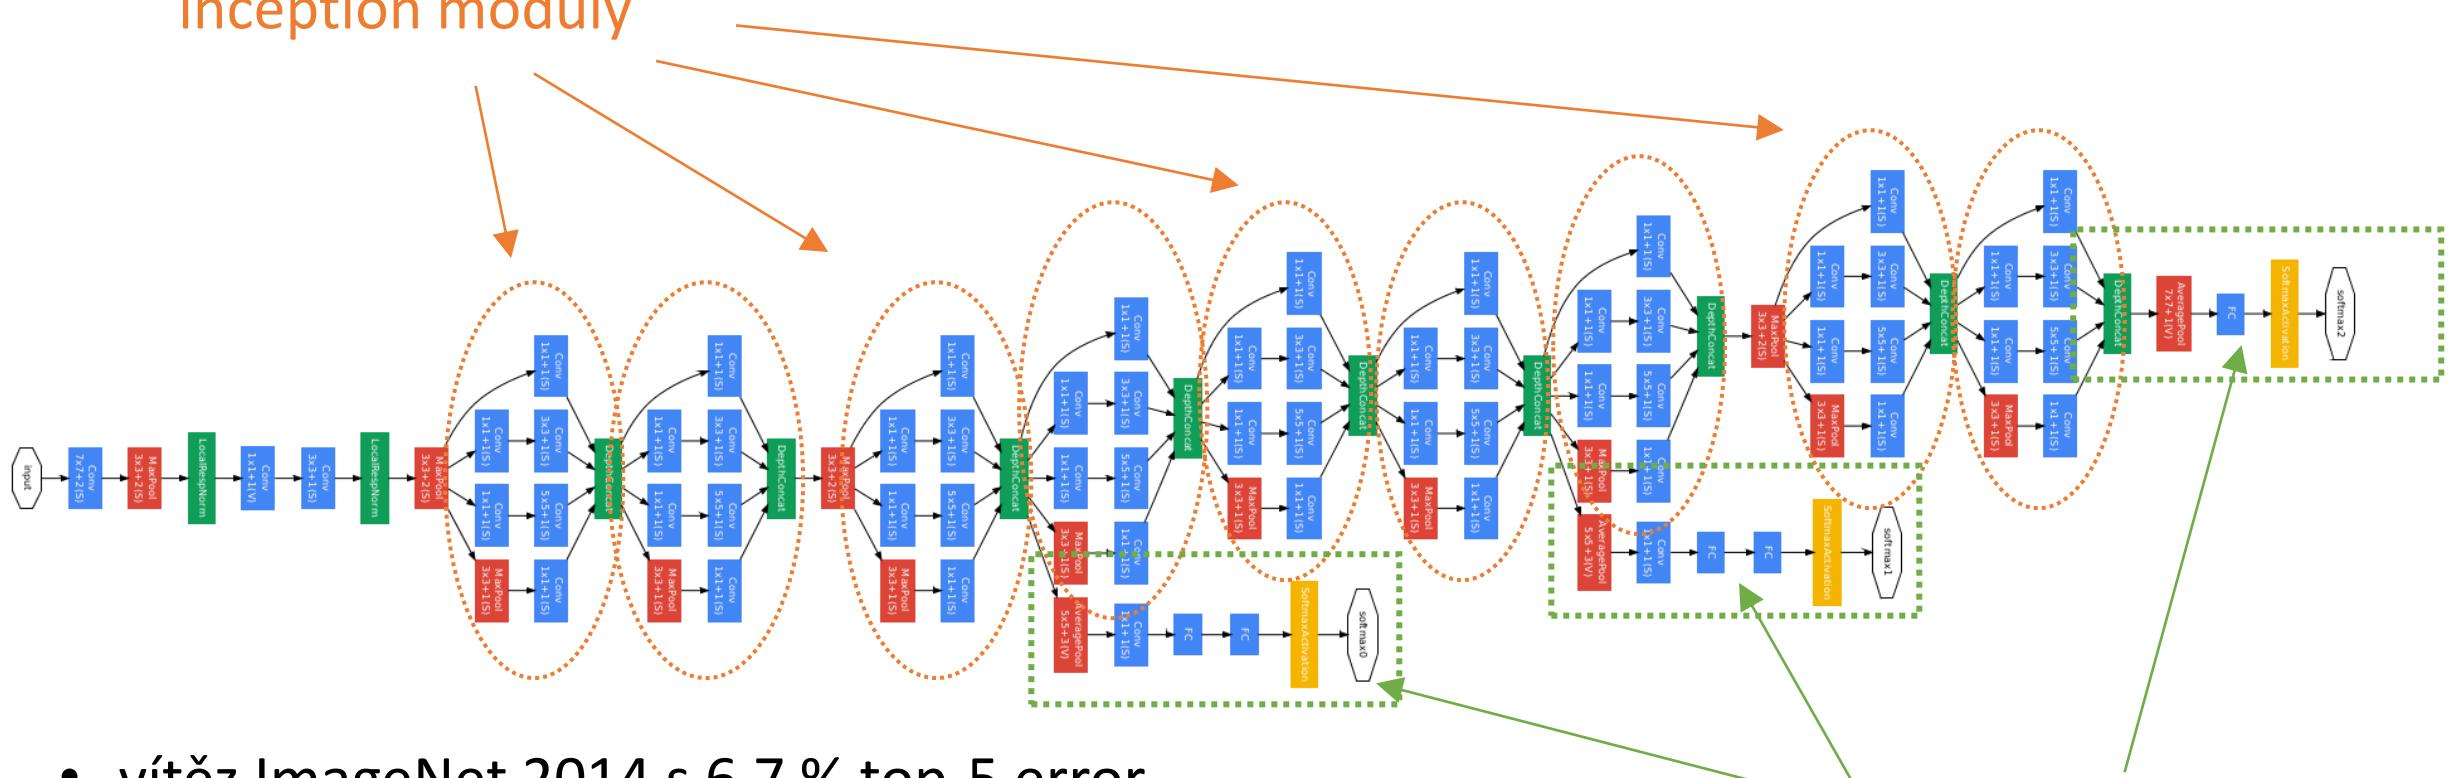
tzn., že i při  $1 \times 1$  konvoluci (bez okolí) je výsledek stále lineární kombinací přes kanály

filtr je tedy  $1 \times 1 \times C \rightarrow$  počet parametrů je  $C \cdot F$



# GoogLeNet (2014)

## inception moduly



- vítěz ImageNet 2014 s 6.7 % top-5 error
- celkem 22 vrstev
- minimum fully-connected (lineárních) vrstev, téměr plně konvoluční síť
- 12x méně parametrů než AlexNet

loss na více místech sítě, ne  
pouze na vrchu

# ResNet (2015)

- He et al.: “Deep Residual Learning for Image Recognition”
- Cílem návrhu být co nejhlubší → 152 vrstev!
- Vítěz ImageNet 2015 ve všech kategoriích
- Vítěz MS COCO challenge
- 3.6 % top-5 error na ImageNet: lepší než člověk (cca 5 %)
- Problém: přidávání vrstev pomáhá jen do určité chvíle, pak už ne
- Overfitting?

# Příliš mnoho vrstev

Overfitting? Ne: kromě testovací chyby s více vrstvami roste i trénovací chyba!

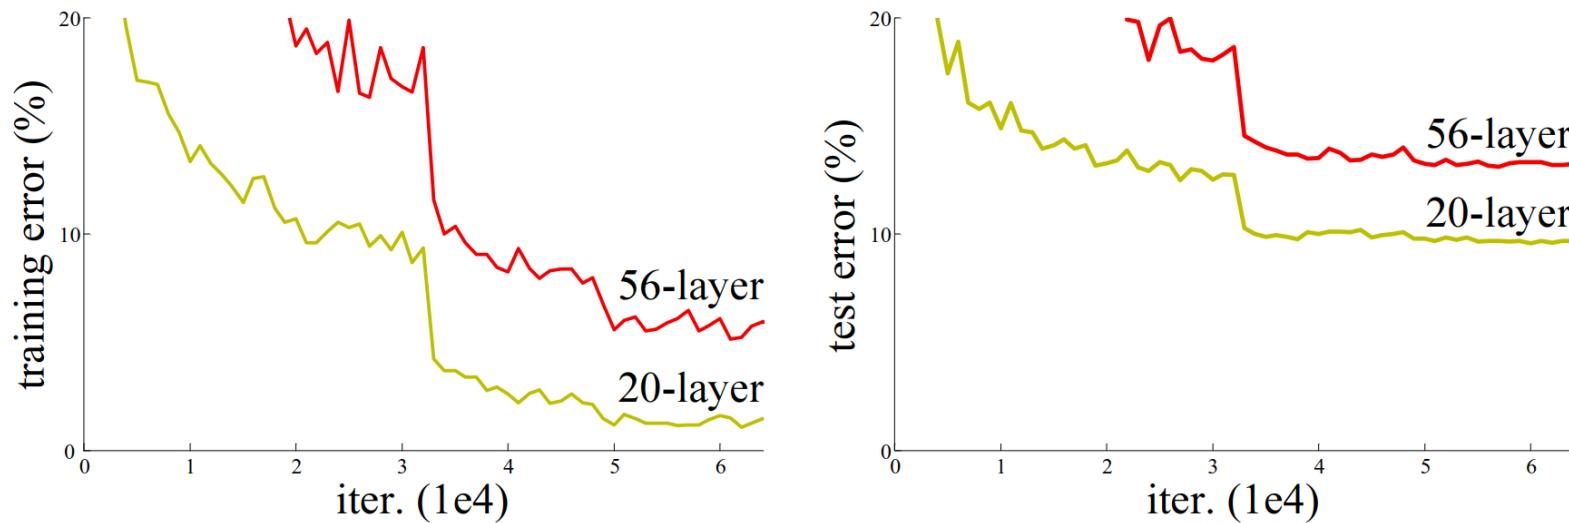


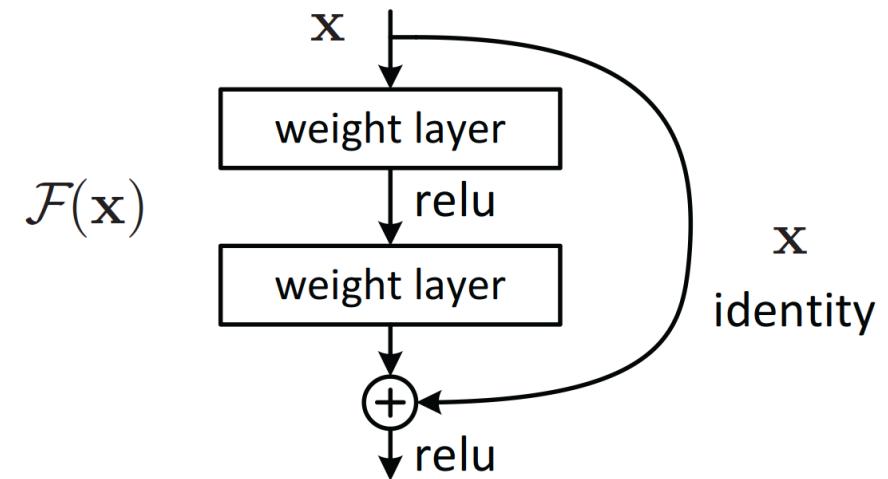
Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

# Reziduální blok

- Podobně jako inception používá složitější bloky
- Výstup sestává ze součtu konvoluce a přímo mapovaného vstupu (identity)
- Sítí se tedy učí pouze rezidua

$$\mathcal{F}(x) = \mathcal{H}(x) - x$$

- “Naučit se nuly je jednodušší než identitu”



$$\mathcal{H}(x) = \mathcal{F}(x) + x$$

Figure 2. Residual learning: a building block.

# Bottleneck residual blok

Podobně jako u Inception i ResNet  
optimalizuje pomocí  $1 \times 1$  bottleneck  
vrstev uvnitř reziduálních bloků

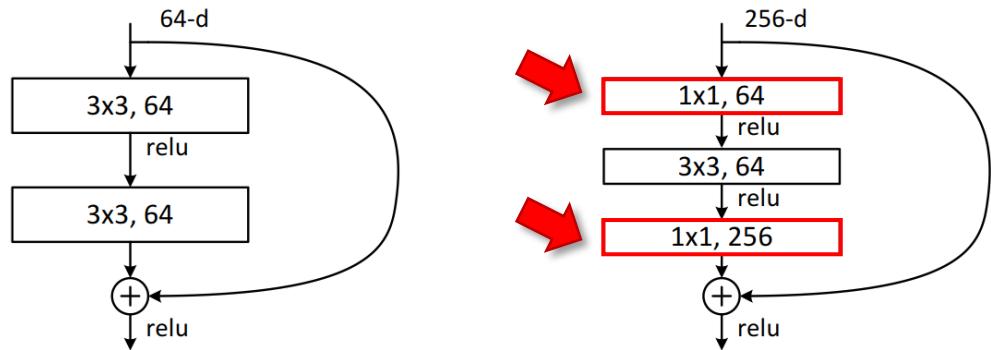
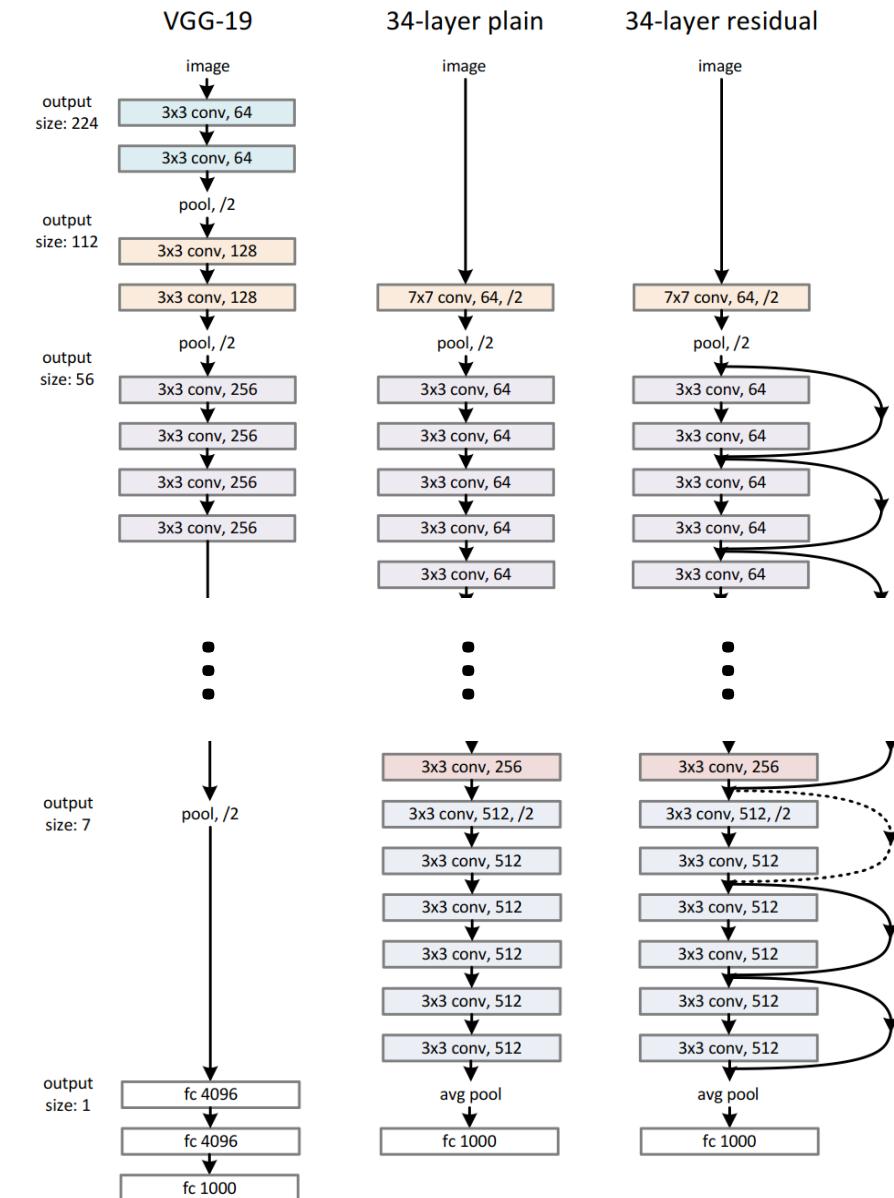


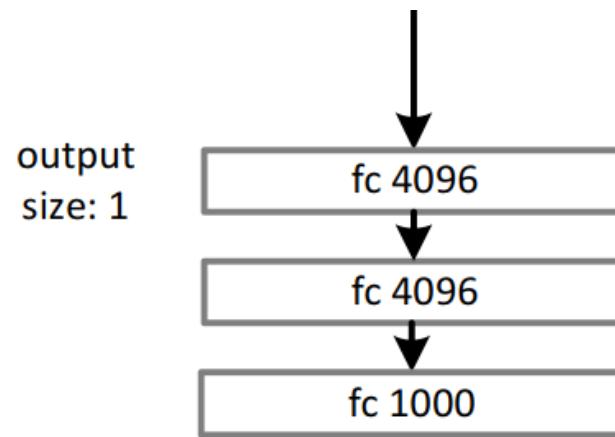
Figure 5. A deeper residual function  $\mathcal{F}$  for ImageNet. Left: a building block (on  $56 \times 56$  feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.



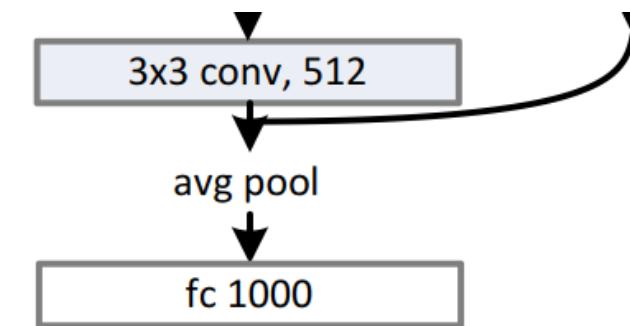
# Téměr plně konvoluční

bez skrytých lineárních vrstev

## VGG:



## ResNet:



pouze lineární klasifikátor

# Average pooling

|   |   |   |   |
|---|---|---|---|
| 1 | 0 | 2 | 3 |
| 4 | 6 | 6 | 8 |
| 3 | 1 | 1 | 0 |
| 1 | 2 | 2 | 4 |

max pooling

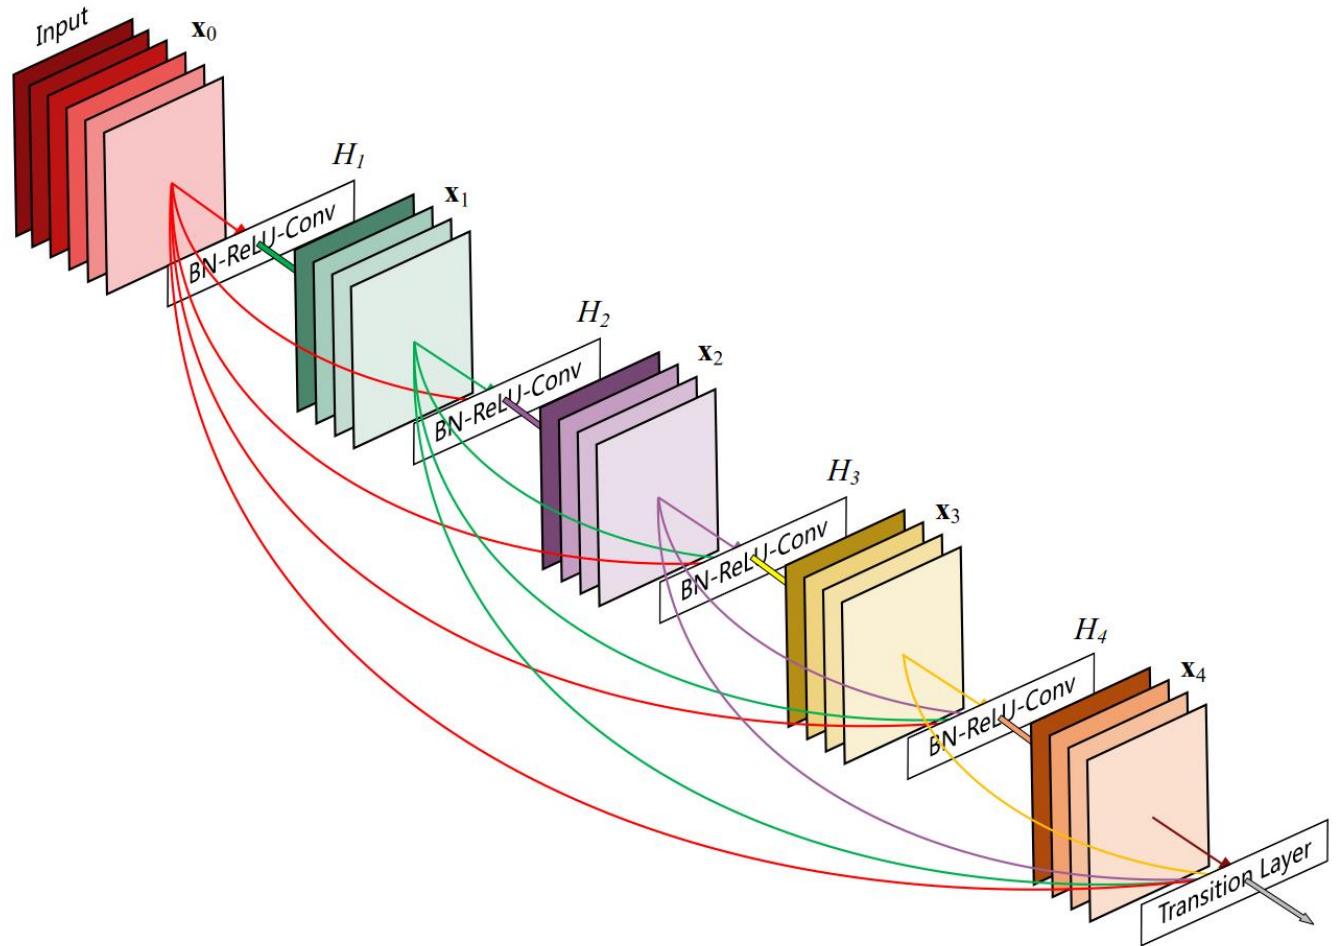
|   |   |
|---|---|
| 6 | 8 |
| 3 | 4 |

average pooling

|   |   |
|---|---|
| 3 | 5 |
| 2 | 2 |

# DenseNet (2016)

- Huang et al.: “Densely Connected Convolutional Networks”
- Výstup vrstvy je připojen na vstup každé další vrstvy
- “ResNet do extrému”



# SqueezeNet (2016)

- Iandola et al: “SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size”
- Cílem co nejmenší a nejfektivnější síť

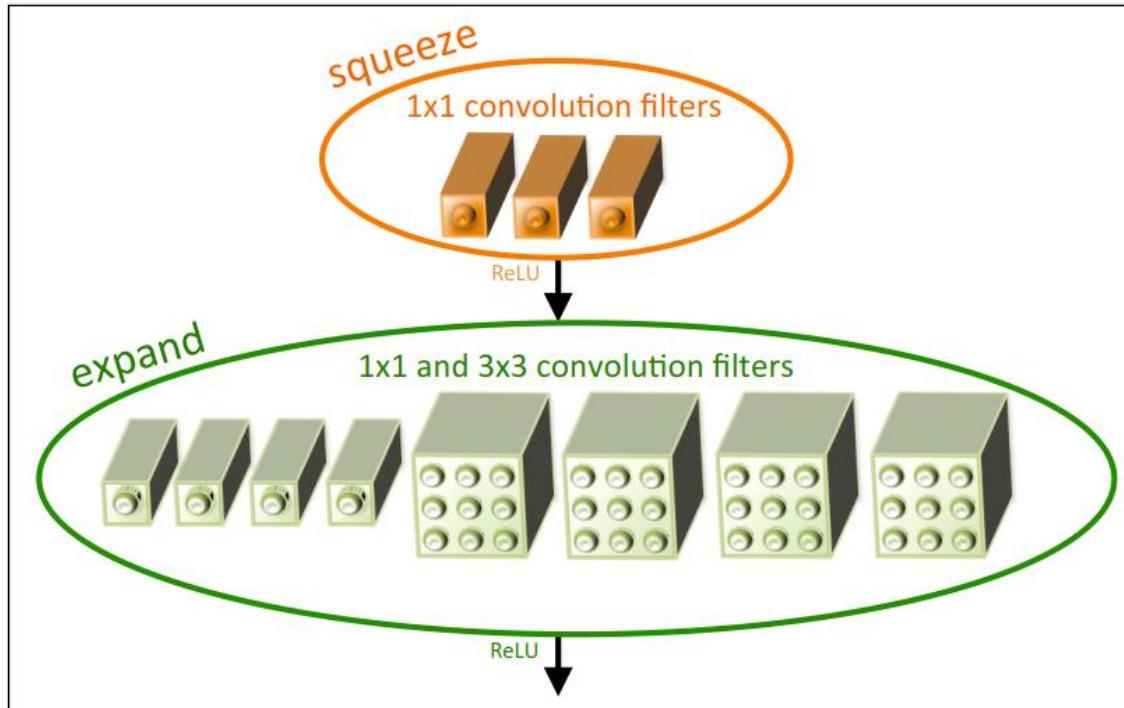
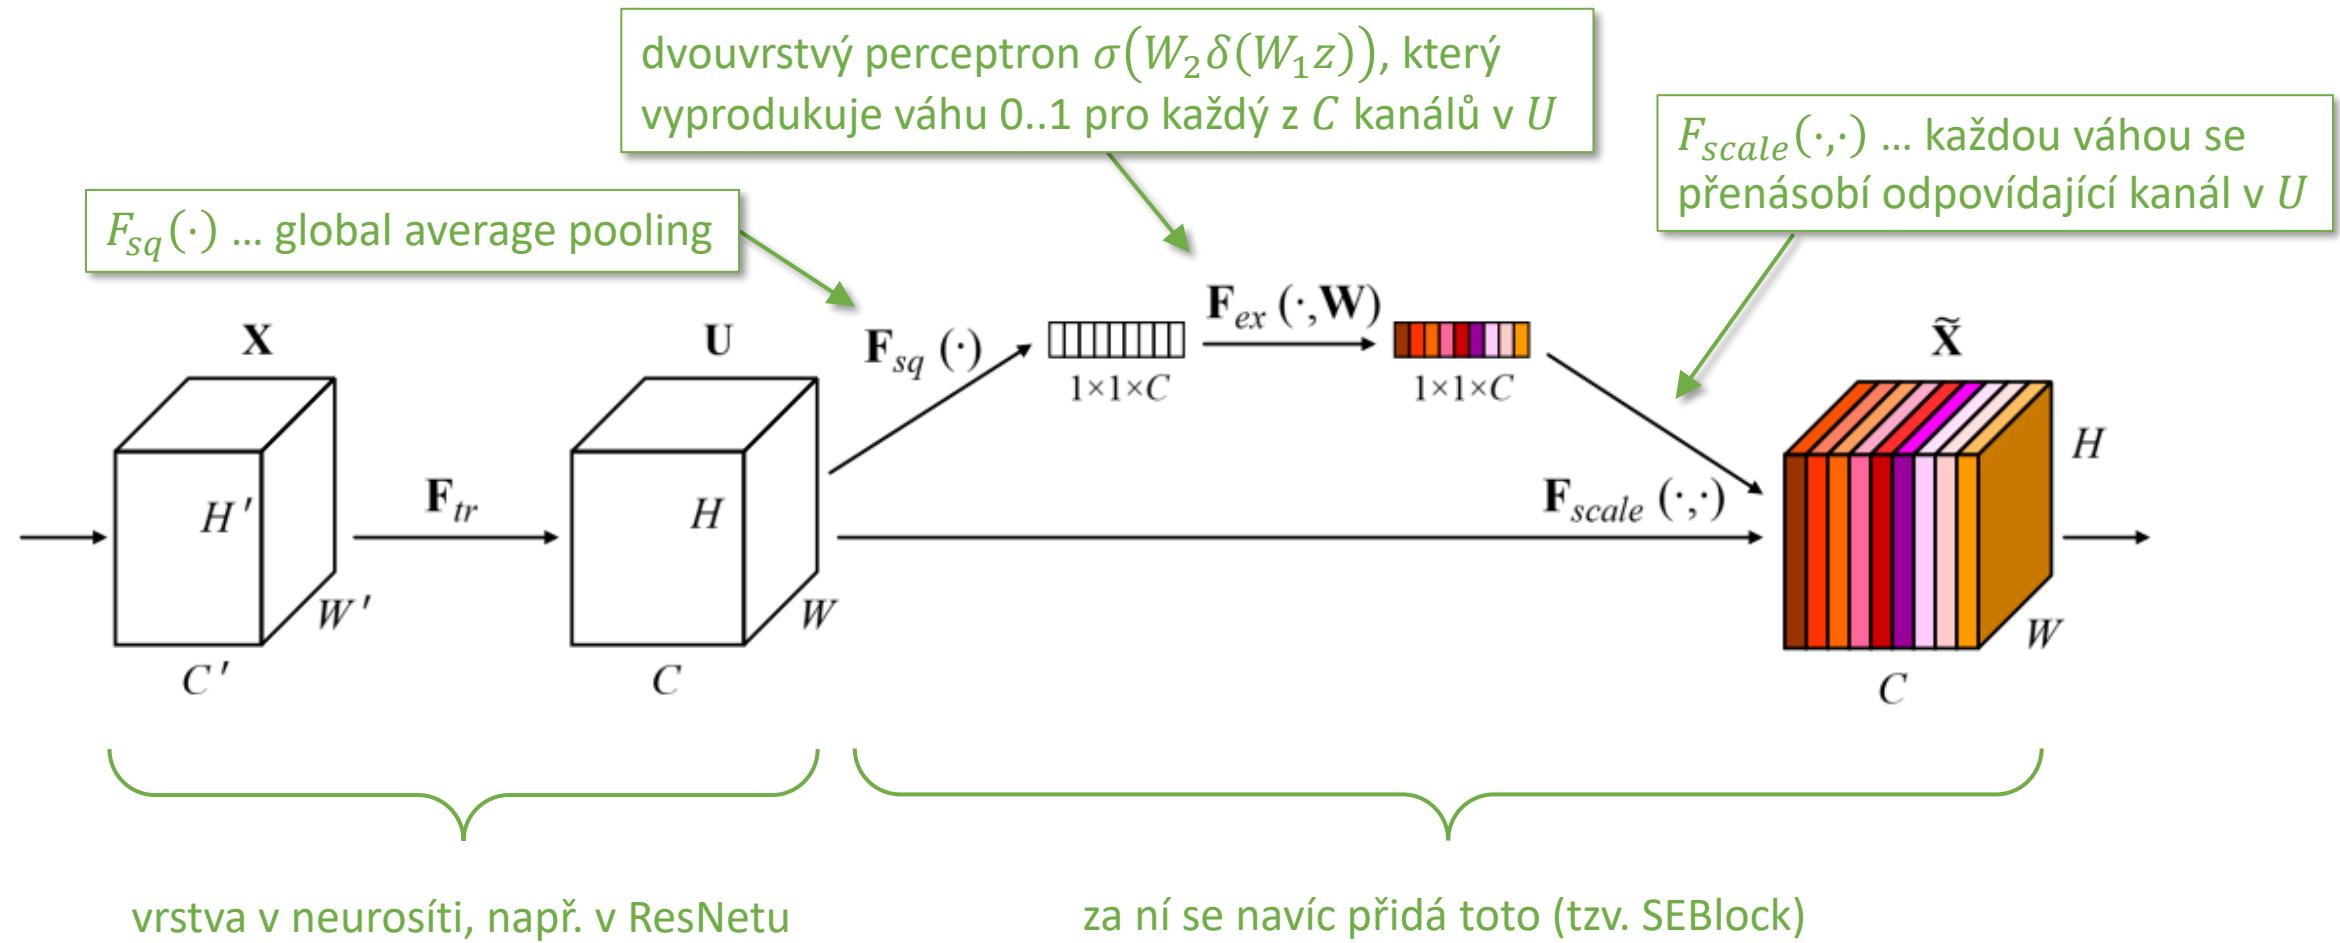


Figure 1: Microarchitectural view: Organization of convolution filters in the **Fire module**. In this example,  $s_{1x1} = 3$ ,  $e_{1x1} = 4$ , and  $e_{3x3} = 4$ . We illustrate the convolution filters but not the activations.

# SENet (2017)

- [Hu et al.: Squeeze-and-excitation Networks](#)
- Cílem nějak explicitně modelovat závislost kanálů



# SENet (2017)

```
class SE_Block(nn.Module):
    "credits: https://github.com/moskomule/senet.pytorch"
    def __init__(self, c, r=16):
        super().__init__()
        self.squeeze = nn.AdaptiveAvgPool2d(1)
        self.excitation = nn.Sequential(
            nn.Linear(c, c // r, bias=False),
            nn.ReLU(inplace=True),
            nn.Linear(c // r, c, bias=False),
            nn.Sigmoid()
        )

    def forward(self, x):
        bs, c, _, _ = x.shape
        y = self.squeeze(x).view(bs, c)
        y = self.excitation(y).view(bs, c, 1, 1)
        return x * y.expand_as(x)
```

plugin do existujících sítí

TABLE 4  
Classification error (%) on CIFAR-10.

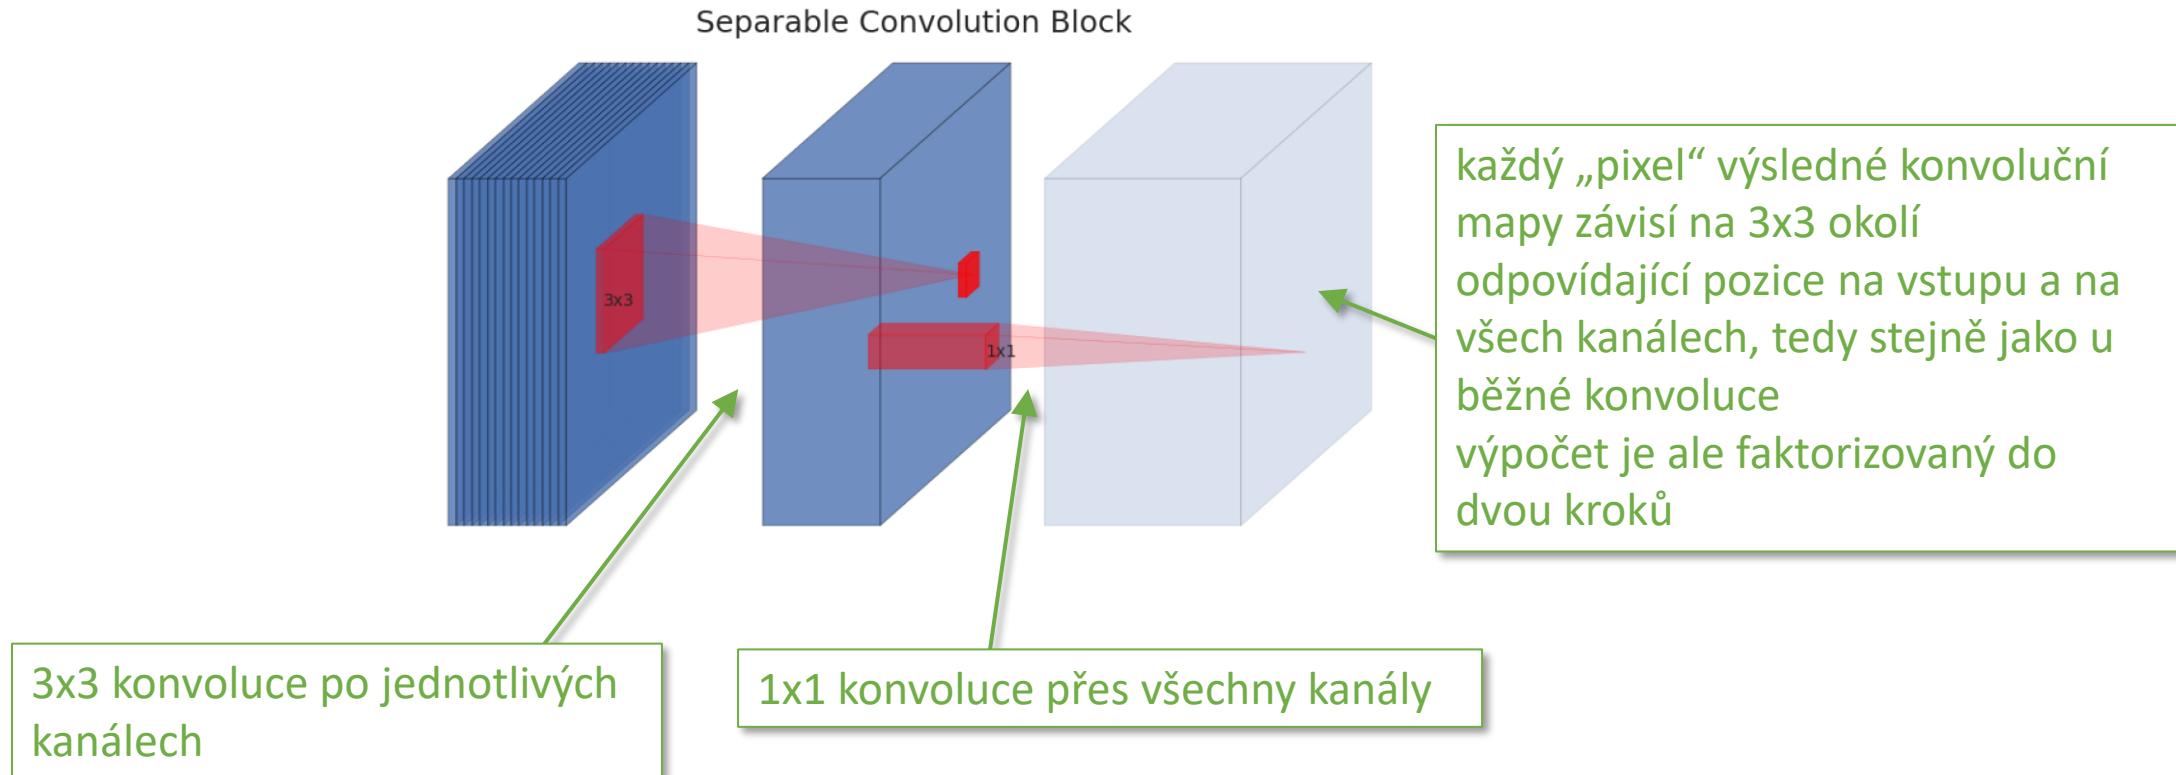
|   | original | SENet |
|---|----------|-------|
| ResNet-110 [14]                         | 6.37     | 5.21  |
| ResNet-164 [14]                         | 5.46     | 4.39  |
| WRN-16-8 [67]                           | 4.27     | 3.88  |
| Shake-Shake 26 2x96d [68] + Cutout [69] | 2.56     | 2.12  |

TABLE 5  
Classification error (%) on CIFAR-100.

|  | original | SENet |
|--|----------|-------|
| ResNet-110 [14]                          | 26.88    | 23.85 |
| ResNet-164 [14]                          | 24.33    | 21.31 |
| WRN-16-8 [67]                            | 20.43    | 19.14 |
| Shake-Even 29 2x4x64d [68] + Cutout [69] | 15.85    | 15.41 |

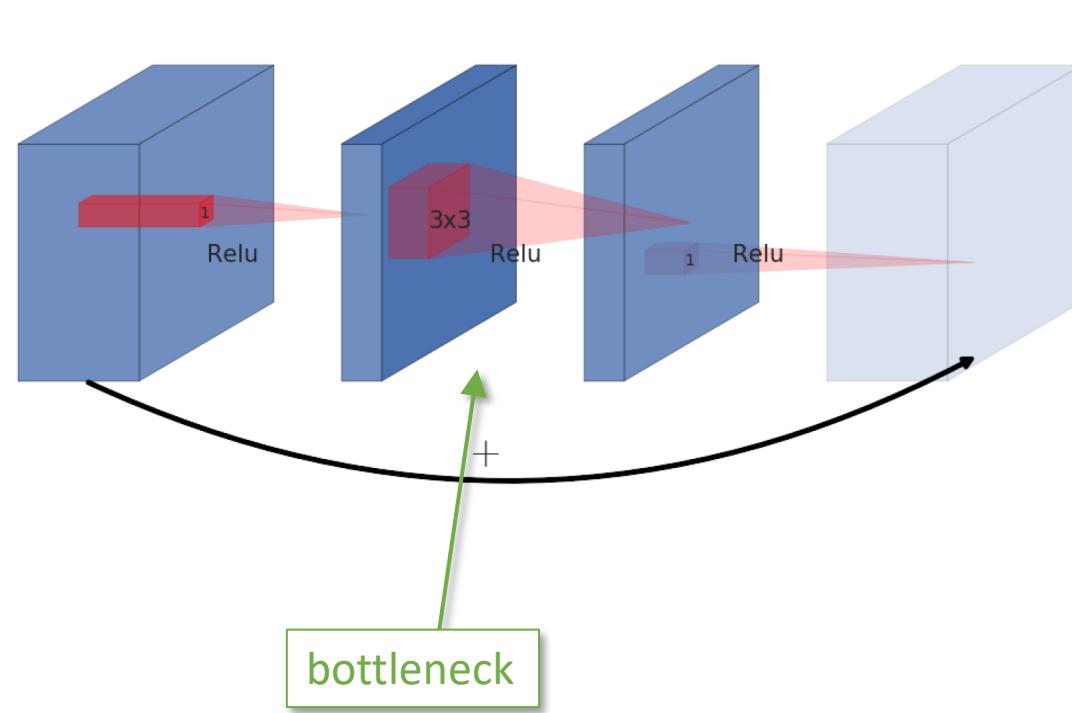
# MobileNetV2 (2018)

- Sandler et al.: MobileNetV2: Inverted Residuals and Linear Bottlenecks
- Depthwise separable konvoluce



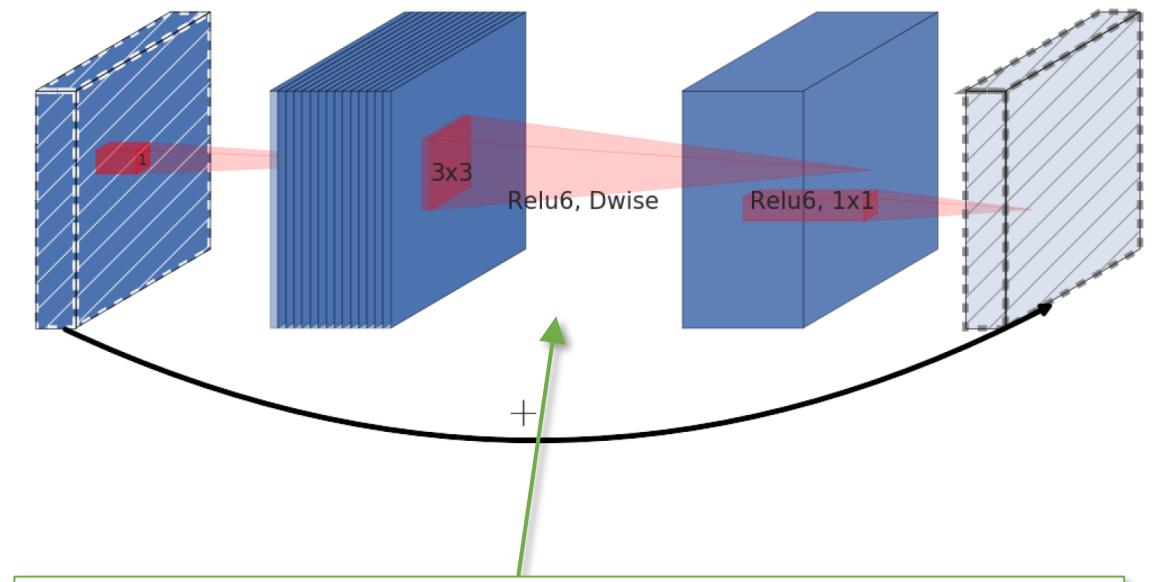
# MobileNetV2 (2018)

standardní ResNet



upravený ResNet s depthwise separable konvolucemi

(b) Inverted residual block



- 1. konvolve je nahrazena depthwise separable verzí
- 2. místo bottlenecku expansion (= více kanálů)
- 3. čárkované konv. mapy neprocházejí nelinearitou

# MobileNetV2 (2018)

| Input                    | Operator    | $t$ | $c$  | $n$ | $s$ |
|--------------------------|-------------|-----|------|-----|-----|
| $224^2 \times 3$         | conv2d      | -   | 32   | 1   | 2   |
| $112^2 \times 32$        | bottleneck  | 1   | 16   | 1   | 1   |
| $112^2 \times 16$        | bottleneck  | 6   | 24   | 2   | 2   |
| $56^2 \times 24$         | bottleneck  | 6   | 32   | 3   | 2   |
| $28^2 \times 32$         | bottleneck  | 6   | 64   | 4   | 2   |
| $14^2 \times 64$         | bottleneck  | 6   | 96   | 3   | 1   |
| $14^2 \times 96$         | bottleneck  | 6   | 160  | 3   | 2   |
| $7^2 \times 160$         | bottleneck  | 6   | 320  | 1   | 1   |
| $7^2 \times 320$         | conv2d 1x1  | -   | 1280 | 1   | 1   |
| $7^2 \times 1280$        | avgpool 7x7 | -   | -    | 1   | -   |
| $1 \times 1 \times 1280$ | conv2d 1x1  | -   | k    | -   |     |

Table 2: MobileNetV2 : Each line describes a sequence of 1 or more identical (modulo stride) layers, repeated  $n$  times. All layers in the same sequence have the same number  $c$  of output channels. The first layer of each sequence has a stride  $s$  and all others use stride 1. All spatial convolutions use  $3 \times 3$  kernels. The expansion factor  $t$  is always applied to the input size as described in Table 1.

| Network           | Top 1       | Params      | MAdds       | CPU          |
|-------------------|-------------|-------------|-------------|--------------|
| MobileNetV1       | 70.6        | 4.2M        | 575M        | 113ms        |
| ShuffleNet (1.5)  | 71.5        | <b>3.4M</b> | 292M        | -            |
| ShuffleNet (x2)   | 73.7        | 5.4M        | 524M        | -            |
| NasNet-A          | 74.0        | 5.3M        | 564M        | 183ms        |
| MobileNetV2       | <b>72.0</b> | <b>3.4M</b> | <b>300M</b> | <b>75ms</b>  |
| MobileNetV2 (1.4) | <b>74.7</b> | 6.9M        | 585M        | <b>143ms</b> |

Table 4: Performance on ImageNet, comparison for different networks. As is common practice for ops, we count the total number of Multiply-Adds. In the last column we report running time in milliseconds (ms) for a single large core of the Google Pixel 1 phone (using TF-Lite). We do not report ShuffleNet numbers as efficient group convolutions and shuffling are not yet supported.

# MNASNet (2018)

- [Tan et al.: MnasNet: Platform-Aware Neural Architecture Search for Mobile \(2018\)](#)
- Automatické hledání optimální architektury

Formulace úlohy jako optimalizace:

$$\underset{m}{\text{maximize}} \quad ACC(m) \times \left[ \frac{LAT(m)}{T} \right]^w$$

$ACC(m)$  ... správnost modelu  $m$

$T$  ... cílová latence = čas potřebný pro dopředný průchod

$LAT(m)$  ... latence změřená přímo na mobilních telefonech

$w = -0.07$

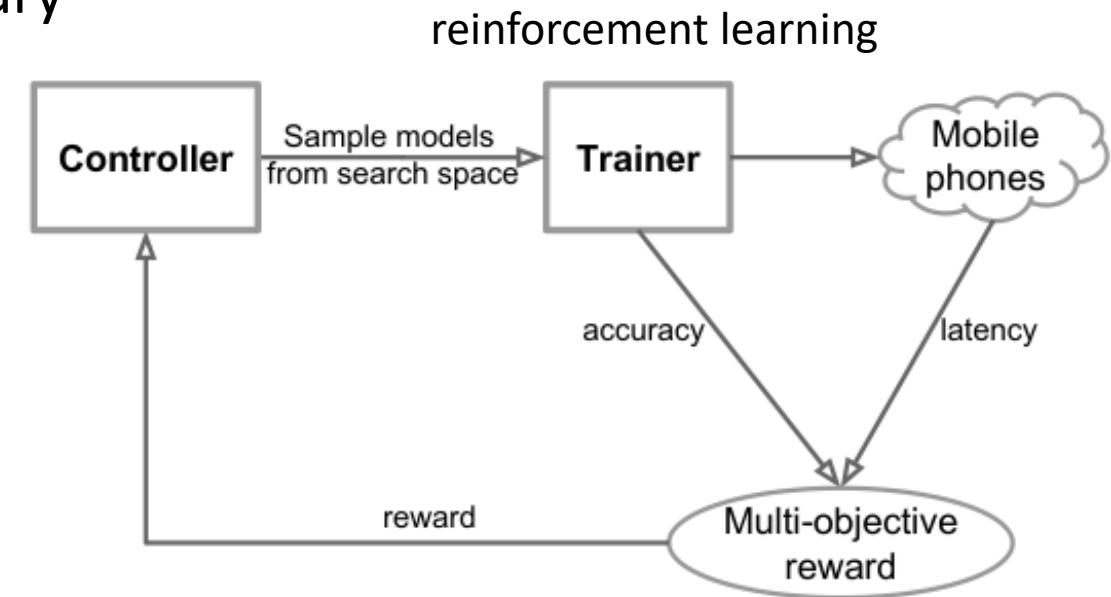
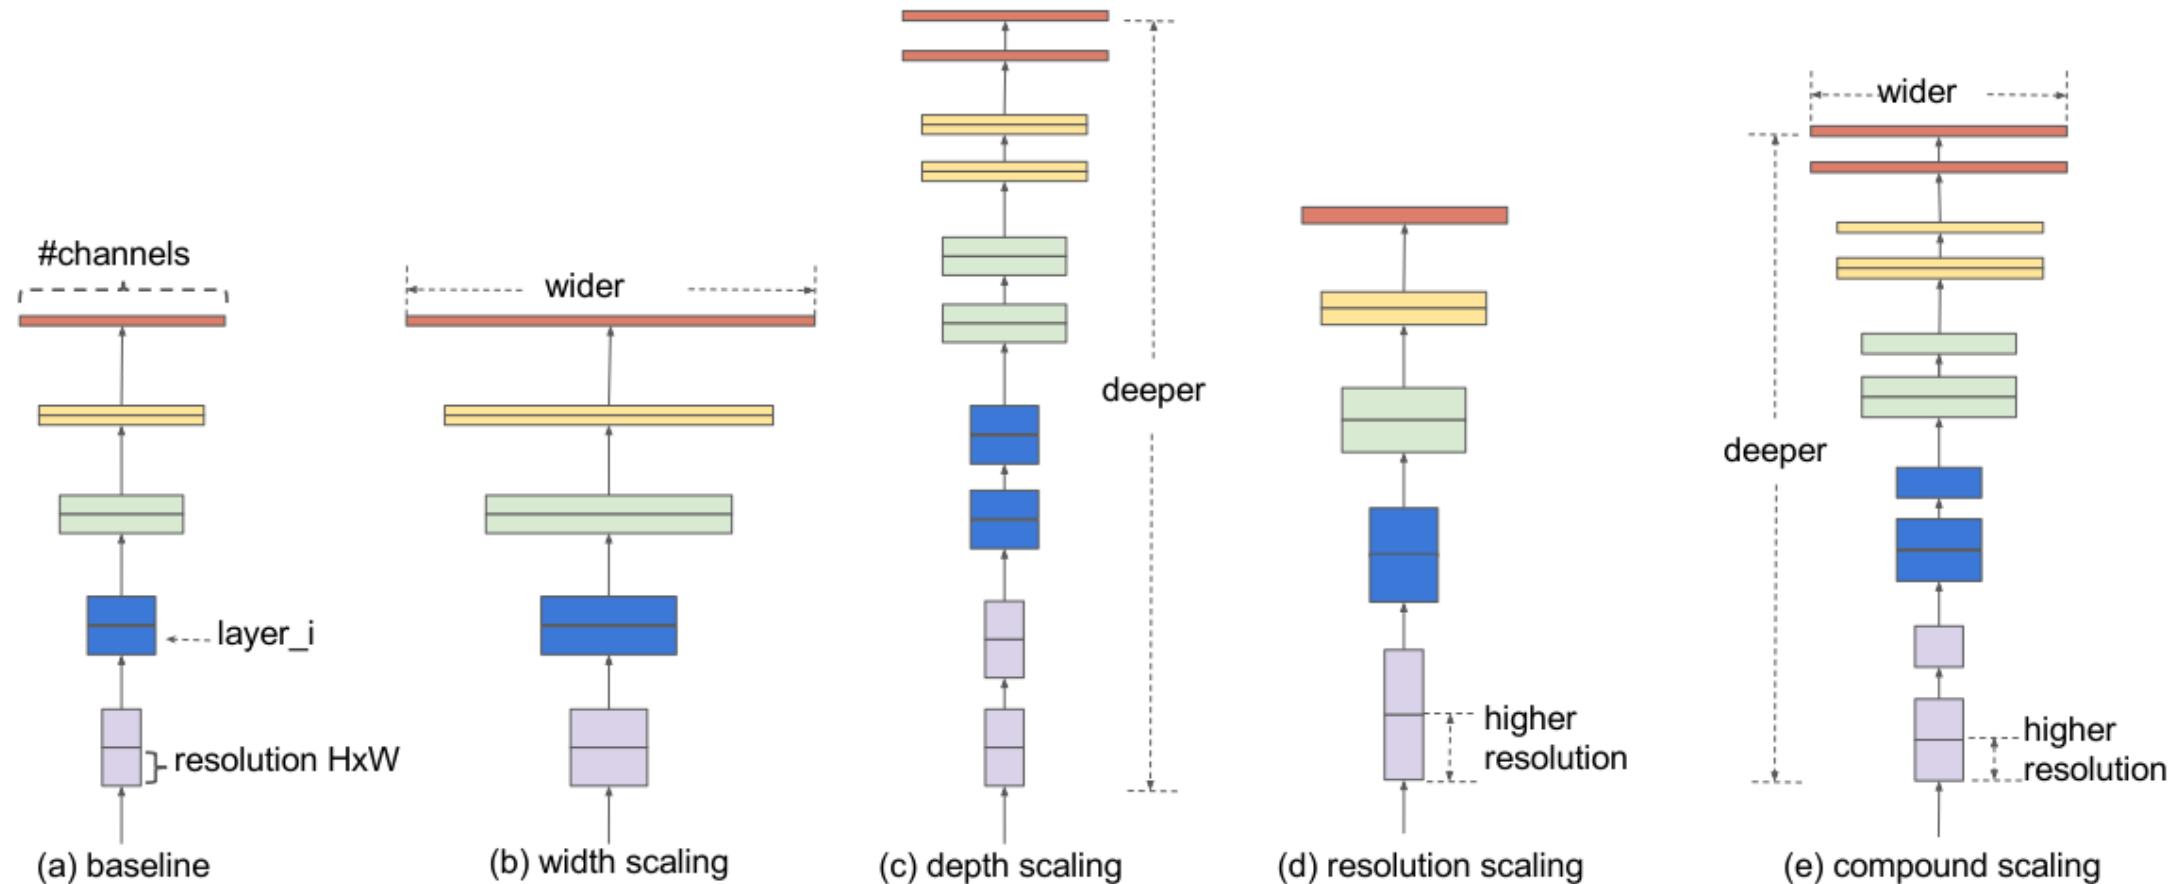


Figure 1: An Overview of Platform-Aware Neural Architecture Search for Mobile.

Hledání není exhaustivní – základním stavebním kamenem je Inverted Residual Block (MobileNetV2), u něhož se pouze upravují hloubka a velikost filtru

# EfficientNet (2019)

- [Tan, Le: EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks](#)



**Figure 2. Model Scaling.** (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.

# EfficientNet (2019)

- [Tan, Le: EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks](#)
- Podobná revoluce jako v roce 2015 přinesl ResNet, stav poznání ve všech oblastech počítačového vidění
- **EfficientNet = neural architecture search + compound scaling**
- Neural architecture search (NAS) - formulováno jako reinforcement learning s expected reward (proximal policy)

$$ACC(m) \cdot [FLOPS(m)/T]^w$$

kde namísto latence je teoretická výpočetní náročnost ve floating point operacích

- Cílovým FLOPS je cca 400 MFLOPS

# EfficientNet (2019)

- Automatickým hledáním NAS vznikne EfficientNet-B0, která má nějaké cílové FLOPs
- Nyní chceme větší síť, ale bez NAS, protože to by nebylo upočítatelné
- Compound scaling
  - Větší síť bude „násobkem“ (škálováním) základní sítě
  - Síť vyjádříme jako spojení s bloků, z nichž každý  $L_i$ -krát opakuje operaci  $\mathcal{F}_i$

$$\mathcal{N} = \bigodot_{i=1 \dots s} \mathcal{F}_i^{L_i}(X_{(H_i, W_i, C_i)}) \quad (1)$$

- Škálovat budeme uvnitř bloků, tj. síť bude mít stejný počet bloků, ty ale budou větší
- Musíme najít optimální poměr toho, jak moc má být větší hloubka (# vrstev), šířka (# filtrů ve vrstvách) a rozlišení (velikost konv. map)
- Zároveň chceme, aby větší verze měla cca 2x více FLOPs

# EfficientNet (2019)

$$\begin{aligned} \text{depth: } d &= \alpha^\phi \\ \text{width: } w &= \beta^\phi \\ \text{resolution: } r &= \gamma^\phi \\ \text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 &\approx 2 \\ \alpha \geq 1, \beta \geq 1, \gamma \geq 1 & \end{aligned}$$

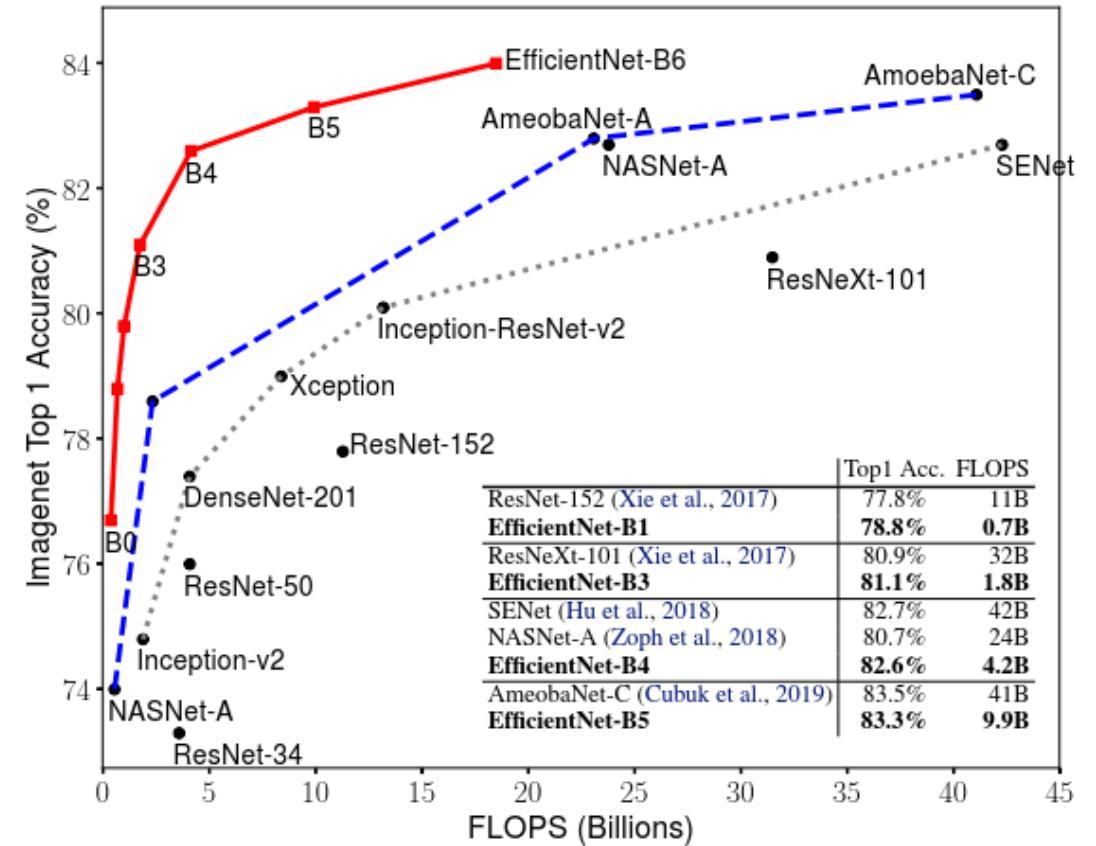
velikost sítě lze ovládat jediným parametrem  $\Phi$  tak, že zvětnutí jeho hodnoty o +1 zdvojnásobí FLOPs (viz podmínka)

- Základní síť EfficientNet-B0 má  $\Phi = 0$
- Větší síť získáme
  - počet vrstev uvnitř každého bloku vynásobíme  $\alpha$ -krát (a zaokrouhlíme)
  - počet filtrů konv. map vynásobíme  $\beta$ -krát
  - rozlišení vstupu zvětšíme  $\gamma$ -krát
- Neznáme hodnoty  $\alpha, \beta, \gamma \rightarrow$  provedeme grid search přes různé kombinace, které splňují podmínu  $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$  a vybereme takovou, která maximalizuje skóre po natrénovalání přeškálované sítě (v článku vyšlo  $\alpha = 1.2, \beta = 1.1, \gamma = 1.15$ )
- Vznikne EfficientNet-B1, protože má  $\Phi = 1$
- Další sítě až do EfficientNet-B6 získáme dosazením  $\Phi = 2 \dots 6$  do škálovacího schématu

# EfficientNet (2019)

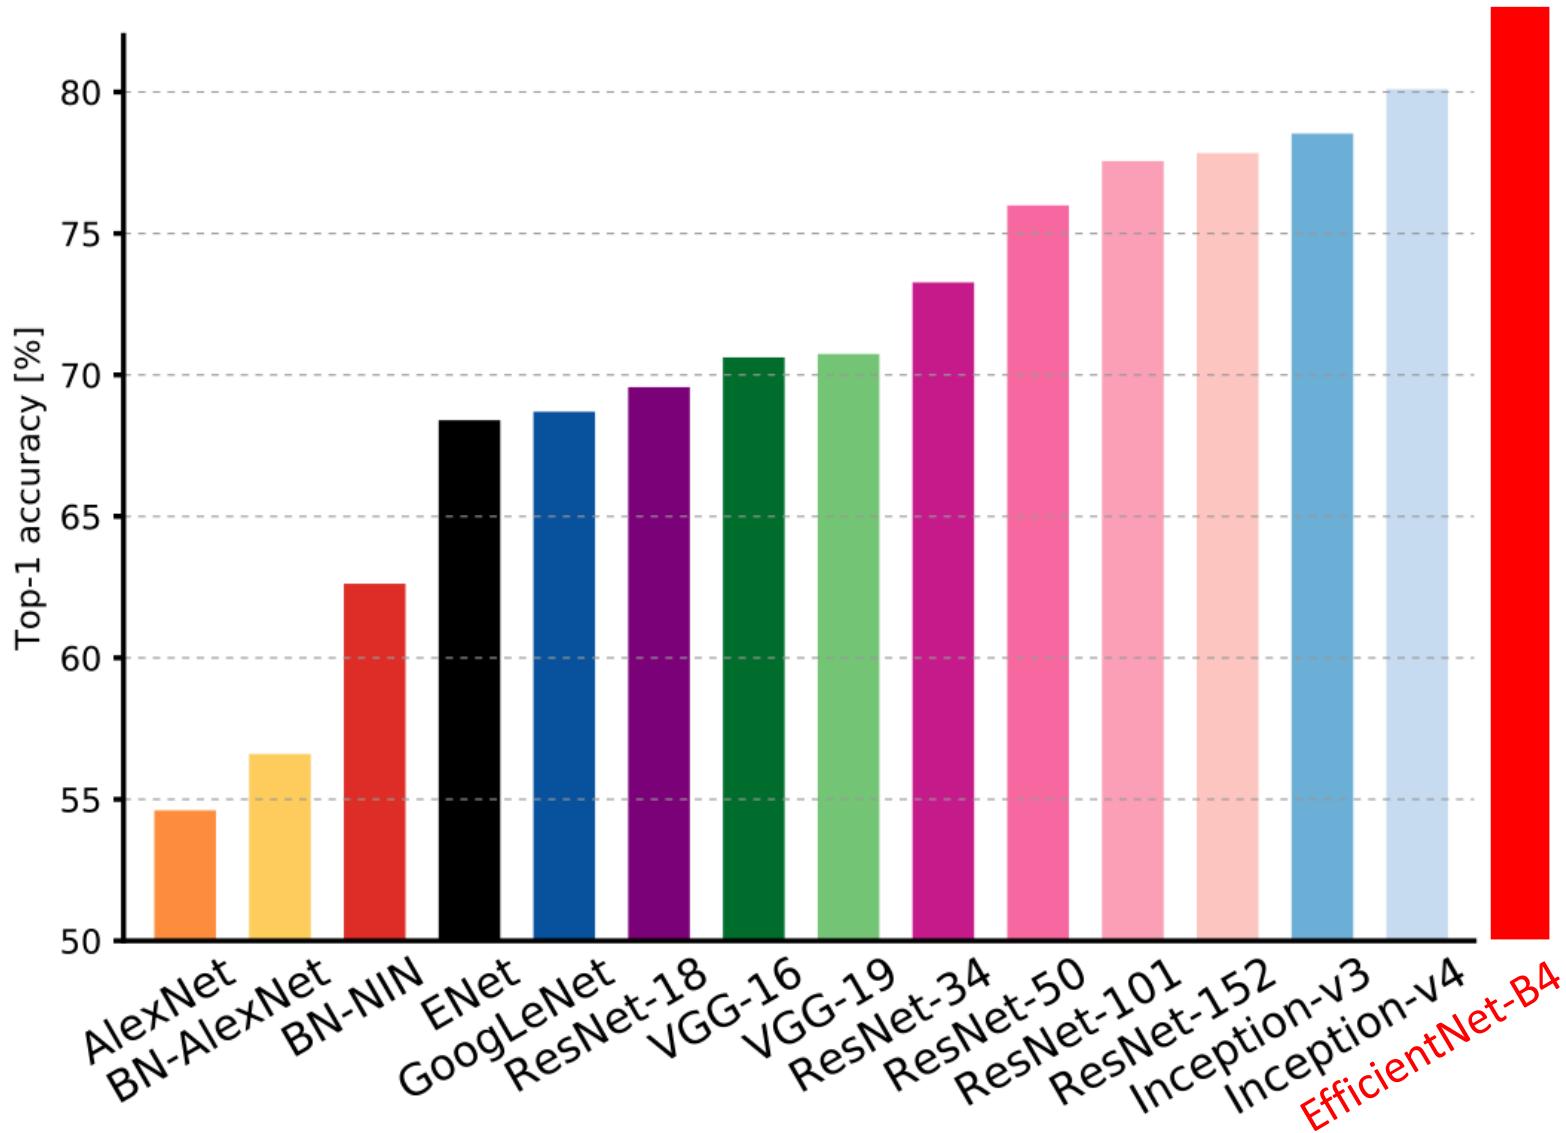
**Table 1. EfficientNet-B0 baseline network** – Each row describes a stage  $i$  with  $\hat{L}_i$  layers, with input resolution  $\langle \hat{H}_i, \hat{W}_i \rangle$  and output channels  $\hat{C}_i$ . Notations are adopted from equation 2.

| Stage $i$ | Operator $\hat{\mathcal{F}}_i$ | Resolution $\hat{H}_i \times \hat{W}_i$ | #Channels $\hat{C}_i$ | #Layers $\hat{L}_i$ |
|-----------|--------------------------------|---|-----------------------|---------------------|
| 1         | Conv3x3                        | $224 \times 224$                        | 32                    | 1                   |
| 2         | MBConv1, k3x3                  | $112 \times 112$                        | 16                    | 1                   |
| 3         | MBConv6, k3x3                  | $112 \times 112$                        | 24                    | 2                   |
| 4         | MBConv6, k5x5                  | $56 \times 56$                          | 40                    | 2                   |
| 5         | MBConv6, k3x3                  | $28 \times 28$                          | 80                    | 3                   |
| 6         | MBConv6, k5x5                  | $14 \times 14$                          | 112                   | 3                   |
| 7         | MBConv6, k5x5                  | $14 \times 14$                          | 192                   | 4                   |
| 8         | MBConv6, k3x3                  | $7 \times 7$                            | 320                   | 1                   |
| 9         | Conv1x1 & Pooling & FC         | $7 \times 7$                            | 1280                  | 1                   |



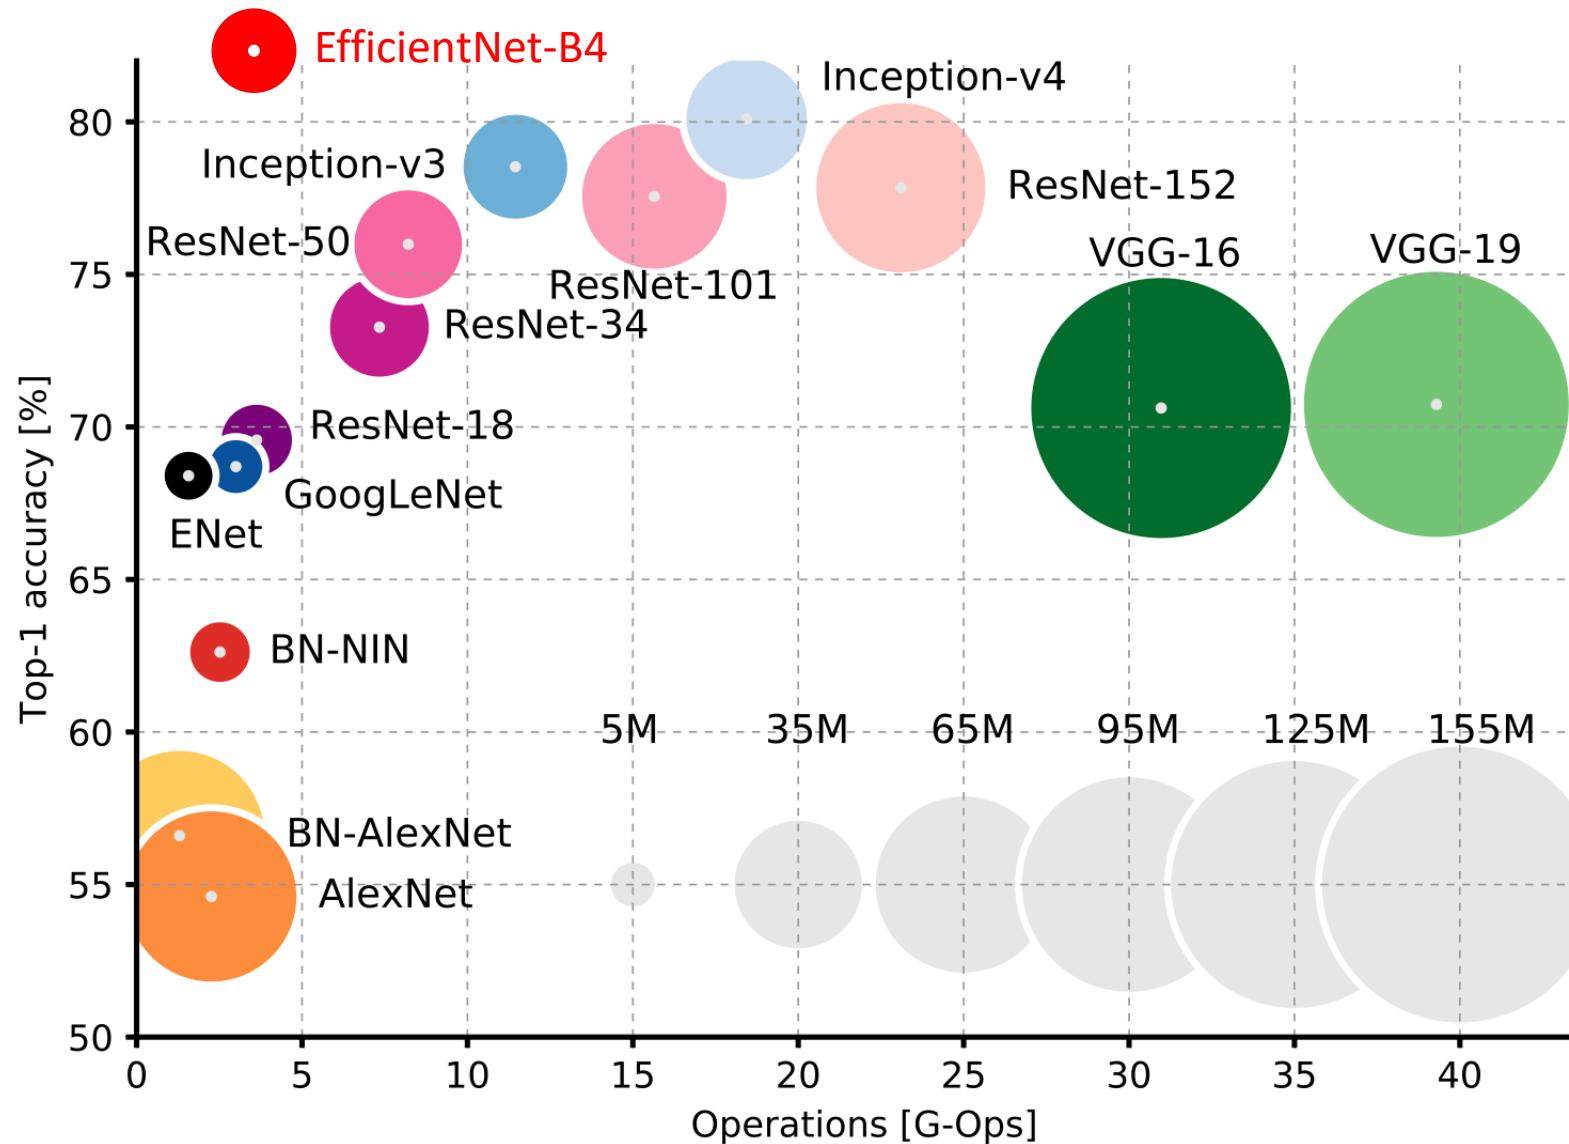
**Figure 5. FLOPS vs. ImageNet Accuracy** – Similar to Figure 1 except it compares FLOPS rather than model size.

# Srovnání nejpoužívanějších CNN architektur



obrázek: [Canziani et al.: "An Analysis of Deep Neural Network Models for Practical Applications"](#)

# Srovnání nejpoužívanějších CNN architektur



velikost znázorňuje  
celkový počet  
parametrů

obrázek: [Canziani et al.: "An Analysis of Deep Neural Network Models for Practical Applications"](#)

# Transfer learning

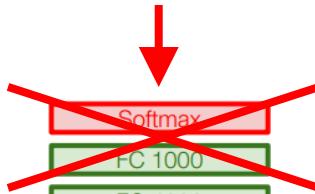
---

# Trénování konvolučních sítí při málo datech

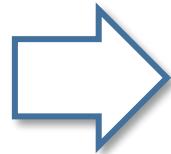
- Popsané architektury mají obvykle miliony parametrů
- Malé datasety na jejich trénování nestačí → výrazný overfit
- I pokud data máme: trénování VGG na ImageNet trvalo autorům 2-3 týdny, a to i s 4x NVIDIA Titan Black GPU
- **Naštěstí lze obejít!**
  1. Můžeme vzít existující již natrénovaný model (např. VGG-16)
  2. Odstraníme poslední klasifikační vrstvu
  3. Nahradíme vlastní

# Transfer learning

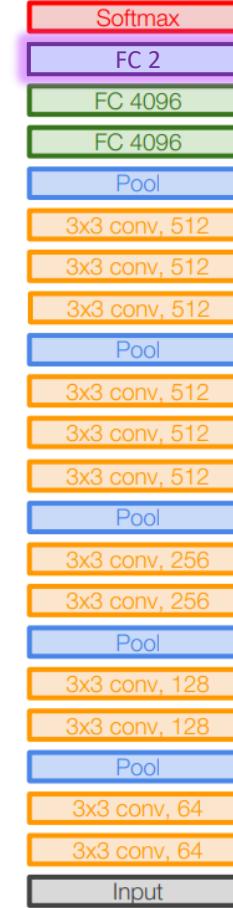
1000 tříd pro ImageNet



poslední lineární vrstvu  
tvaru  $4096 \times 1000$   
zahodíme



2 třídy: kočky vs psi



připojíme vlastní lineární vrstvu  
tvaru  $4096 \times 2$  a náhodně  
Inicializujeme

pokud máme málo dat, je lepší  
konvoluční vrstvy netrénovat →  
layer freeze

ImageNet data

VGG16

můžeme použít vlastní data

# Transfer learning v PyTorch

```
model_conv = torchvision.models.resnet18(pretrained=True)
for param in model_conv.parameters():
    param.requires_grad = False
```

“zmrazení” vrstev, nebudou se trénovat a zůstávají konst. → síť pouze jako extractor příznaků

# Parameters of newly constructed modules have requires\_grad=True by default

```
num_ftrs = model_conv.fc.in_features
model_conv.fc = nn.Linear(num_ftrs, 2)
```

poslední vrstvu klasifikující do 1000 ImageNet tříd nahradíme vlastní, která má pouze 2 třídy

```
model_conv = model_conv.to(device)
```

```
criterion = nn.CrossEntropyLoss()
```

jako seznam parametrů pro optimalizaci předáváme pouze poslední lineární vrstvu (pouze pro urychlení)

# Observe that only parameters of final layer are being optimized as

# opposed to before.

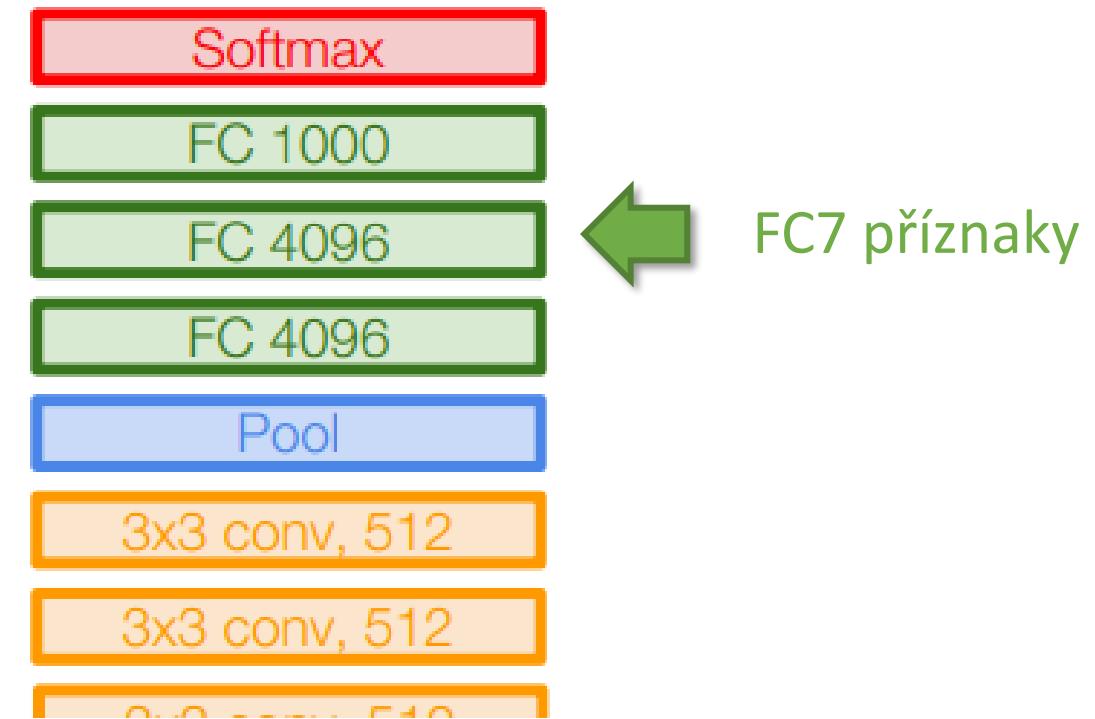
```
optimizer_conv = optim.SGD(model_conv.fc.parameters(), lr=0.001, momentum=0.9)
```

- poté, co je poslední vrstva natrénovaná, je možné opět uvolnit (“rozmrazit”) i konvoluční vrstvy a model dále zlepšit (fine tuning)

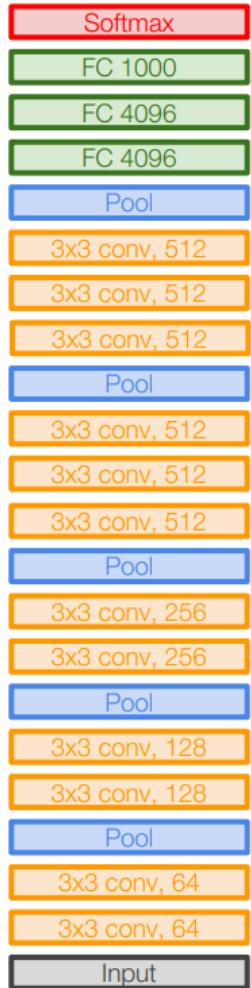
# CNN příznaky

- Výstup z posledních lineárních vrstev lze použít např. jako příznaky (tzv. FC7) → CNN jako “feature extractor”
- Např. VGG-16 předposlední vrstva má rozměr 4096
- Nad těmito příznaky je možné natrénovat libovolný klasifikátor, třeba i rozhodovací stromy/lesy, bayesovské klasifikátory, ...
- Lze také využít pro urychlení trénování: celý dataset projet sítí a pro každý obrázek uložit na disk FC7 příznaky
- Během trénování se pak nemusí znova a znova provádět dopředný průchod celou sítí, pouze těmi posledními

např. VGG-16:



# Transfer learning: shrnutí



specifické příznaky  
(obličeje, text, ...)

obecné příznaky  
(hrany, bloby, ...)

|                  | <b>podobná data</b>                             | <b>odlišná data</b>                    |
|------------------|---|--|
| <b>málo dat</b>  | trénovat spíše jen poslední vrstvu              | problém 😊                              |
| <b>hodně dat</b> | fine tune několika vrstev (lze ale i celou síť) | fine tune více vrstev nebo i celé sítě |